

Area_min Transformer 模型报告

Transformer 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_transformer_20261006_110944
运行时间	11:09:44 ~ 11:20:33 (约 11 分钟, 210 轮训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-10-06
备注	本运行为修复训练脚本错误后的 完整重跑 : 首次尝试 (2026-08-07 101205) 因 PositionalEncoding 中 <code>math.log</code> 未导入而崩溃, 未产出任何模型/指标; 此轮修复后成功训练并保存

概述

Transformer 采用 **3 层 Transformer Encoder** ($d_{\text{model}}=128$ 、4 头注意力、FFN 256、GELU 激活), 与 RNN 相同, 将 522 维特征向量重塑为 (batch, 522, 1) 的序列输入, 通过**自注意力机制**建模特征维度间的依赖关系, 末层池化后映射为 Area_min。训练使用 CosineAnnealingLR 学习率调度与梯度裁剪。

在 Area_min 任务中, Transformer 的 Test $R^2 = -0.0125$ 、Test RMSE = 0.8123, 在 10 个模型中**排名最末** (第 10), 且 Test R^2 为负——“预测劣于”直接预测均值”的基线, 模型**实质失效**, 成为 Area_min 全部 10 个模型中的最差者

(取代此前垫底的 RNN) 。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]) , 与其余模型一致。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

Transformer 使用**固定架构, 不经过 Optuna**:

参数	值
d_model	128
Encoder 层数	3
注意力头数	4
FFN 维度	256
激活	GELU
dropout	0.1
learning_rate	1e-3
weight_decay	1e-5
batch_size	16
调度器	CosineAnnealingLR

固定超参 + 小 batch (16) , 整体容量与训练策略均未针对 522 维小样本优化。

训练过程

日志记录了每 5 轮的验证 RMSE, **训练曲线剧烈震荡, 仅在第 60 轮出现一次单点深谷**:

Epoch	Val RMSE	best
5	0.7921	0.7921
20	0.7271	0.7271
35	0.7203	0.7203
55	0.6789	0.6789
60	0.5493	0.5493
65	1.5803	0.5493
100	0.8117	0.5493
135	1.4455	0.5493
210	0.9997	0.5493

Early stopping at epoch 210, best val RMSE = 0.5493 (epoch 60) 。

关键观察： - 验证 RMSE 在 epoch 60 短暂深降至 **0.5493** 后立即反弹 (epoch 65 飙至 1.58) ，此后再未低于 0.5493，在 0.63~1.58 区间剧烈震荡直至早停——该深谷是训练中的**偶然性单点**，而非稳定收敛标志。 - **Test RMSE (0.8123) 远劣于 Best val RMSE (0.5493)** ，说明 epoch 60 的最优检查点完全无法泛化到测试集，过拟合/退化特征明显。 - 与 RNN (best val 0.6212 → test 0.7203) 相比，Transformer 的 val→test 恶化幅度更大 (0.5493→0.8123) ，表明自注意力路线在该小样本任务上更为脆弱。

测试结果

指标	值
Test RMSE	0.8123
Test MAE	0.5761
Test R ²	-0.0125
Best val RMSE	0.5493

说明：本次 Transformer 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

关键信号：Test R² 为负 (-0.0125) 且 Test RMSE (0.8123) 劣于 Best val RMSE (0.5493) ——这是决定性的失效信号，模型的预测精度连“永远预测训练集均值”都不如，且测试表现远差于验证，泛化完全失败。Test MAE = 0.5761 为全模型最高，RMSE 0.8123 同样垫底。

特征重要性

Transformer 依赖注意力权重，但日志未输出注意力归因。其自注意力会为 522 个特征维度计算两两关联，理论上可做可解释性分析 (attention rollout)，但本项目未生成相应图。鉴于模型整体失效 ($R^2 < 0$)，其特征级解释的参考价值有限。

结论与评价

优点： - 作为注意力机制的探索性 baseline，与 RNN 一起验证了“序列化 + 自注意力”路线在 Area_min 任务上的**不适用性**，为后续方法选择提供了明确的反面证据。

不足： - **性能垫底：** $R^2 = -0.0125$ 为全模型最低 (RNN 尚有 0.2037)，RMSE 0.8123、MAE 0.5761 均为 10 个模型中最差，取代 RNN 成为新的最末位模型。
- 训练曲线 210 轮剧烈震荡，最优 val 仅为第 60 轮的一次偶然深谷 (0.5493)，随后反复反弹，实质退化为输出近似常量；最优检查点在测试集上完全失效 (test 0.8123 $\gg$ val 0.5493)。
- 与 RNN 相同的结构性问题：522 维异构特征**无自然序列关系**，自注意力建模的“依赖”缺乏物理意义；而 Transformer 参数量大、对 531 条小样本更容易过拟合。
- 固定超参未优化，小 batch + 大模型加剧了不稳定性，训练成本 (约 11 分钟) 与收益严重失衡。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R ²
7	XGBoost	0.5495	0.5366
8	MLP	0.5547	0.5278
9	RNN	0.7203	0.2037
10	Transformer	0.8123	-0.0125

方法论结论： 三个深度模型 (MLP 0.5278 / RNN 0.2037 / Transformer -0.0125) 的排序清晰地说明——对 522 维 PharmHGT 扁平特征，**全连接 (MLP) $\gg$ 循环 (LSTM) $\gg$ 注意力 (Transformer)**。Transformer 的强项在

于长程依赖与大规模预训练，而本任务样本量小、特征维度排列无时序意义，恰恰落在其能力盲区。**Transformer 应被排除出本项目的生产预测方案**；若未来引入图结构（AttentiveFP）或大分子表示，方可重新评估注意力路线的价值。