

Area_min CatBoost 模型报告

CatBoost 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_catboost_20260806_205305
调参日志	同上运行目录 train.log (Optuna 50 轮)
运行时间	20:53 ~ 22:46 (约 1 小时 53 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CatBoost 是 Yandex 开源的梯度提升框架，以**对称树 (oblivious trees)** 与**有序目标编码**著称：每层所有叶子共享同一分裂特征，天然抗过拟合且支持分类特征的有序统计编码。其内置**过拟合检测器**在验证误差停止改善时自动早停，训练流程高度自动化。

在 Area_min 任务中，CatBoost 的 Test R² = 0.5664、Test RMSE = 0.5315，**在 9 个模型中排名第 6**，处于中游偏后。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²)，与 Gamma_max 负相关 (r = -0.62)。CatBoost 是本 target 首个运行的模型，日志开头为 [Cache MISS] (触发 522 维特征首次计算并缓存)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征。本次运行为首个运行 ([Cache MISS]) , 现场计算 607/607、70/70 个有效分子的特征并缓存至 data\features\surfpro\Area_min\ , 后续模型全部复用 ([Cache HIT]) 。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条; 调参阶段采用 5 折交叉验证。
- **数据划分**: train_test_split(0.125, random_state=42) , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 depth[4,10]、learning_rate[5e-3,0.3]、iterations[500,3000]、l2_leaf_reg[1,50] 等。

最优试验 (Trial 38, CV RMSE = 0.4033) :

参数	值
depth	7
learning_rate	0.0127
iterations	2622
l2_leaf_reg	3.80
random_strength	1.60
bagging_temperature	7.95
border_count	42
one_hot_max_size	21
leaf_estimation_iterations	6
min_data_in_leaf	8
Best CV RMSE	0.4033

Optuna 参数重要度:

参数	重要度
l2_leaf_reg	0.4657
random_strength	0.2069
learning_rate	0.1625
iterations	0.0727
其余 (border_count/bagging_temperature/depth...)	< 0.04

调优过程观察： - **l2_leaf_reg (叶子 L2 正则) 重要度压倒性 (0.47)**，其次为 random_strength 与 learning_rate——说明在 522 维高维特征上，正则强度是 CatBoost 表现的首要杠杆，`l2_leaf_reg=3.8` + `random_strength=1.6` 的组合有效抑制了分裂过拟合。 - 最优解采用**低学习率 (0.013) + 长迭代 (2622)** 的保守路线；搜索过程在 Trial 38 后继续收敛到 0.41~0.42 的稳定区间，未再突破 0.40。 - 50 轮中仅 1 轮被剪枝 (Trial 7)；单轮 5 折 CV 平均数分钟，**整体调参耗时约 1 小时 53 分钟**，为 9 个模型中最长 (CatBoost 全量迭代训练昂贵)。


训练过程

调参完成后以最优参数在 531 条训练集上训练最终模型，**过拟合检测器在 bestIteration = 1012 触发早停** (patience=150，训练日志显示 test RMSE 自迭代 1012 后不再改善，`Stopped by overfitting detector`)，最终模型收缩至前 1013 轮迭代。学习曲线显示 learn RMSE 持续下降 (0.83→0.10) 而 test RMSE 在 0.288 附近触底，印证早停必要性。

测试结果

指标	值
Test RMSE	0.5315
Test MAE	0.2908
Test R ²	0.5664
Best CV RMSE	0.4033

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.5315) 较 Best CV (0.4033) 回退约 **0.13**，是 9 个模型中回退幅度最大者之一——尽管 CV 上 CatBoost 在树模型中表现最优 (0.4033，仅逊于深度模型 MLP 的 0.3687)，但在 70 条独立测试集上表现却滑落至中游 (MAE 0.2908 尚可)。Test MSE = 0.2825 与之印证。这一“CV 高、Test 低”的落差提示其最优参数对验证集存在一定过拟合，或测试集与 CV 分布存在差异。

特征重要性 (Top 20)


CatBoost 输出特征重要度 (Top 20, CatBoost 内部重要性口径，数值为相对权重)，前 5 位为：

1. **maccs_101** (MACCS 药效团子结构键, 4.9)
2. **maccs_105** (MACCS 药效团子结构键, 4.0)
3. **brics_10** (BRICS 片段直方图桶, 2.4)
4. **atom_mean_48** (Gasteiger 电荷分箱聚合, 1.9)
5. **atom_mean_26** (氢键供体 one-hot 聚合, 1.6)


MACCS 子结构位 (maccs_101 / maccs_105) 与 BRICS 碎片 (brics_10) 居首，与 HistGB 的 permutation 结论**高度一致**；紧随其后的原子电子结构特征 (Gasteiger 电荷、H 键供体、配位度) 与 NumRings/MolWt/NAtoms 等尺寸特征共同构成归因图景。这说明 Area_min 的预测由**子结构身份为主、尺寸/电子结构为辅**共同决定。下方为 `shap_catboost.py` 生成的 SHAP 实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: maccs_101、maccs_105、brics_10 等子结构特征居前, 与日志重要度排序一致。



Top-1 特征依赖图: *maccs_101* 的 SHAP 贡献随取值发生翻转, 体现该子结构存在/缺失对预测的二元作用。

结论与评价

优点:

- **Best CV RMSE 0.4033 为树模型中最低**, 调参阶段表现突出, 说明 CatBoost + 有序编码在 531 条数据上拟合能力极强。
- 内置过拟合检测器自动早停 (`bestIteration=1012`), 训练流程稳健。
- 参数重要度 (`l2_leaf_reg=0.47`) 给出明确的正则方向洞察, 指导了该 target 的整体正则策略。

不足:

- **Test $R^2 = 0.5664$ 仅排第 6**, Test 相对 CV 回退约 0.13, 为树模型中最大落差——CV 高估了其真实泛化, 交付精度低于第一梯队。
- 调参成本全模型最高 (约 1 小时 53 分钟), 性价比低。
- 依赖 l_2 正则程度强, 参数敏感, 需 SHAP 图才能完成精确归因。

横向定位 (9 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
4	RF	0.5179	0.5884
5	NGBoost	0.5240	0.5786
6	CatBoost	0.5315	0.5664
7	XGBoost	0.5495	0.5366
8	MLP	0.5547	0.5278

CatBoost 的 CV 与 Test 指标差异巨大，是本 target 的一个警示案例：**CV 最优 ≠ Test 最优**。若以 CV 作为选型依据会误选 CatBoost；实际交付应以 HistGB/CIF (Test R² ≈ 0.64) 为准。在后续 target 训练中应关注“CV-Test 落差”这一泛化信号。