

Area_min HistGB 模型报告

HistGB 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_histgb_20260807_075850
调参日志	同上运行目录 train.log (Optuna 50 轮)
运行时间	07:58 ~ 09:03 (约 64 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

HistGB (`sklearn.ensemble.HistGradientBoostingRegressor`) 是 sklearn 对梯度提升树的**直方图加速**实现：将连续特征离散化为 `max_bins` 个分箱，以近似分箱代替精确分裂点搜索，从而在大样本上显著提速，同时保持了梯度提升的强非线性拟合能力，并内置 L2 正则与早停。

在 Area_min 任务中，HistGB 的 Test R² = 0.6416、Test RMSE = 0.4833，**在 9 个模型中排名第 1**，与 CIF (R² = 0.6377) 共同构成该 target 的第一梯队——这是全部 6 个 target 中少数几个“直方图梯度提升登顶”的场景。Area_min 描述表面活性剂分子在气-液界面单分子膜中所占的最小截面积 (nm²)，与 Gamma_max 负相关 (r = -0.62)，主要受分子头部/尾部结构与整体疏水体积驱动。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条; 调参阶段采用 5 折交叉验证。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 22, CV RMSE = 0.4512) :

参数	值
learning_rate	0.0171
max_iter	2475
max_depth	12
max_leaf_nodes	49
min_samples_leaf	15
l2_regularization	4.18e-4
max_bins	241
Best CV RMSE	0.4512

调优过程观察: - 最优解呈现典型的**保守配置**: 学习率偏低 (0.017) 、迭代充分 (2475 轮) , 配合较小的叶子数 (49) 与适度 L2 正则, 说明 Area_min 上每棵树的单次贡献宜小、靠增加迭代次数逼近目标。 - 早期试验 (Trial 0/4) 即进入 0.45~0.46 的较高水平, 随后 Trial 20~23 围绕 `learning_rate=0.014~0.017` 、`max_iter=2300~2500` 、`max_leaf_nodes=49~59` 收敛, 说明该参数组合是稳定的局部最优。 - 50 轮中仅 1 轮被剪枝 (Trial 8) , 搜索效率高。


训练过程

调参完成后直接以最优参数在 531 条训练集上训练最终模型 (Training Final Model with Best Hyperparameters) , 随后在 70 条测试集上评估。max_iter 固定为 2475 且无提前终止触发, 训练过程平稳无早停。

测试结果

指标	值
Test RMSE	0.4833
Test MAE	0.2689
Test R ²	0.6416
Best CV RMSE	0.4512

图: 预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (0.4833) 略高于调参 CV (0.4512) , 属于可接受的回退幅度; **Test MAE = 0.2689 为 9 个模型中最低**, 说明残差分布集中、对多数分子的预测都贴近真实值。Test MSE = 0.2335 与之印证。

特征重要性 (Top 20)

HistGB 输出基于 **permutation 置换重要度** (Top 20) , 前 5 位为:


1. **maccs_101** (MACCS 药效团子结构键, 0.2745 ± 0.0262)
2. **brics_10** (BRICS 片段直方图桶, 0.2667 ± 0.0268)
3. **atom_mean_20** (原子四配位 one-hot 的均值聚合, 0.1237 ± 0.0247)

4. **atom_mean_48** (Gasteiger 电荷分箱聚合, 0.0703 ± 0.0050)


5. **maccs_141** (MACCS 药效团子结构键, 0.0596 ± 0.0113)

MACCS 药效团位 (maccs_101 / maccs_141) 与 BRICS 碎片 (brics_10) 占据前两位, 权重总和超 0.5——这与 Area_min 的物理本质高度吻合: 最小截面积主要由分子所含的具体官能团/子结构 (亲水头基的极性取代模式) 决定, 而非单纯的分子大小。atom_mean_20 (配位度)、atom_mean_48 (Gasteiger 电荷) 反映分子局部电子结构对界面堆积的调制。NumRings、HeavyAtoms、MolWt 等尺寸类描述符排名偏后 (第 6、12、15 位), 说明**子结构身份比整体尺寸更能预测 Area_min**。


下方为 shap_histgb.py 生成的 SHAP 分析实测结果:



SHAP 蜜蜂图: 每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: maccs_101、brics_10 等子结构特征居前, 与 permutation 重要度排序一致。



Top-1 特征依赖图: `maccs_101` 取值越高, SHAP 贡献方向发生翻转, 体现子结构存在/缺失对预测的二元作用。

结论与评价

优点: - 9 个模型中 Test R² 最高 (0.6416) , 且 MAE 全模型最低

(0.2689) , 是 Area_min 的最优模型。 - 直方图实现训练/调参速度快 (50 轮约 64 分钟, 含最终训练) , 性价比高于 CIF。 - 内置 L2 正则与分箱, 对 522 维高维稀疏特征抗过拟合能力强。

不足: - Test RMSE (0.4833) 较 Best CV (0.4512) 回退 0.03, 存在轻度过拟合于验证集。 - 与 CIF (0.4859) 差距极小 (0.003) , 领先优势不显著, 需结合 SHAP 图进一步确认稳定性。 - 依赖 permutation 重要度 (约 50 次重排) , 单次运行耗时较长, 且结果存在随机波动 (± 0.02 量级) 。

横向定位 (9 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
1	HistGB	0.4833	0.6416
2	CIF (ExtraTrees)	0.4859	0.6377
3	LightGBM	0.5157	0.5919

HistGB 与 CIF 构成 Area_min 的第一梯队 ($R^2 \approx 0.64$)，明显领先其余模型 0.03 以上。两者的特征归因高度一致（子结构主导），互为印证。若追求**最小残差集中度 (MAE)** 优先选 HistGB；若追求更强的稳定鲁棒性可同等考虑 CIF。