

Area_min LightGBM 模型报告

LightGBM 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_lightgbm_20260807_090524
调参日志	同上运行目录 train.log (Optuna 50 轮)
运行时间	09:05 ~ 09:07 (约 2 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

LightGBM (Light Gradient Boosting Machine) 是微软开源的梯度提升框架, 采用**叶子生长 (leaf-wise) 策略**与直方图分箱, 能在固定叶子数下优先分裂损失最大的叶子, 配合基于梯度的单边采样 (GOSS) 与互斥特征捆绑 (EFB), 训练效率在主流 GBDT 中首屈一指。

在 Area_min 任务中, LightGBM 的 Test R² = 0.5919、Test RMSE = 0.5157, **在 9 个模型中排名第 3**, 处于第二梯队首位 (紧随第一梯队的 HistGB/CIF 之后)。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²), 与 Gamma_max 负相关 (r = -0.62)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条; 调参阶段采用 5 折交叉验证。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 `boosting_type[gbdt, dart]` 、 `max_depth[3,15]` 、 `num_leaves[15,255]` 等。

最优试验 (Best Trial, CV RMSE = 0.4651) :

参数	值
boosting_type	gbdt
max_depth	7
num_leaves	227
learning_rate	0.0578
n_estimators	2073
subsample	0.835
colsample_bytree	0.746
reg_alpha / reg_lambda	~2.2e-8 / 1.05e-3
min_child_samples	18
min_split_gain	0.035
Best CV RMSE	0.4651

调优过程观察: - 最优解收敛到 **gbdt + 中等深度 (7) + 大叶子数 (227) + 低学习率 (0.058) + 长迭代 (2073)** : leaf-wise 策略下叶子数偏大、深度受限, 靠加大迭代次数逼近目标, 与 Area_min 平滑的回归面相适应。 - 早期试验 (Trial 0) 使用 dart 提升时 CV 高达 1.03 (drop-out 正则在该任务上反而拖累

拟合)，dart 类试验普遍表现不佳并被 MedianPruner 快速剪枝；最终最优为传统 gbdt，说明该 target 无需 dropout 型正则。- 50 轮中多轮被剪枝（Trial 6/7 等），单轮 5 折 CV 秒级完成，整体调参约 1 分钟，效率极高。


训练过程

调参完成后以最优参数在 531 条训练集上训练最终模型，**早停在 best iteration 138 触发**（验证 RMSE = 0.3221，patience=50）。早停较早（<150 轮）说明模型在验证集上快速收敛，继续训练对验证误差无改善；最终以验证最优权重作为交付模型。

测试结果

指标	值
Test RMSE	0.5157
Test MAE	0.3206
Test R ²	0.5919
Best CV RMSE	0.4651

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.5157) 较 Best CV (0.4651) 回退约 0.05，为第一梯队模型的普遍回退水平；**MAE (0.3206) 在 9 个模型中偏高**（仅优于 MLP/RNN），说明对中间区间分子存在系统性偏差，残差分布比 HistGB 更散。Test MSE = 0.2659 与之印证。

特征重要性 (Top 20)


LightGBM 输出 **split-based (分裂次数) 重要度** (Top 20) , 前 5 位为:

1. **LogP** (脂水分配系数, 79 次分裂)
2. **tail_ratio** (尾链碳比例, 58)
3. **atom_mean_26** (氢键供体 one-hot 聚合, 56)
4. **atom_std_25** (杂化态 one-hot 标准差聚合, 47)
5. **MolWt** (分子量, 47)


与 HistGB 的 permutation 排序**明显不同**: LightGBM 把疏水性 (LogP) 、头尾结构 (tail_ratio / head_ratio) 与分子尺寸 (MolWt、RotBonds) 放在首位, 而 HistGB 更看重 MACCS/BRICS 子结构。这一差异源于两种重要度口径不同 (分裂次数 vs 置换) , 但均指示**疏水性-尺寸-头尾结构**在 Area_min 预测中的核心地位。SHAP 归因 (下方图) 进一步将 MolWt 排在首位, 与 split 重要度大体一致。



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、atom_mean_20、maccs_113、NumRings、head_ratio 居前。



Top-1 特征依赖图：MolWt 与 SHAP 贡献近似正相关，分子量增大 → 预测的每分子最小面积增大，符合界面堆积的物理直觉。

结论与评价

优点： - **9 个模型中排名第 3** ($R^2 = 0.5919$)，稳居第二梯队首位。 - 训练/调参成本极低（约 2 分钟），与 CIF 并列最快档；gbdt + 早停的配置稳定可复现。 - split 与 SHAP 双重重要度相互印证，特征归因清晰（疏水性/尺寸/头尾结构主导）。

不足： - 与第一梯队 (HistGB/CIF, $R^2 \approx 0.64$) 存在约 0.05 的 R^2 差距，未进入最优梯队。 - MAE (0.3206) 偏高，对中间区间分子的系统性偏差大于 HistGB (0.2689)。 - dart 提升在该任务上失效（最优试验 CV 差），搜索空间对该 target 部分无效，探索略浪费。

横向定位 (9 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
1	HistGB	0.4833	0.6416
2	CIF (ExtraTrees)	0.4859	0.6377
3	LightGBM	0.5157	0.5919
4	RF	0.5179	0.5884
5	NGBoost	0.5240	0.5786

LightGBM 与 RF 几乎并列（差 0.002），是第二梯队的代表；相对第一梯队有 0.03 的 RMSE 差距，但训练速度快、可解释性好。若追求“速度 + 可用精度”兼顾，LightGBM 是不错的工程化选择；追求精度上限仍以 HistGB/CIF 为优。