

Area_min MLP 模型报告

MLP 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_mlp_20260807_094659
调参日志	runs\Area_min\Area_min_mlp_tuning_20260807_090916\train.log (Optuna 50 轮)
运行时间	调参 09:09 ~ 09:47 (约 38 分钟), 最终训练 09:47
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

MLP (多层感知机) 是 9 个模型中唯一的**前馈全连接深度网络** (RNN 为序列式深度模型)。架构为 Linear → BatchNorm → 激活 → Dropout 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 Area_min 任务中，MLP 的 Test $R^2 = 0.5278$ 、Test RMSE = 0.5547，在 9 个模型中排名第 8，为深度模型中较优者（显著优于 RNN 的 0.20），但仍低于全部 7 个树模型。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积（nm²），与 Gamma_max 负相关（ $r = -0.62$ ）。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载，与其余模型一致。
- **数据规模**：训练池 607 条（531 训练 + 76 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner）。这是深度模型中唯一使用 Optuna 的（RNN 用固定架构）。

最优试验（Trial 15, CV RMSE = 0.3687）：

参数	值
n_layers	5
hidden_dim	526
dropout	0.0845
activation	leaky_relu
learning_rate	5.37e-4
weight_decay	6.16e-5
batch_size	89
Best CV RMSE	0.3687

调优过程观察： - 早期试验（Trial 0/1）表现差（CV RMSE 0.53 / 0.79），原因是学习率过低（ $1.5e-5$ / $3.5e-5$ ）导致欠拟合；**搜索快速收敛到 $lr \in [4e-4, 1e-3]$ 的合理区间。** - 最优解偏好 **5 层 + 中等隐藏层（~520） + leaky_relu** 的结构，dropout 取 0.08（相对低正则），与 pCMC 任务的 GELU 偏好不同，说明该 target 上浅-中度网络 + 低丢弃即可。 - Trial 15 之后大量试验（18 轮）被 MedianPruner 剪枝，搜索集中于收敛区；Trial 45 的 CV 0.3691 与最优仅差 $4e-4$ ，最优解稳定。 - 单轮 5 折 CV 平均约 40 秒，深度网络调参成本（约 38 分钟）高于多数树模型。

训练过程

最终模型以最优参数在 531 条数据上训练，**早停在 epoch 190 触发**。训练约 190 个 epoch 表明网络需要较多迭代收敛，但早停机制保证了未出现过拟合蔓延；最终以验证最优权重（而非末轮权重）作为交付模型。

说明：最终训练与调参在不同目录中执行——

`Area_min_mlp_tuning_20260807_090916` 保存调参过程，

`Area_min_mlp_20260807_094659` 为最终训练运行目录。

测试结果

指标	值
Test RMSE	0.5547
Test MAE	0.3594
Test R ²	0.5278
Best CV RMSE	0.3687
Best val RMSE	0.3677

说明：本次 MLP 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用

`train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (0.5547) 较 Best CV (0.3687) 回退约 **0.19**，是 9 个模型中回退幅度最大者——MLP 在 CV 上为**全模型最低 (0.3687，优于 CatBoost 的 0.4033)**，但独立测试集上仅排第 8。这提示 5 折 CV 对该网络的泛化估计明显偏乐观，70 条小测试集下深度模型的评估方差与分布偏移被放大。Test MSE = 0.3077 与之印证。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因（本次 Area_min 运行未生成 SHAP 图）。基于其余模型的一致性结论，可推断其预测主要由 **MolWt**、

MACCS 子结构位、head_ratio/tail_ratio (头尾结构) 等疏水性-尺寸-结构特征驱动——这是 7 个树模型 SHAP 分析的共识归因。

结论与评价

优点： - **深度模型中的较优者**： $R^2 = 0.5278$ ，显著优于 RNN (0.20)，证明神经网络能部分挖掘 522 维手工特征的非线性结构。 - 使用 Optuna 充分调参 (vs 固定架构的 RNN)，超参选择有依据、结果可复现。 - **Best CV RMSE = 0.3687 为 9 个模型中最低**，在训练分布内拟合能力全模型最强。

不足： - **Test $R^2 = 0.5278$ 仅排第 8**，CV 与 Test 落差约 0.19，泛化到独立测试集能力弱，为全模型最大落差之一。 - MAE (0.3594) 为 9 个模型中最高，残差分布散、对中间区间分子存在系统性偏差。 - 调参成本高 (约 38 分钟)，且黑盒不可解释、不提供不确定性估计。

横向定位 (9 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
6	CatBoost	0.5315	0.5664
7	XGBoost	0.5495	0.5366
8	MLP	0.5547	0.5278
9	RNN	0.7203	0.2037

MLP 在 Area_min 上**未兑现其 CV 潜力**：调参阶段 CV 为全模型最低 (0.3687)，但测试阶段垫底梯队。这一结果与 pCMC 任务 (MLP 排名第 5、深度最优) 形成对比，提示深度网络在该 target 的小样本 (531) + 高维 (522) 配置下泛化不稳。若需深度模型，可考虑更强的正则/集成；但就交付精度而言，应优先 HistGB/CIF。