

Area_min NGBost 模型报告

NGBost 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_ngboost_20260807_094721
调参日志	同上运行目录 train.log (预调优, 跳过 Optuna)
运行时间	09:47:21 ~ 09:47:37 (约 16 秒)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

NGBost (Natural Gradient Boosting) 是斯坦福提出的**概率型梯度提升**: 它在每一轮同时学习目标分布的参数 (默认 Normal 分布的均值 μ 与方差 σ) , 用**自然梯度**而非普通梯度更新, 最终输出每个样本的完整概率分布而非单点预测。这在 9 个模型中独树一帜——除预测值外还给出**逐分子不确定性估计**。

在 Area_min 任务中, NGBost 的 Test R² = 0.5786、Test RMSE = 0.5240, **在 9 个模型中排名第 5**, 处于第二梯队中部。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²) , 与 Gamma_max 负相关 (r = -0.62) 。NGBost 的统计输出平均预测标准差 0.1264 nm², 可在预测置信度上提供附加价值。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

本次运行**使用预调优参数、跳过 Optuna 搜索** (Using pretuned hyperparameters) :

参数	值
n_estimators	637
learning_rate	0.0337
minibatch_frac	0.723
max_depth	5
min_samples_leaf	13
score_rule	LogScore (对数分数)
输出分布	Normal (均值 ± 方差双输出)

参数来源为旧调参日志 (本项目此前对 pCMC 等 target 的 NGBoost 预调优结论) , 采用**保守浅树 (max_depth=5) + 低学习率 (0.034) + 较多迭代 (637)** 的配置, 配合 minibatch 采样 (0.72) 稳定自然梯度估计。Score rule 取 LogScore 对应最大化对数似然的概率训练目标。


训练过程

最终模型在 531 条训练集上直接训练 637 轮 (日志仅打印 iter 0/100/200/.../600) , 训练损失从 1.17 单调下降至 -0.93 (对数分数为负值属正常) , 无早停。由于跳过 Optuna, 整段训练约 16 秒, 是 9 个模型中训练成本最低者之一。

测试结果

指标	值
Test RMSE	0.5240
Test MAE	0.2964
Test R ²	0.5786
平均预测标准差	0.1264 (nm ²)


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.5240) 与 MAE (0.2964) 均居中游，略优于 CatBoost 而略逊于 LightGBM/RF；**MAE (0.2964) 为 9 个模型中第 4 低**，残差分布尚可。Test MSE = 0.2746 与之印证。作为概率模型，其输出的平均预测标准差 (0.1264 nm²) 可在筛选“预测不确定”的分子时提供参考，但该量级是否贴合真实残差需进一步校准。

特征重要性


NGBoost 的对象返回 `feature_importances_` 形状为 (2, 522) (分别对应均值与方差两个分布参数的树集合)，脚本检测到形状不匹配后跳过输出 (unexpected shape (2, 522), skipping)，因此日志**未提供 Top-20 特征列表**。精确归因须依赖 `shap_ngboost.py` 的 **KernelExplainer** SHAP 分析 (NGBoost 非树结构，无法用 TreeExplainer)。下方 SHAP 图为该分析的实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、maccs_101、head_ratio、maccs_126、atom_std_20 居前。



Top-1 特征依赖图: MolWt 与 SHAP 贡献正相关, 分子量增大 → 预测的每分子最小面积增大, 与 LightGBM/RF 的 SHAP 结论一致。

SHAP 归因指示 **MolWt (分子量) 为第一重要特征**, MACCS 子结构位

(maccs_101/126) 与 head_ratio (头基比例) 紧随其后——“分子尺寸 + 子结构身份 + 头尾结构”三者协同决定 Area_min, 与其余树模型结论高度一致。

结论与评价

优点: - **唯一的概率型输出:** 提供逐分子均值 ± 标准差, 可支撑不确定性筛选, 这是其余 8 个模型不具备的能力。 - 预调优跳过 Optuna, 训练约 16 秒, 成本极低、复现快。 - MAE (0.2964) 居中游偏优, 残差分布尚可; SHAP 归因与其余模型一致, 物理可解释。

不足: - Test $R^2 = 0.5786$, 排名第 5, 低于第一梯队 (HistGB/CIF, $R^2 \approx 0.64$) 约 0.06。 - 日志未输出特征重要度 (形状不匹配跳过), 可解释性依赖 KernelExplainer, 计算开销大。 - 预调优参数来自历史 target 的结论, 未针对 Area_min 重新搜索, 精度天花板可能未充分挖掘。

横向定位 (9 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
3	LightGBM	0.5157	0.5919
4	RF	0.5179	0.5884
5	NGBoost	0.5240	0.5786
6	CatBoost	0.5315	0.5664
7	XGBoost	0.5495	0.5366

NGBoost 位于第二梯队中部，与 CatBoost 相差 0.007。若**精度是唯一目标**，选 HistGB/CIF 更优；若需要**不确定性估计**（用于筛选低置信度分子、支撑界面性质的可靠性分析），NGBoost 是 Area_min 上的独特选择。