

Area_min RandomForest 模型报告

RandomForest 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_rf_20260807_100009
调参日志	同上运行目录 train.log (Optuna 50 轮)
运行时间	10:00 ~ 10:03 (约 2 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RandomForest (随机森林) 通过 **bagging + 随机特征子集** 构建大量并行决策树并对预测取平均: 每棵树在 bootstrap 样本上以 `max_features` 随机选取的特征子集分裂, 天然抗过拟合、无需学习率/早停等额外调节, 是最经典的强健基线。

在 Area_min 任务中, RF 的 Test R² = 0.5884、Test RMSE = 0.5179, **在 9 个模型中排名第 4**, 与 LightGBM (0.5919) 几乎持平, 处于第二梯队。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²), 与 Gamma_max 负相关 ($r = -0.62$)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条; 调参阶段采用 5 折交叉验证。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间 `n_estimators[200,2000]` 、 `max_depth[3,30]` 等。

最优试验 (Trial 48, CV RMSE = 0.4576) :

参数	值
n_estimators	1827
max_depth	21
min_samples_split	7
min_samples_leaf	1
max_features	log2
bootstrap	False
Best CV RMSE	0.4576

调优过程观察: - 最优解偏好**大森林 (1827 棵树) + 中等深度 (21)** , `max_features='log2'` 且 `bootstrap=False` ——每分裂仅考察约 9 个特征, 随机化程度高、树间相关性低。 - 有趣的是, RF 与 CIF 的搜索空间与最终最优参数**完全相同** (Trial 48、1827 棵树、`max_depth=21`、`log2`、`bootstrap=False`) , 说明该配置在 522 维特征上是“树集成类”模型的共同好解。 - 早期试验 (Trial 0/1) CV 0.71/0.64, 随 `min_samples_split` 降至 2、`min_samples_leaf` 降至 1, CV 收敛至 0.48 (Trial 12) 并逐步改善到 0.4576 (Trial 48) ; 50 轮中 12 轮被剪枝, 单轮 5 折 CV 仅 2~5 秒。


训练过程

调参完成后直接以最优参数在 531 条训练集上训练最终模型 (Training Final Model with Best Hyperparameters) , 无早停需求。整段训练含调参约 2 分钟, 与 CIF 同属最快档。

测试结果

指标	值
Test RMSE	0.5179
Test MAE	0.3115
Test R ²	0.5884
Best CV RMSE	0.4576

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.5179) 较 Best CV (0.4576) 回退约 0.06, 为所有模型中回退偏大者之一 (RF 在 70 条小测试集上单次评估的方差较大) 。Test MSE = 0.2682 与 LightGBM (0.2659) 几乎一致, 印证两者精度水平相当。


特征重要性 (说明)

当前日志输出的 Top-20 特征重要度数值全部为 0.0, 但排序仍指示 **atom_mean_48 (Gasteiger 电荷分箱聚合)**、**atom_std_26**、**atom_mean_38 (显式价态 one-hot)**、**maccs_101**、**maccs_105** 等原子电子结构特征与 MACCS 子结构位靠前, 且 NumRings、MolWt、LogP、tail_ratio/head_ratio 位列中后段——与其余树模型结论**大体一致** (电子结构 +


子结构 + 尺寸/头尾结构共同驱动)。数值归零的原因是 RF 模型的对象未暴露 sklearn 标准 `feature_importances_` 口径，属于日志展示缺陷；精确归因须依赖 `shap_rf.py` 的 SHAP 分析 (TreeExplainer)。下方 SHAP 图为实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、maccs_105、maccs_101、NumRings、NAtoms 居前。



Top-1 特征依赖图: MolWt 越大 SHAP 贡献越正, 即分子量增大 $\rightarrow$ 预测的每分子最小面积增大, 与 LightGBM 的 SHAP 结论一致。

SHAP 归因将 **MolWt 置于首位**, 随后是 MACCS 子结构位与环数/原子数——说明 Area_min 由“分子整体尺寸”与“具体子结构身份”协同决定, 这与 HistGB 子结构主导、LightGBM 尺寸/疏水性主导的结论互相补充。

结论与评价

优点: - **9 个模型中排名第 4** ($R^2 = 0.5884$), 与 LightGBM 几乎并列, 属稳健的第二梯队。 - bagging 天然抗过拟合, 无需学习率、早停等调节, 训练约 2 分钟成本极低。 - 最优超参与 CIF 完全一致, 配置经验可跨模型复用。

不足: - 与第一梯队 (HistGB/CIF, $R^2 \approx 0.64$) 存在约 0.05 的 R^2 差距。 - Test 较 CV 回退约 0.06, 单次测试评估方差偏大 (70 条小样本下不稳定)。 - 日志未输出有效特征重要度 (全 0), 可解释性依赖 SHAP 补充。

横向定位 (9 个模型中按 Test RMSE 排序):

排名	模型	Test RMSE	Test R²
2	CIF (ExtraTrees)	0.4859	0.6377
3	LightGBM	0.5157	0.5919
4	RF	0.5179	0.5884
5	NGBoost	0.5240	0.5786
6	CatBoost	0.5315	0.5664

RF 与 LightGBM 并列 (RMSE 差 0.002) , 处于第二梯队中部; 相对 CIF 同类 (ExtraTrees) 落后 0.03, 差异主要来自随机森林 vs 极端随机树的特征采样策略。作为无需调参强度、天然稳健的基线, RF 适合作为 Area_min 的**对照模型**; 追求精度上限仍以 HistGB/CIF 为优。