

Area_min RNN-LSTM 模型报告

RNN 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_rnn_20260807_100527
调参日志	同上运行目录 train.log (固定架构, 无 Optuna)
运行时间	10:05:27 ~ 10:07:03 (约 2 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RNN (LSTM) 将 522 维特征向量**重塑为序列** (batch, 522, 1) ——把每个特征维度当作一个时间步, 用 3 层 LSTM 逐维读取并聚合信息, 最后以末隐状态映射到单值输出。这一“把特征当序列”的设计是深度模型路线的另一种尝试, 但特征维度间本无时间先后语义, 序列化仅是工程上的权宜。

在 Area_min 任务中, RNN 的 Test $R^2 = 0.2037$ 、Test RMSE = 0.7203, **在 9 个模型中排名第 9 (垫底)**, 是全模型唯一 R^2 低于 0.3 的模型。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²), 与 Gamma_max 负相关 ($r = -0.62$)。RNN 的失败与其余深度模型 (MLP 0.53) 形成对比, 说明序列式建模在该 target 上不适用。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征，从缓存加载（`[Cache HIT]`），与其余模型一致。
- **数据规模**: 训练池 607 条（531 训练 + 76 验证），测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)`，固定随机种子。
- **序列化**: 522 维输入重塑为 `(batch, 522, 1)`，每维作为一个时间步。

超参数与调优

RNN 使用**固定架构，无 Optuna 调参**（区别于 MLP）：

参数	值
层数	3 层 LSTM
hidden	64
learning_rate	1e-3
weight_decay	1e-5
batch_size	32

该配置为本项目既定模板（3 层 LSTM、64 隐单元），未针对 Area_min 重新搜索。从结果看，64 隐单元对 522 维“序列”的信息容量偏小，且无任何正则调节手段。

训练过程

最终模型在 531 条数据上训练，**早停在 epoch 415 触发**（验证最优 RMSE = 0.6212 出现在 epoch 200）。训练曲线显示验证 RMSE 波动剧烈（epoch 50 的 0.79 → epoch 200 的 0.62 → epoch 250 回升至 0.75），自 epoch 200 后验证误差不再改善，训练进入无效震荡；早停机制在 415 轮止损，最终以 epoch 200 的验证最优权重交付。

说明：本次 RNN 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（深度模型训练脚本不输出绘图文件）。如需可视化，可复用 `train_rnn_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

测试结果

指标	值
Test RMSE	0.7203
Test MAE	0.4872
Test R ²	0.2037
Best val RMSE	0.6212

Test RMSE (0.7203) 较 Best val (0.6212) 进一步恶化约 0.10, 且 **MAE (0.4872) 为 9 个模型中最高**、R² (0.2037) 为全模型唯一低于 0.3 者。Test MSE = 0.5189 与之印证。该模型仅能解释测试方差的两成, 基本不具备 Area_min 的预测能力。

特征重要性

RNN 为黑盒序列模型, 日志未输出特征重要性。其将 522 维特征逐维按序列读取, LSTM 的隐状态在时间步间压缩信息, 缺乏明确的归因结构; 若需解释, 只能借助逐特征扰动或 SHAP 的近似 KernelExplainer 事后估计 (本次未生成)。基于其余 7 个树模型的共识结论, 可推断 Area_min 主要由 MolWt、MACCS 子结构位、头尾结构等特征驱动——但 RNN 的精度已不足以支撑对该结论的进一步佐证。

结论与评价

优点: - 训练速度快 (约 2 分钟), 早停机制在验证震荡中正确止损, 未无限消耗算力。 - 作为深度模型基线, 验证了“序列式建模 + 522 维手工特征”路线在该 target 上的不适用性, 为后续方法选择提供了反面证据。

不足: - **9 个模型中垫底 (R² = 0.2037)**, MAE 全模型最高 (0.4872), 预测基本失效。 - 固定架构无调参、64 隐单元容量不足; “把特征当序列”的假设缺乏物理依据, 特征维度间并无时间语义。 - 训练震荡剧烈 (val RMSE 0.62~0.79 大幅波动), 收敛不稳定, 复现性差。

横向定位 (9 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
7	XGBoost	0.5495	0.5366
8	MLP	0.5547	0.5278
9	RNN	0.7203	0.2037

RNN 与 MLP 的对比极具说明性：同为深度模型，**前馈 MLP (0.53) 远超序列式 RNN (0.20)** ——522 维特征更适合整体非线性组合（MLP）而非时序压缩（RNN）。在 Area_min 这一小样本（531）+ 高维（522）任务上，深度模型整体弱于树模型，RNN 尤其不建议选用；交付应优先 HistGB/CIF。