

Area_min XGBoost 模型报告

XGBoost 模型报告 — Area_min 预测

报告信息

项目	内容
目标变量	Area_min (每分子最小面积, nm ²)
运行目录	runs\Area_min\Area_min_xgboost_20260807_101507
调参日志	同上运行目录 train.log (Optuna 200 轮)
运行时间	10:15 ~ 10:36 (约 21 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

XGBoost 是陈天奇提出的梯度提升框架，以其**二阶泰勒展开**、稀疏感知与列块并行的实现著称。本项目为 XGBoost 配置了**最复杂的调参管线**：200 轮 Optuna × 5 折 CV (CV 样本 546)，配合 **Top-5 holdout 泛化性筛选** (独立 holdout 61 样本，从 CV 最优的 5 组参数中选出在 holdout 上最泛化者)，并引入训练-验证差距惩罚防过拟合。

在 Area_min 任务中，XGBoost 的 Test R² = 0.5366、Test RMSE = 0.5495，在 **9 个模型中排名第 7**，处于中游偏后。Area_min 描述表面活性剂分子在气-液界面单分子膜中的最小截面积 (nm²)，与 Gamma_max 负相关 (r = -0.62)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。构成: 原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12。
- **数据规模**: 训练池 607 条 (531 训练 + 76 验证) , 测试集 70 条; 调参阶段进一步划分 **CV 546 / Holdout 61**。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 200 轮 × 5 折交叉验证** (多变量 TPE + Top-K holdout 筛选 + gap 惩罚) 。

Best Trial (CV RMSE = 0.4820) :

参数	值
n_estimators	2973
max_depth	4
learning_rate	0.0117
subsample	0.920
colsample_bytree / bylevel / bynode	0.671 / 0.681 / 0.776
min_child_weight	4.54
gamma	0.0102
reg_alpha / reg_lambda	1.1e-4 / 0.114
max_delta_step	4.43
booster	dart

Optuna 参数重要度:

参数	重要度
gamma	0.9472
min_child_weight	0.0152
learning_rate	0.0100
其余 (colsample_bytree 等)	< 0.008

Top-5 Holdout 泛化筛选 (选择在独立 holdout 上最泛化的参数, 而非仅 CV 最优) :

Rank	CV RMSE	Holdout RMSE	Holdout R ²
1	0.4820	0.5032	0.7110
2	0.4856	0.4695	0.7483
3	0.4861	0.4921	0.7235
4	0.4866	0.4757	0.7417
5	0.4872	0.4585	0.7601

最终选中的参数为 **Holdout RMSE 最低的第 5 组** (n_estimators=2902、max_depth=4、learning_rate=0.0127、subsample=0.761、colsample 三档 0.776/0.477/0.494、gamma=0.046、booster=dart) , Holdout R² = 0.7601。这一“弃 CV 最优、取 holdout 最优”的流程与 pCMC 任务一致, 体现了对过拟合的一贯警惕。


训练过程

- **调参阶段**: 200 轮 Optuna 从 Trial 0 的 0.58 收敛至 CV RMSE = 0.4820 (Best Trial) , 随后进入 Top-5 holdout 筛选, 最终选定 holdout RMSE = 0.4585 的参数组合。
- **最终训练**: 在 **546 条 CV 样本** (非全量 531) 上以选定参数训练 (Training Final Model with Best Hyperparameters (X_cv: 546 samples)) , 随后在 70 条测试集上评估。约 21 分钟内完成全部调参与训练。

测试结果

指标	值
Test RMSE	0.5495
Test MAE	0.3010
Test R ²	0.5366
Best CV RMSE	0.4820
Holdout RMSE	0.4585


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.5495) 较 CV (0.4820) 与 holdout (0.4585) 均回退约 0.07~0.09, 且 **Holdout R² = 0.76 远高于 Test R² = 0.54**——即使经过 holdout 泛化筛选, 独立测试集上仍明显下滑。这提示 Area_min 的 70 条测试样本与训练分布存在差异, 或样本量小导致评估波动大。Test MSE = 0.3020 与之印证。

特征重要性 (说明)


当前日志输出的 Top-20 特征重要度数值全部为 0.0 (dart booster + 重要性口径的展示问题, 与 pCMC 任务相同), 但排序仍指示 **atom_max_46 (Gasteiger 电荷最大值聚合)**、**atom_max_16**、**AroRings (芳香环数)**、**atom_max_20**、**maccs_105** 等原子极值/电子结构特征与 MACCS 子结构位靠前, 且 NumRings、brics_10 位列中段——与其余树模型的结论**大体一致** (电子结构与子结构共同驱动)。精确归因须依赖 `shap_xgboost.py` 的 SHAP 分析 (TreeExplainer)。下方 SHAP 图为实测结果:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、maccs_105、maccs_101、maccs_126、head_ratio 居前, 与其余树模型结论一致。



Top-1 特征依赖图: MolWt 与 SHAP 贡献正相关, 分子量增大 → 预测的每分子最小面积增大, 与 LightGBM/RF/NGBoost 的 SHAP 结论一致。

SHAP 归因将 **MolWt 置于首位**, 随后是 MACCS 子结构位与 head_ratio——“分子尺寸 + 子结构身份 + 头尾结构” 共同决定 Area_min, 与其余模型高度一致。

结论与评价

优点: - 调参管线最严谨 (200 轮 + Top-5 holdout 泛化筛选 + gap 惩罚), 参数选择有据可依、过拟合风险被主动压制。 - **Holdout $R^2 = 0.7601$** 为全模型在验证侧的最高水平之一, 说明其在验证分布上的拟合能力优秀。 - 参数重要度 ($\gamma=0.95$) 给出明确洞察: 532 维特征上的分裂极易过拟合, 需依赖 γ 强制信息增益。

不足: - **Test $R^2 = 0.5366$ 仅排第 7**, CV/holdout 与 Test 落差明显 (holdout 0.76 → test 0.54), 泛化到独立测试集的能力偏弱。 - 200 轮调参成本 (约 21 分钟) 高于多数模型, 且最终精度低于成本更低的 HistGB/CIF。 - dart booster 的特征重要性输出异常, 可解释性依赖 SHAP 补充。

横向定位 (9 个模型中按 Test RMSE 排序):

排名	模型	Test RMSE	Test R ²
5	NGBoost	0.5240	0.5786
6	CatBoost	0.5315	0.5664
7	XGBoost	0.5495	0.5366
8	MLP	0.5547	0.5278
9	RNN	0.7203	0.2037

XGBoost 与 CatBoost 同属“验证侧强、测试侧弱”的梯队，测试精度排名靠后。作为调参最充分的模型，其 holdout 高精度说明**验证选型流程本身合理**，但 Area_min 测试集上仍未兑现；若追求交付精度，应优先 HistGB/CIF，XGBoost 适合作为过拟合控制与泛化性分析的参照。