

AW_ST_CMC CIF (ExtraTrees) 模型报告

CIF 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_cif_20260804_214844
运行时间	21:48 开始 ~ 21:50 结束 (约 2 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CIF (Conditional Inference Forest, 条件推理森林) 以**基于统计显著性检验的无偏递归划分**为特色 (Hothorn et al., 2006) : 每次分裂通过排列检验选择变量与切分点, 避免树模型对数值型特征的**分裂变量选择偏差**。本项目在 Python 中采用 `ExtraTreesRegressor` 作为其近似实现——ExtraTrees 的**随机阈值分裂**同样降低了选择偏差, 且在保持与 RandomForest 相近精度的同时进一步抑制过拟合, 在高维特征上更具优势。

在 AW_ST_CMC 任务中, CIF 的 $\text{Test } R^2 = 0.5700$ 、 $\text{Test RMSE} = 4.6913$, 在 10 个模型中排名第 7, 处于中下游 (与 RF 同属第三梯队, 落后于梯度提升类模型)。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载（[Cache HIT]），与其余模型一致。
- **数据规模**：训练集 843 条（737 训练 + 106 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner），搜索空间与 RF 相同：`n_estimators[200,2000]`、`max_depth[3,30]`、`min_samples_split`、`min_samples_leaf`、`max_features[sqrt, log2, None]`、`bootstrap`、`max_samples`。

最优试验（Trial 27, CV RMSE = 4.1738）：

参数	值
<code>n_estimators</code>	451
<code>max_depth</code>	23
<code>min_samples_split</code>	2
<code>min_samples_leaf</code>	1
<code>max_features</code>	log2
<code>bootstrap</code>	True
<code>max_samples</code>	0.9074
Best CV RMSE	4.1738

调优过程观察： - 最优解采用 **bootstrap=True + max_samples=0.9074（有放回抽样 90.7%） + max_features= 'log2'** ——即保留行采样、仅用 log2 个特征的随机子集，比 RF 最优解的 sqrt 更激进的列随机化，进一步压低树间相关性。 - `min_samples_leaf=1`、`min_samples_split=2` 使树近乎完全生长（配合 `max_depth=23` 的深树），容量偏大但被 ExtraTrees 的双重随机化（随机阈值 + 列子集）天然对冲。 - 50 轮中 22 轮完成、**28 轮被剪枝**（剪枝率 56%），最优值在 Trial 27 达到 **CV RMSE = 4.1738**，后续 22 轮未再突破；单轮 5 折 CV 平均耗时约 1 秒，总耗时约 2 分钟，效率极高。


训练过程

- **调参阶段**：50 轮 Optuna 中 22 轮完成、28 轮被剪枝，最优值从 Trial 0 的 6.1389 快速改善，Trial 11/12 进入 4.22~4.29 区间后，**Trial 27 以 4.1738 锁定最优**并保持到结束，收敛充分。
- **最终训练**：以最优参数在 737 条训练集上训练（无早停，直接训练完整森林），输出测试评估。

测试结果

指标	值
Test RMSE	4.6913
Test MAE	3.4126
Test R ²	0.5700
Best CV RMSE	4.1738

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (4.6913) 明显高于调参 CV (4.1738) ， Test MSE = 22.0079， Test-CV 差距约 0.52， 与 RF 一样存在明显的**独立测试集泛化落差**。值得注意的是， CV 表现 (4.1738) 本可进入第一梯队（接近 CatBoost 的 3.83）， 但测试集上跌至第三梯队，说明该配置的 CV 虚高或对数据划分敏感。R² = 0.5700 与 RF 几乎持平。

特征重要性 (Top 20)


CIF 输出原生 Top-20 特征重要度，数值显示为 0.0（口径展示问题，保留排序），排序前 5 名为：

1. **atom_mean_3** — 原子特征均值
2. **atom_std_16** — 原子特征标准差
3. **atom_std_22** — 原子特征标准差
4. **atom_mean_46** — 原子特征均值
5. **atom_mean_47** — 原子特征均值

其下依次为 atom_mean_38、atom_std_17、LogP、atom_mean_23、atom_mean_17 等，整体以**原子级聚合统计为主，辅以 LogP 与 head_ratio/tail_ratio**。数值归零属默认重要度口径的展示缺陷，**精确归因需以 SHAP 为准**：SHAP 依赖图前 5 名（atom_max_33、maccs_65、surf_cationic、maccs_125、maccs_117）中，**surf_cationic 与两个 MACCS 药效团特征（maccs_65/125/117）同时上榜**，印证了“阳离子头基类型 + 药效团子结构”对 CMC 时表面张力的主导作用——与 HistGB 的 surf_cationic 第 2、CatBoost 的 maccs 特征靠前结论相互印证。



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_max_33*、*maccs_65*、*surf_cationic* 位居前列。

结论与评价

优点： - 训练效率极高（50 轮约 2 分钟），ExtraTrees 双重随机化天然抗过拟合，开箱即用。 - CV 表现（4.1738）接近第一梯队，说明模型结构具备较强的拟合能力。 - SHAP 归因揭示 *surf_cationic* + MACCS 药效团的联合主导作用，物理解释清晰。

不足： - 精度第 7 ($R^2 = 0.5700$)，Test 明显差于 CV (4.69 vs 4.17)，泛化落差在树模型中最大之一。 - 非自适应集成上限低于梯度提升（第一梯队 ≈ 0.68 ）。 - 重要度数值全 0 的展示缺陷，依赖 SHAP 补充文档化。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
5	HistGB	4.4287	0.6168
6	LightGBM	4.5686	0.5922
7	CIF (ExtraTrees)	4.6913	0.5700
8	RandomForest	4.7340	0.5621
9	Transformer	7.2719	-0.0332

CIF 与 RF 构成第三梯队 ($R^2 \in [0.56, 0.57]$)，在 AW_ST_CMC 上明显落后于梯度提升类模型。其**高效、抗过拟合、归因清晰**的特性使其适合作为特征工程反馈或集成成员的候选；但追求该 target 精度时应优先 NGBoost/XGBoost/CatBoost，CIF 不宜作为主推模型。