

AW_ST_CMC HistGB 模型报告

HistGB 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_histgb_20260804_215135
运行时间	21:51 开始 ~ 22:31 结束 (约 40 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

HistGB (scikit-learn `HistGradientBoostingRegressor`) 是基于 **Histogram-based 分箱** 的梯度提升实现, 与 LightGBM 同属直方图加速路线, 但采用 **Level-wise (按层) 生长策略**。其默认 `early_stopping` 机制 (内部分出验证子集) 与 `l2_regularization`、`min_samples_leaf` 等正则项共同控制过拟合, 是本项目 10 个模型中**开箱即用程度最高的树模型**。

在 AW_ST_CMC 任务中, HistGB 的 Test $R^2 = 0.6168$ 、Test RMSE = 4.4287, 在 10 个模型中排名第 5, 处于第二梯队之首 (第一梯队 NGBost/XGBoost/CatBoost 之后)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 `learning_rate`、`max_iter`、`max_depth`、`max_leaf_nodes`、`min_samples_leaf`、`l2_regularization`、`max_bins`。

最优试验 (Trial 17, CV RMSE = 4.2171) :

参数	值
<code>learning_rate</code>	0.1061
<code>max_iter</code>	2538
<code>max_depth</code>	15
<code>max_leaf_nodes</code>	16
<code>min_samples_leaf</code>	11
<code>l2_regularization</code>	0.0226
<code>max_bins</code>	174
Best CV RMSE	4.2171

调优过程观察: - 最优解的关键特征是 **max_leaf_nodes=16**——在 `max_depth=15` 的允许深度下仅生成 16 个叶子, 即通过 `max_leaf_nodes` 强制“浅且窄”的树, 与第一梯队模型 (`depth 8~10`) 的复杂度约束思路一致。 - 前 12 轮中 Trial 4 短暂领先 (4.2671) , Trial 17 以 4.2171 突破后保持到 50 轮结束, 后续 30 余轮未再刷新, 收敛充分。 - 50 轮中 **31 轮被 MedianPruner 剪枝**、19 轮完成, 剪枝率 (62%) 在树模型中最高的之一, 说明该搜索空间下大量采样集中在低质量区域, TPE 采样器早熟收敛。


训练过程

- **调参阶段**：50 轮 Optuna 中 19 轮完成、31 轮被剪枝，最优值在 Trial 17 达到 **CV RMSE = 4.2171** 并保持到结束。
- **最终训练**：以最优参数在 737 条训练集上训练（HistGB 内置 early_stopping，日志未单独打印迭代截断），输出测试评估。

测试结果

指标	值
Test RMSE	4.4287
Test MAE	3.4174
Test R ²	0.6168
Best CV RMSE	4.2171

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (4.4287) 略高于调参 CV (4.2171)，差距 (约 0.21) 介于 CatBoost (Test≈CV) 与 LightGBM (Test-CV≈0.38) 之间。Test MSE = 19.6131。R² = 0.6168 处于第二梯队 (0.59~0.62)，明显落后于第一梯队 (≈0.68)，但仍显著优于深度模型 RNN/Transformer 的负 R²。

特征重要性 (Top 20)


HistGB 输出 **permutation-based (置换) 特征重要度**，对采样波动不敏感、可信度较高，前 5 名为：

1. **atom_mean_44** (1.1938 ± 0.2117) — 原子特征均值
2. **surf_cationic** (0.5420 ± 0.1065) — 阳离子表面活性剂类型
3. **atom_std_44** (0.5013 ± 0.0965) — 原子特征标准差
4. **atom_mean_38** (0.4213 ± 0.0966) — 原子特征均值
5. **bond_mean_0** (0.3008 ± 0.0717) — 键特征均值


其下依次为 atom_mean_20、atom_mean_52、brics_30、atom_mean_48、atom_mean_47 等。**atom_mean_44 以 1.19 的置换重要度断崖式领先**（约为第 2 名 surf_cationic 的 2.2 倍），而 surf_cationic 稳居第 2——**阳离子头基类型对 AW_ST_CMC 的影响被 HistGB 独立确认**，与其余树模型的 SHAP 结论一致；原子级 44 号特征（对应原子聚合统计）在各模型反复位居前列，指向“原子局部环境”是表面张力的核心决定因子。SHAP 依赖图前 5 名（atom_mean_44、surf_cationic、atom_mean_38、atom_std_44、atom_mean_54）与置换重要度高度吻合。



SHAP 蜜蜂图: 每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: atom_mean_44、surf_cationic、atom_std_44 位列前三, 与置换重要度一致。



SHAP 交互热力图：展示 Top 特征两两交互对预测的平均影响。

结论与评价

优点： - permutation 重要度与 SHAP 双重归因高度一致，atom_mean_44、surf_cationic 的结论**可信度高**。 - 开箱即用程度高（内置早停 + 分箱加速），默认正则项覆盖全面。 - 剪枝率达 62% 仍保持稳健 CV，调参收敛良好，过拟合风险被主动压制。

不足： - 精度第 5 ($R^2 = 0.6168$)，与第一梯队 (≈ 0.68) 差距约 0.06，未进入第一梯队。 - Test RMSE 高于 CV (4.43 vs 4.22)，独立测试集上泛化弱于 CatBoost。 - 最优解 max_leaf_nodes=16 的窄树对复杂界面的表达能力受限，限制了上限。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
3	CatBoost	4.0407	0.6810
4	MLP	4.3235	0.6348
5	HistGB	4.4287	0.6168
6	LightGBM	4.5686	0.5922
7	CIF (ExtraTrees)	4.6913	0.5700

HistGB 与 MLP、LightGBM 共同构成第二梯队 ($R^2 \in [0.59, 0.64]$)，优于随机森林类模型 (CIF/RF) 但明显落后于第一梯队。其**归因可信度高、实现简洁**，适合作为特征工程质量检验的参考模型；若追求极致精度，应优先

NGBoost/XGBoost/CatBoost.