

AW_ST_CMC LightGBM 模型报告

LightGBM 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC（表面活性剂在 CMC 时的表面张力，单位 mN/m）
运行目录	runs\AW_ST_CMC\AW_ST_CMC_lightgbm_20260805_055441
运行时间	05:54 开始 ~ 05:59 结束（约 5 分钟）
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

LightGBM 是微软提出的梯度提升框架，以 **Histogram-based 分箱加速**、**Leaf-wise 生长策略**（逐叶生长、精确最佳分裂）与原生类别特征支持著称。相比 Level-wise 的 XGBoost/CatBoost，其 Leaf-wise 生长在小样本高维数据上更易过拟合，因此本任务中 `num_leaves` 与正则项的组合至关重要。

在 AW_ST_CMC 任务中，LightGBM 的 Test $R^2 = 0.5922$ 、Test RMSE = 4.5686，在 10 个模型中排名第 6，处于中游（第一梯队 NGBost/XGBoost/CatBoost 之后）。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 `boosting_type[gbdt, dart]`、`max_depth[3,15]`、`num_leaves[15,255]` , 并附加 `learning_rate` / `n_estimators` / `subsample` / `colsample_bytree` / `reg_alpha` / `reg_lambda` / `min_child_samples` / `min_split_gain` 等次要参数。

最优试验 (Trial 31, CV RMSE = 4.1933) :

参数	值
<code>boosting_type</code>	gbdt
<code>max_depth</code>	13
<code>num_leaves</code>	207
<code>learning_rate</code>	0.0797
<code>n_estimators</code>	2528
<code>subsample</code> / <code>subsample_freq</code>	0.7687 / 7
<code>colsample_bytree</code>	0.8086
<code>reg_alpha</code> / <code>reg_lambda</code>	≈ 0 / ≈ 0
<code>min_child_samples</code>	5
<code>min_split_gain</code>	0.3367
Best CV RMSE	4.1933

调优过程观察: - 早期试验 (Trial 0/1) CV 误差高达 22.2 / 9.3, 源于 `dart` 模式参数组合不佳; 搜索随后收敛到 `gbdt` + 大 `num_leaves` (207) 的配置。 - 最优解偏好 **gbdt (而非 dart) + 深树 (max_depth=13) + 大叶子数 (207)** , 但 `reg_alpha`/`reg_lambda` 均为 0、`min_child_samples`=5, **几乎未使用 L1/L2 正**

则——说明在该搜索空间内模型倾向靠“大容量 + 早停”而非正则来平衡误差。
- 50 轮中 18 轮被剪枝，其余均正常收敛；单轮 5 折 CV 平均耗时约 5 秒，**调参总耗时仅约 5 分钟**，是 10 个模型中效率最高之一。


训练过程

- **调参阶段**：50 轮 Optuna 中 32 轮完成、18 轮被剪枝，最优值在 Trial 31 达到 **CV RMSE = 4.1933**，后续 18 轮未再突破，搜索收敛。
- **最终训练**：以最优参数在 737 条训练集上训练，内置早停于 **iteration 77** 触发 (valid_0 RMSE = 4.3832)，即实际仅使用了 2528 棵候选树中的前 77 棵，**远早于 n_estimators 上限**——说明该配置在 30~50 轮内迅速过拟合，早停对控制最终误差起了决定性作用。

测试结果

指标	值
Test RMSE	4.5686
Test MAE	3.4103
Test R ²	0.5922
Best CV RMSE	4.1933

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.5686) 明显高于调参 CV (4.1933)，Test MSE = 20.8717，说明最终模型**在独立测试集上泛化弱于 CV 表现**。这一“Test > CV”的差距 (约 0.38) 在 10 个模型中偏大，指向早停迭代数偏少 (77 轮) 导致欠拟合，或该超


参组合对数据划分敏感。 $R^2 = 0.5922$ 仍为正，但已落在第一梯队 (≈ 0.68) 之后约 0.09。

特征重要性 (Top 20)


LightGBM 输出原生 Top-20 特征重要度，前 5 名为：

1. **tail_ratio** (236.0) — 尾链碳占比 (头尾比)
2. **LogP** (215.0) — 油水分配系数
3. **atom_mean_35** (192.0) — 原子特征均值
4. **MolWt** (166.0) — 分子量
5. **atom_mean_47** (125.0) — 原子特征均值

其下依次为 atom_mean_17、atom_std_25、atom_std_35、atom_mean_23、atom_mean_3 等。**tail_ratio 与 LogP 分列前两位**，是 LightGBM 视角下对 AW_ST_CMC 最重要的两个特征——尾链越长、疏水性越强，表面活性剂在界面的分子排布越紧凑，直接影响 CMC 时的表面张力；这与第一梯队模型的 SHAP 结论（阳离子类型、分子量、疏水描述符主导）在**疏水维度上高度一致**。SHAP 依赖图前 5 名 (atom_mean_44、surf_cationic、atom_std_52、atom_std_17、MolWt) 与日志重要度排序略有出入，属 LightGBM 重要度口径与 SHAP 归因的正常差异。



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: atom_mean_44、surf_cationic、atom_std_52 位居前列, 疏水/电荷维度突出。

结论与评价

优点: - 调参效率全模型最高 (50 轮约 5 分钟), 适合快速迭代实验。 - 内置早停自动确定最优迭代数, 超参可复现、配置简洁。 - tail_ratio + LogP 的重要度排序清晰指向疏水尾链的物理作用, 可解释性良好。

不足: - 精度第 6 ($R^2 = 0.5922$), 与第一梯队 (≈ 0.68) 差距约 0.09, 未进入第一梯队。 - **Test RMSE 显著高于 CV (4.57 vs 4.19)**, 泛化稳定性弱于同族模型 (CatBoost 的 Test $\approx$ CV)。 - 最优解未用任何 L1/L2 正则, 对数据划分的敏感性较高。

横向定位 (10 个模型中按 Test RMSE 排序):

排名	模型	Test RMSE	Test R ²
4	MLP	4.3235	0.6348
5	HistGB	4.4287	0.6168
6	LightGBM	4.5686	0.5922
7	CIF (ExtraTrees)	4.6913	0.5700
8	RF	4.7340	0.5621

LightGBM 与 HistGB 共同构成第二梯队 ($R^2 \in [0.59, 0.62]$)，明显落后于第一梯队。尽管其**训练速度快、适合快速验证**，但在 AW_ST_CMC 这一小样本 (737) 任务上，其 Test-CV 差距偏大、精度受限，**优先性不及 CatBoost/XGBoost/NGBoost**；作为高效基线或特征工程的快速反馈工具价值更高。