

AW_ST_CMC MLP 模型报告

MLP 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_mlp_20260805_100151
调参日志	runs\AW_ST_CMC\AW_ST_CMC_mlp_tuning_20260805_082026\train.log
运行时间	调参 08:20 ~ 10:01 (约 100 分钟), 最终训练 10:01 ~ 10:02
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

MLP (多层感知机) 是 10 个模型中唯一的**前馈全连接深度网络**

(RNN/Transformer 为序列式深度模型)。架构为 `Linear → BatchNorm → GELU → Dropout` 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 AW_ST_CMC 任务中，MLP 的 Test $R^2 = 0.6348$ 、Test RMSE = 4.3235，排名第 4，是**深度模型中的最优者**（显著优于 RNN/Transformer 的负 R^2 ），并超越了 HistGB、LightGBM 等部分树模型。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载，与其余模型一致。
- **数据规模**：训练集 843 条（737 训练 + 106 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner），搜索空间覆盖 `n_layers[2,6]`、`hidden_dim[128,1024]`、`dropout`、`activation`、`learning_rate`、`weight_decay`、`batch_size`。这是深度模型中唯一使用 Optuna 的（RNN/Transformer 用固定架构）。

最优试验（Trial 7，CV RMSE = 3.6940）：

参数	值
n_layers	3
hidden_dim	379
dropout	0.2713
activation	gelu
learning_rate	0.00913
weight_decay	7.26e-5
batch_size	38
Best CV RMSE	3.6940

调优过程观察： - 早期试验（Trial 0/1）表现极差（CV 22.1 / 34.3），原因是学习率过低（ $1.5e-5$ / $3.5e-5$ ）导致欠拟合；**Trial 2 起学习率进入 $[2e-4, 9e-3]$ 区间后迅速收敛到 3.7~3.9。** - **Trial 7 以 3.6940 锁定最优并保持到 50 轮结束，**后续 42 轮（含 Trial 25 的 3.6946、Trial 26 的 3.6945）均未突破，说明搜索已收敛、最优解稳定。 - 最优解偏好 **GELU 激活 + 3 层 + 中等隐藏层 (379)**；激

活函数从早期 relu/leaky_relu 逐渐被 gelu 取代, gelu 成为优势激活。 - 50 轮中 32 轮完成、18 轮被剪枝；单轮 5 折 CV 平均耗时约 3.5 分钟，深度网络调参成本（约 100 分钟）显著高于树模型（LightGBM 仅 5 分钟）。

训练过程

最终模型以最优参数在 737 条数据上训练，**早停在 epoch 205** 触发，验证集 RMSE 最优值 **3.5588**（比调参 CV 的 3.6940 更好）。训练 205 个 epoch 表明网络需要较多迭代才能收敛，但早停机制避免了过拟合蔓延；最终以验证最优权重交付。

说明：最终训练与调参在同一脚本中连续执行（调参日志末尾包含最终训练段）， `AW_ST_CMC_mlp_tuning` 目录即本次调参过程存档。

测试结果

指标	值
Test RMSE	4.3235
Test MAE	3.3005
Test R ²	0.6348
Best CV RMSE	3.6940
Best val RMSE	3.5588

说明：本次 MLP 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用 `train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (4.3235) 高于验证集最优 (3.5588)，Test MSE = 18.6930，说明在独立测试集（70 条）上误差有所回升。R² = 0.6348 排名第 4，虽逊于第一梯队（≈0.68），但**明显优于 RNN (-0.05) 与 Transformer (-0.03)**，验证了 MLP 作为深度模型中唯一有效者的地位。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因。基于其余模型的一致性结论，可推断其预测主要由原子聚合统计（atom_std_44 等）、阳离子类型 surf_cationic 与分子量/疏水描述符驱动——这些特征在 7 个树模型的 SHAP 与重要度排序中反复位居前列，是 AW_ST_CMC 的稳健归因。

结论与评价

优点： - **深度模型中的最优者：** $R^2 = 0.6348$ ，超越 HistGB/LightGBM 等部分树模型，证明神经网络能有效挖掘 522 维手工特征的非线性结构。 - 使用 Optuna 充分调参（vs 固定架构的 RNN/Transformer），超参选择有依据、结果可复现。 - 早停 + Dropout + weight_decay 三重正则，验证集 RMSE (3.5588) 优于 CV，泛化良好。

不足： - 调参成本高（约 100 分钟），为树模型的数十倍。 - 黑盒模型，可解释性差；Test-val 差距 (4.32 vs 3.56) 表明独立测试集上存在误差回升。 - 不提供不确定性估计（对比 NGBoost）。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
2	XGBoost	4.0139	0.6852
3	CatBoost	4.0407	0.6810
4	MLP	4.3235	0.6348
5	HistGB	4.4287	0.6168
6	LightGBM	4.5686	0.5922

MLP 以 0.28~0.31 的 RMSE 差距位列第一梯队之后、第二梯队之前。作为深度网络代表，其**扩展潜力**（更深的架构、特征自学习）优于树模型；在现有手工特征 + 小样本（737）配置下，精度逊于 NGBoost/XGBoost/CatBoost，但已是深度路线在该 target 上的最佳选择。