

AW_ST_CMC NGBoost 模型报告

NGBoost 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_ngboost_20260805_114314
运行时间	11:45 开始 ~ 13:55 结束 (约 130 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

NGBoost (Natural Gradient Boosting) 是斯坦福提出的**概率梯度提升**框架: 与传统回归输出单一标量不同, NGBoost 直接对目标分布的**自然梯度**做 boosting, 输出 `Normal(mean, std)` 完整概率分布, 从而同时给出点预测与不确定性。本项目 AW_ST_CMC 运行与 pCMC 的预调优方式不同, 采用 **Optuna 50 轮 × 5 折 CV 重新调参** (score_rule 在 LogScore/CRPScore 间搜索)。

在 AW_ST_CMC 任务中, NGBoost 的 Test $R^2 = 0.6924$ 、Test RMSE = 3.9679, **在 10 个模型中排名第 1**, 是第一梯队的领跑者 (XGBoost 4.0139、CatBoost 4.0407 紧随其后)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 `n_estimators`、`learning_rate`、`minibatch_frac`、`max_depth`、`min_samples_leaf`、`score_rule`[LogScore, CRPScore]。这是本项目 5 个新 target 中 **NGBoost 的调参形态** (pCMC 用预调优参数, 此处改为 Optuna) 。

最优试验 (Trial 36, CV RMSE = 4.1665) :

参数	值
<code>n_estimators</code>	1869
<code>learning_rate</code>	0.0236
<code>minibatch_frac</code>	0.7390
<code>max_depth</code>	6
<code>min_samples_leaf</code>	8
<code>score_rule</code>	LogScore
Best CV RMSE	4.1665

调优过程观察: - **score_rule 是决定性分歧点**: 早期试验 (Trial 2~7) 使用 CRPScore, CV 全部落在 5.1~5.8 的劣质区间; 自 **Trial 10 起全面转向 LogScore 后进入 4.2~4.3**, Trial 36 达到 4.1665。说明对本任务, 对数似然评分显著优于连续分级概率评分。 - 最优解偏好 **max_depth=6 的中等树 + minibatch_frac≈0.74 的批量随机梯度** + 低学习率 (0.0236) , `n_estimators` 高达 1869 棵, 靠“慢学习 + 大迭代”收敛。 - 50 轮中 35 轮完成、15 轮被剪枝; 单轮 5 折 CV 平均耗时约 2.4 分钟, **总耗时约 130 分钟**, 是树模型中调参最慢的 (概率双输出训练开销大) 。


训练过程

- **调参阶段**: 50 轮 Optuna 中 35 轮完成、15 轮被剪枝，最优值在 Trial 36 达到 **CV RMSE = 4.1665**，后续 13 轮未再突破，收敛稳定。
- **最终训练**: 以最优参数 (1869 棵) 在 737 条训练集上训练，日志显示训练损失从 [iter 0] 的 3.37 单调下降至 [iter 1800] 的 0.23，**无早停、完整跑满 `n_estimators`**；输出为 `Normal(mean, std)` 双参数分布，测试集平均预测标准差 **avg pred std = 0.4009** (即 NGBoost 自估的每分子预测不确定性)。

测试结果

指标	值
Test RMSE	3.9679
Test MAE	2.9515
Test R ²	0.6924
Best CV RMSE	4.1665

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (3.9679) **显著优于调参 CV (4.1665)**，Test MSE = 15.7446，是全模型最低。R² = 0.6924 为 10 个模型最高，且 MAE (2.9515) 仅次与 CatBoost (2.8057)。**Test 好于 CV 的现象**说明该概率模型在独立测试集上泛化稳健，没有过拟合迹象；avg pred std = 0.4009 的不确定性估计为每分子的预测置信度提供了量化参考。


特征重要性

NGBoost 的 `feature_importances_` 在本任务中返回**双输出 (mean+var) 形状 (2, 522)**，与单输出假设不符，日志以 `(unexpected shape (2, 522), skipping)` 跳过输出，故**无 Top-20 特征列表**。精确归因依赖 SHAP

(KernelExplainer, 对概率模型的均值输出做事后归因)。实测 SHAP 依赖图前 5 名 (atom_std_44、atom_mean_17、surf_cationic、atom_mean_35、brics_30) 与其余树模型结论一致——**atom_std_44 (原子环境标准差)**、**surf_cationic (阳离子类型)** 与 **brics_30 (BRICS 碎片)** 是 AW_ST_CMC 的主导因子，进一步巩固了“分子局部异质性 + 阳离子头基 + 骨架碎片”的归因画像。



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_std_44*、*atom_mean_17*、*surf_cationic* 位居前列，与其余树模型一致。

结论与评价

优点： - **精度第 1 ($R^2 = 0.6924$, $RMSE = 3.9679$)**，全模型最优，且 **Test 优于 CV**，泛化稳健。 - 概率输出 (mean $\pm$ std)：同时给出点预测与不确定性，avg pred std = 0.4009 支持带置信区间的决策。 - LogScore 与 CRPScore 的对比为评分规则选择提供了可复现的实证。

不足： - **调参成本最高** (50 轮约 130 分钟)，概率双输出训练开销大，性价比低于 CatBoost。 - 特征重要度因双输出形状无法直接输出，文档化依赖 SHAP 补充。 - 无内置早停，1869 棵完整训练，需自行控制迭代上限。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R ²
1	NGBoost	3.9679	0.6924
2	XGBoost	4.0139	0.6852
3	CatBoost	4.0407	0.6810

NGBoost 与 XGBoost、CatBoost 构成差距小于 0.08 RMSE 的**紧密第一梯队**，三者 R² 均在 0.68 上下。NGBoost 以**唯一概率模型的身份居首**，兼具精度与不确定性估计，是最适合生产决策的模型；若对计算成本敏感、仅需点预测，CatBoost（MAE 最优、调参快）与 XGBoost（泛化验证最严）是更轻量的替代。