

AW_ST_CMC RandomForest 模型报告

RandomForest 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_rf_20260805_143027
运行时间	14:30 开始 ~ 14:32 结束 (约 2 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RandomForest (随机森林) 是 Breiman 提出的**Bagging + 特征子集随机化**集成模型: 对每棵树使用 bootstrap 抽样, 并在每次分裂时从 `max_features` 个随机特征子集中选取最优分裂, 以树间的**低相关性**换取整体方差的显著下降。RF 是**非自适应 (不依赖残差迭代)**的集成方法, 与梯度提升

(CatBoost/XGBoost/LightGBM) 在建模哲学上根本不同——它对高维手工特征更稳健, 但上限通常低于梯度提升。

在 AW_ST_CMC 任务中, RF 的 Test R^2 = 0.5621、Test RMSE = 4.7340, 在 10 个模型中排名第 8, 处于中下游 (仅优于失效的深度模型 RNN/Transformer 与同源的 CIF 之外仍处末段)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索空间覆盖 `n_estimators[200,2000]`、`max_depth[3,30]`、`min_samples_split`、`min_samples_leaf`、`max_features[sqrt, log2, None]`、`bootstrap`、`max_samples`。

最优试验 (Trial 45, CV RMSE = 4.3051) :

参数	值
n_estimators	402
max_depth	21
min_samples_split	3
min_samples_leaf	1
max_features	sqrt
bootstrap	False
Best CV RMSE	4.3051

调优过程观察: - 最优解采用 **bootstrap=False (全量样本建树) + max_features= 'sqrt'** 的组合——即放弃行采样、仅靠特征子集随机化来去相关, 这在 737 条小样本下避免了 bootstrap 引入的样本浪费, 是 RF 在小数据上的常见最优形态。 - `min_samples_leaf=1`、`min_samples_split=3` 表明搜索趋于“叶子不限最小样本”的完全生长树, 配合 `max_depth=21` 的深树, 模型容量偏大; 由于 RF 的 bagging 特性, 这种高容量并未带来严重过拟合, 但精度上限受限于非自适应集成。 - 50 轮中 33 轮完成、17 轮被剪枝; 单轮 5 折 CV 平均耗时约 1.5 秒, **总耗时约 3 分钟**, 效率极高。


训练过程

- **调参阶段**：50 轮 Optuna 中 33 轮完成、17 轮被剪枝，最优值从 Trial 0 的 5.8652 逐步改善，**Trial 45 达到 CV RMSE = 4.3051**，末轮（Trial 49）仍在 4.3106 附近震荡，说明搜索在 4.30~4.32 区间已收敛。
- **最终训练**：以最优参数在 737 条训练集上训练（RF 无早停概念，直接训练完整森林），输出测试评估。

测试结果

指标	值
Test RMSE	4.7340
Test MAE	3.4557
Test R ²	0.5621
Best CV RMSE	4.3051

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (4.7340) 明显高于调参 CV (4.3051)，Test MSE = 22.4105，Test-CV 差距约 0.43，是树模型中泛化差距最大者之一。R² = 0.5621 仍为正，但对 AW_ST_CMC 的拟合质量已明显弱于梯度提升类模型（第一梯队 ≈ 0.68 ），仅显著优于负 R² 的深度模型。

特征重要性 (Top 20)


RF 输出原生 Top-20 特征重要度（默认 split 型），数值显示为 0.0（口径展示问题，保留排序），排序前 5 名为：

1. **atom_std_44** — 原子特征标准差
2. **atom_mean_17** — 原子特征均值
3. **atom_std_17** — 原子特征标准差
4. **atom_mean_44** — 原子特征均值
5. **atom_std_38** — 原子特征标准差

其下依次为 LogP、atom_mean_38、atom_mean_3、atom_std_54、atom_std_3 等，整体以**原子级聚合统计 (std/mean)** 为主，辅以 **LogP、HBD、MolWt 等显式描述符**。数值归零属 RF 默认重要度口径的展示缺陷，**精确归因需以 SHAP 为准**：SHAP 依赖图前 5 名 (atom_std_44、atom_max_35、atom_mean_17、atom_std_17、bond_std_12) 与日志排序基本吻合，且 **atom_std_44** 与 HistGB/CatBoost 的 SHAP 结论一致，指向“原子局部环境的标准差（即分子内化学环境的异质性）”对 CMC 时表面张力的决定性作用。



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图：atom_std_44、atom_max_35、atom_mean_17 位居前列。

结论与评价

优点： - 训练效率极高（50 轮约 3 分钟），开箱即用、无需早停，适合快速建立基线。 - bootstrap=False + max_features=sqrt 的小样本最优配置搜索清晰，超参结论可复现。 - SHAP 归因与 HistGB/CatBoost 高度一致（atom_std_44 居首），特征解释稳定。

不足： - 精度第 8 ($R^2 = 0.5621$)，非自适应集成的上限明显低于梯度提升（第一梯队 ≈ 0.68 ）。 - **Test RMSE 显著高于 CV (4.73 vs 4.31)**，独立测试集泛化弱。 - 重要度数值全 0 的展示缺陷，依赖 SHAP 补充文档化。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
6	LightGBM	4.5686	0.5922
7	CIF (ExtraTrees)	4.6913	0.5700
8	RandomForest	4.7340	0.5621
9	Transformer	7.2719	-0.0332
10	RNN	7.3354	-0.0514

RF 与同源的 CIF 构成第三梯队 ($R^2 \in [0.56, 0.57]$)，优于深度模型但明显落后于第一、二梯队。其**高效、稳健、可解释**的特性使其适合作为基线或特征筛选工具；但 AW_ST_CMC 预测追求精度时应优先 NGBoost/XGBoost/CatBoost，而非 RF 类非自适应集成。