

AW_ST_CMC Transformer 模型报告

Transformer 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC (表面活性剂在 CMC 时的表面张力, 单位 mN/m)
运行目录	runs\AW_ST_CMC\AW_ST_CMC_transformer_20260805_151238
运行时间	15:12 开始 ~ 15:23 结束 (约 11 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

Transformer 是 10 个模型中的**序列式深度模型**之一 (与 RNN 同类)。本项目将 522 维特征向量 reshape 为 (batch, 522, 1), **把每个特征维度当作一个时间步**, 用 3 层 Transformer Encoder ($d_{\text{model}}=128$ 、4 头注意力、FFN=256、GELU) 对特征序列做自注意力建模, 配合 CosineAnnealingLR 学习率调度与梯度裁剪 ($\text{grad_clip}=5.0$)。架构为**固定配置, 未做 Optuna 调参**。

在 AW_ST_CMC 任务中, Transformer 的 Test $R^2 = -0.0332$ 、Test RMSE = 7.2719, 排名第 9 (倒数第二)。其 R^2 为负, 意味着预测**不如“直接用均值”这一朴素基线**, 模型在该 target 上完全失效——与 RNN 一同构成本项目两个完全失效的深度模型, 值得重点分析。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **序列化方式**: 522 维特征 $\rightarrow$ (batch, 522, 1), 每特征维度为一步长。

超参数与调优

采用 **固定架构** (深度模型中仅 MLP 使用 Optuna, RNN/Transformer 均不调参) :

参数	值
d_model	128
num_layers (编码器层数)	3
nhead (注意力头数)	4
dim_feedforward (FFN)	256
activation	gelu
dropout	0.1
learning_rate	1e-3
weight_decay	1e-5
batch_size	16
最大 epoch	500 (早停保护)
调度/裁剪	CosineAnnealingLR、grad_clip=5.0

设计说明: 4 头注意力 $\times$ d_model=128 是轻量 Transformer, FFN 256 居中。与 MLP 相比, Transformer 缺少 Optuna 调参、且自注意力机制对 522 维“伪序列”的建模假设存疑。

训练过程

- 固定架构直接训练: Val RMSE 在 epoch 15 达到最优 **6.9977**, 此后至 epoch 105 在 7.00~7.26 之间小幅震荡。

- **Epoch 110 起验证误差断崖式爆增至 45.5+ 并持续 (45.5 ~ 46.0)**，呈现明显的**训练发散/崩溃**（自注意力在 737 样本上进入不稳定状态），早停在 epoch 165 触发。

说明：本模型训练脚本未生成 pred_vs_true 与 SHAP 图（深度模型统一不输出绘图文件）。

测试结果

指标	值
Test RMSE	7.2719
Test MAE	5.7139
Test R ²	-0.0332
Best val RMSE	6.9977

Test MSE = 52.8808, RMSE (7.27) 高于验证最优 (6.9977)，R² 为负。与 RNN 一样，7.3 的 RMSE 与 AW_ST_CMC 目标本身的标准差同量级，**预测未学到有效结构**。与 RNN 的“平台期失效”相比，Transformer 是“中期崩溃”——即便早停保留了 epoch 15 的权重，测试表现依旧为负。

特征重要性

Transformer 为黑盒注意力网络，日志未输出特征重要性；且本任务 R² 为负、训练中期还发生发散，**任何特征归因都缺乏意义**。仅能推断：把无序手工特征当作序列让自注意力去捕捉“跨维度关系”的建模假设不成立——特征维度之间本无时序依赖，且 522 长序列对 737 样本的自注意力训练极不稳定。

结论与评价

优点： - 架构现代、代码可复现；grad_clip 与早停成功防止了发散彻底污染交付权重。

不足： - **完全失效**：Test R² = -0.0332（第 9 名），劣于常数基线，无实用价值。 - **Epoch 110 起验证损失爆增至 45+**，训练不稳定，早停前的权重已无意义。 - 自注意力在 522 维伪序列 + 737 样本上的组合既不高效也不稳定，固定架构又无调参兜底。

关于失效原因的分析： AW_ST_CMC 的 522 维特征是无序的手工描述符，**不具备序列/时序语义**。Transformer 的自注意力需要在足够大的数据上学习跨 token 关联，而 737 样本对“522 长度序列”的训练极不稳定（本次甚至中期发散）。对比鲜明的是：**MLP（同样 522 维输入、不做序列化、经 Optuna 调参） $R^2 = 0.6348$** ，而 RNN/Transformer 双双为负——**差距根源在序列化建模方式与样本量不匹配，而非“深度”本身**。这也印证了本项目深度路线的正确收敛方向是“手工特征 + MLP”，而非序列式模型。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
7	CIF (ExtraTrees)	4.6913	0.5700
8	RandomForest	4.7340	0.5621
9	Transformer	7.2719	-0.0332
10	RNN	7.3354	-0.0514

Transformer 与 RNN 构成唯一的“负 R^2 ”梯队，双双垫底。两者在 AW_ST_CMC 上均为无效模型，**不应作为该 target 的预测工具**；追求精度应使用第一梯队（NGBoost/XGBoost/CatBoost），追求深度路线应使用 MLP。