

AW_ST_CMC XGBoost 模型报告

XGBoost 模型报告 — AW_ST_CMC 预测

报告信息

项目	内容
目标变量	AW_ST_CMC（表面活性剂在 CMC 时的表面张力，单位 mN/m）
运行目录	runs\AW_ST_CMC\AW_ST_CMC_xgboost_20260805_152638
运行时间	15:26 开始 ~ 16:17 结束（约 51 分钟）
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

XGBoost 是陈天奇提出的梯度提升框架，以其对**二阶泰勒展开**、稀疏感知与列块并行的实现著称。本项目为 XGBoost 配置了**全模型最复杂的调参管线**：200 轮 Optuna × 5 折 CV（CV 样本 758），配合 **Top-5 holdout 泛化性筛选**（独立 holdout 85 样本 + 训练-验证差距惩罚，防止过拟合的“虚高”参数被选中）。

在 AW_ST_CMC 任务中，XGBoost 的 Test $R^2 = 0.6852$ 、Test RMSE = 4.0139，在 10 个模型中排名第 2，处于第一梯队（仅次于 NGBoost）。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 843 条 (737 训练 + 106 验证) , 测试集 70 条; 调参阶段进一步在 843 条内划分 CV 758 / Holdout 85 (最终模型在 758 条上训练, 85 条仅用于参数泛化筛选) 。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 200 轮 × 5 折交叉验证** (多元 TPE 采样器 + gap penalty) , 并在 200 轮结束后取 CV 最优的 **Top-5 参数在独立 holdout (85 样本) 上复评**, 最终选择 holdout 上最泛化的参数而非 CV 最优者。

Optuna 最优试验 (CV RMSE = 4.1316) :

参数	值
n_estimators	1807
max_depth	10
learning_rate	0.0305
subsample	0.6512
colsample_bytree / bylevel / bynode	0.9343 / 0.7815 / 0.8013
min_child_weight	3.4974
gamma	0.1382
reg_alpha / reg_lambda	≈0 / 0.8036
max_delta_step	3.5148
booster	dart

Optuna 参数重要度:

参数	重要度
min_child_weight	0.4253
colsample_bytree	0.3547
max_delta_step	0.0942
max_depth	0.0687
其余 (learning_rate、subsample 等)	< 0.02

参数重要度显示 **min_child_weight (最小叶样本权重)** 与 **colsample_bytree (列采样)** 合计 **0.78**，是本任务中决定 XGBoost 表现的**两个主导杠杆**——前者通过强制叶节点拥有足够样本量来抑制过拟合，后者通过列随机化增强集成多样性，二者合计 0.78，说明**样本量小 (758) 且特征维数高 (522) 的数据上，控制叶子复杂度与特征冗余是精度关键**。最终经 Top-5 holdout 筛选选中的参数为 `booster='gbtree'`、`n_estimators=1313`、`max_depth=9`、`learning_rate=0.0118`、`gamma=0.0934` (holdout RMSE = 4.1431)，与 CV 最优的 dart 组合略有分歧，体现了“选泛化最优而非 CV 最优”的取舍。


训练过程

- **调参阶段**：200 轮 Optuna 中大部分轮次快速完成（多为数秒级），最终 CV 最优为 4.1316 (Trial 172)。随后 **Top-5 holdout 复评**：5 个 CV 最优候选在 85 条独立 holdout 上重算，Holdout RMSE 从 4.3671 (Rank 1) 到 4.1431 (Rank 5)，**最优泛化者并非 CV 排名最前者**——Rank 5 的候选因 holdout 误差最小而胜出，gap penalty 成功避免了“CV 虚高”参数的选中。
- **最终训练**：以选中参数 (gbtree、n_estimators=1313) 在 758 条训练集上训练，输出测试评估。

测试结果

指标	值
Test RMSE	4.0139
Test MAE	3.0172
Test R ²	0.6852
Best CV RMSE	4.1316
Holdout RMSE	4.1431

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.0139) 优于调参 CV (4.1316) 与 holdout (4.1431)，说明经过 Top-K 泛化筛选的参数在**独立测试集上表现更好**，验证了“以泛化性而非 CV 精度选参”这一策略的价值。Test MSE = 16.1116 与之印证。

特征重要性 (说明)

当前日志输出的 Top-20 特征重要度数值**基本全为 0.0**（仅 surf_cationic、maccs_125、bond_mean_12 为 0.1），排序语义有限。0 值集中在 AroRings、NumRings、maccs_65/166/107、bond_std_12 等**环结构、MACCS 药效团与键性质特征**上，而 surf_cationic（表面活性剂类型——阳离子 one-hot）占据首位，结合本项目其余树模型（CatBoost/CIF/HistGB）SHAP 的结论，阳离子类型与分子量/亲疏水描述符是 AW_ST_CMC 的主导因素。**注意：本次 XGBoost 运行未生成任何 SHAP 图**（仅保存 pred_vs_true.png），数值归零属于 XGBoost 默认 weight 型重要度在该配置下的口径展示问题；若要精确归因，应复用

shap_xgboost.py 对模型另行做 TreeExplainer 分析。物理上，阳离子 headgroup 在界面上的电荷排布直接影响表面压行为，与 AW_ST_CMC ↔ Pi_CMC ($r=-0.99$) 的近似线性关系一致。

结论与评价

优点： - 精度第 2 ($R^2 = 0.6852$)，与 NGBoost (0.6924) 仅差 0.007，处于第一梯队核心。 - 最严谨的调参流程 (200 轮 + Top-5 泛化筛选 + gap penalty)，**Test 优于 CV/holdout** 直接证明了该流程的价值。 - 参数重要度 (min_child_weight + colsample_bytree = 0.78) 给出清晰的正则方向。

不足： - 特征重要度输出数值异常 (全 0)，可解释性文档化需依赖 SHAP 补充。 - 调参成本高 (200 轮 + holdout 复评约 51 分钟)。 - 相对 NGBoost (3.9679) 仍有 0.046 的 RMSE 差距，未登顶。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
1	NGBoost	3.9679	0.6924
2	XGBoost	4.0139	0.6852
3	CatBoost	4.0407	0.6810
4	MLP	4.3235	0.6348

XGBoost 与 NGBoost、CatBoost 构成差距小于 0.08 RMSE 的**紧密第一梯队**；其 Test < CV 的泛化表现是三个模型中最“诚实”的选参结果。作为调参最充分、泛化验证最严格的模型，XGBoost 适合作为**精度基准**；若追求不确定性可优先 NGBoost，追求 MAE 最优可优先 CatBoost。