

Gamma_max CatBoost 模型报告

CatBoost 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m², 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_catboost_20260805_163145
运行时间	16:31:45 ~ 17:15:35 (约 44 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CatBoost 是 Yandex 提出的梯度提升框架, 以**对称树 (oblivious trees)**、ordered boosting 与内建类别特征处理著称。本项目用 Optuna 50 轮 × 5 折 CV 对其 depth、learning_rate、iterations、l2_leaf_reg 以及 random_strength / bagging_temperature / border_count / one_hot_max_size / leaf_estimation_iterations / min_data_in_leaf 共 10 个超参进行联合调优, 是调参最充分的树模型之一。

在 Gamma_max 任务中, CatBoost 的 Test $R^2 = 0.3308$, 在 10 个模型中排名第 5 (MLP 0.7515、CIF 0.5956、RF 0.4621、LightGBM 0.3413 之后)。 R^2 为正但处于中游, 说明其捕获了目标的部分相关结构, 但显著弱于深度模型 MLP。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征 (原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12)。本次运行 [Cache MISS]，现场计算 628/628 有效分子并写入 `data\features\surfpro\Gamma_max\` 缓存。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**)，测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)`，固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 `Y_SCALE = 1e6` (`config.json` "`y_scale`": `1000000`)，Optuna trial 值与最终训练评估均为缩放单位。

超参数与调优

Optuna 50 轮 × 5 折 CV (TPE 采样器 + MedianPruner)，最优试验 (Trial 39, CV RMSE = 1.0057, 缩放单位)：

参数	值
depth	10
learning_rate	0.208
iterations	676
l2_leaf_reg	4.648
random_strength	5.129
bagging_temperature	2.490
border_count	33
one_hot_max_size	43
leaf_estimation_iterations	2
min_data_in_leaf	47

Optuna 参数重要度：

参数	重要度
depth	0.2714
min_data_in_leaf	0.2701
l2_leaf_reg	0.1371
one_hot_max_size	0.1250
random_strength	0.0800
其余 (lr / iterations / border_count 等)	< 0.05

参数重要度显示 **depth 与 min_data_in_leaf 共同主导 (合计 0.54)** ——树深与叶节点最小样本数决定模型容量与过拟合控制，这与该任务样本量小 (549)、树模型易过拟合的特点吻合。搜索从 Trial 0 (1.065) 逐步收敛到 Trial 39 (1.006)，后期多数试验落在 1.03~1.05 区间，搜索稳定收敛。

训练过程

- **调参阶段**：50 轮中 5 轮被 MedianPruner 剪枝；最优试验 Trial 39 的 CV RMSE = 1.0057 (缩放单位)。
- **最终训练**：以 Trial 39 参数在 549 条数据上训练，**过拟合检测器在第 20 轮触发早停** (bestTest = 1.3574、bestIteration = 20，缩放单位)，模型收缩为前 21 轮迭代。训练日志可见 learn RMSE 从 1.42 一路降到 0.05，而 test RMSE 始终停在 ~1.36——典型**过拟合信号**，早停将模型限制在泛化更好的前 21 轮。


注意：Gamma_max 下 Optuna 最优 CV (1.0057) 与最终训练的验证 RMSE (bestTest = 1.3574) 均为缩放单位；最终验证值高于 CV 最优，说明该参数组合在独立验证集上过拟合风险仍较明显，早停至关重要。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.3308
参考 CV RMSE (Optuna 最优, 缩放单位)	1.0057

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000), 评估回到原始单位后取 4 位小数, 原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000; R² 无量纲, 是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致 (本脚本已 $\div 1e6$ 为 0.0), 因此本报告以日志中 Optuna Best-trial 值 (缩放单位, 约 1.0 量级) 作为 CV 参考。

图: 预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test R² = 0.3308, 说明模型解释了约三分之一的目标方差。最终验证 RMSE (1.3574, 缩放单位) 明显高于 Optuna CV (1.0057), 印证了该模型在 Gamma_max 上的过拟合倾向——这也是其排名仅居第 5 的主要原因。

特征重要性 (Top 20)

日志输出 Top-20 特征重要度 (weight 口径), Top-5:


1. **atom_mean_46** (7.7) : Gasteiger 电荷落在 [-1,-0.5) 强负电分桶的原子占比均值
2. **atom_std_4** (6.3) : 氮原子类型的分布标准差

3. `maccs_166` (5.8) : MACCS 结构键 bit 166
4. `tail_ratio` (5.3) : 疏水尾链碳占比
5. `atom_mean_26` (5.2) : 隐氢数 = 3 的原子占比均值


紧随其后: `atom_std_35` (4.0, 原子质量标准差)、`atom_mean_17` (3.6, 度数 = 1)、`bond_mean_0` (2.5)、`brics_2` (2.2, BRICS 片段)、`FracSP3` (2.1, 饱和碳比例)。

物理分析: 排首的强负电原子占比 (Gasteiger 分桶) 与氮原子分布指向**带电/极性头基**的影响; `tail_ratio` 与 `FracSP3` 则刻画**疏水尾链长度与柔性**。最大表面超量取决于分子在界面上的堆积密度, 头基带电结构决定极性取向、尾链决定疏水堆积, 二者共同作用符合界面物理直觉。MACCS 结构键与 BRICS 片段作为结构基元补充了局部化学环境的识别。


SHAP 图组由 `shap_catboost.py` (TreeExplainer) 生成, 给出逐样本归因:



SHAP 蜜蜂图: 每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_mean_46*、*atom_std_4*、*tail_ratio* 等与日志重要度排序大致一致。



Top-1 SHAP 依赖图：强负电原子占比 (*atom_mean_46*) 对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - 调参最充分：10 个超参联合优化（50 轮 × 5 折），参数重要度分析清晰指出深度与叶节点样本数为主导。 - 特征归因完备：pred_vs_true、SHAP 蜜蜂图 / 条形图 / 依赖图齐全，可解释性好。 - 早停机制有效拦截过拟合，最终交付的是泛化更稳的早期迭代。

不足： - Test $R^2 = 0.3308$ 仅列第 5，与领先的 MLP (0.7515) 差距大，对 Gamma_max 的预测能力有限。 - 最终训练验证 RMSE (1.3574) 明显高于 Optuna CV (1.0057)，说明该任务上 CatBoost 的过拟合控制仍未到位。 - 原始 RMSE/MAE 因目标量级太小而失去判别意义，只能依赖 R^2 评价。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
3	RandomForest	0.4621
4	LightGBM	0.3413
5	CatBoost	0.3308
6	NGBoost	0.3191
7	XGBoost	0.2821

CatBoost 处于中游偏下，优于 NGBoost/XGBoost/HistGB 等其余树模型，但明显逊于 MLP 与 CIF。综合其完备的可解释性工具链，可作 Gamma_max 的特征-目标关系分析的参考模型，但在精度导向的筛选中不具竞争力。