

Gamma_max CIF (ExtraTrees) 模型报告

CIF (条件推理森林 / ExtraTrees) 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_cif_20260805_172005
运行时间	17:20:05 ~ 17:21:43 (约 1.5 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CIF (Conditional Inference Forest) 在此实现中由 **ExtraTrees (极端随机树)** 承载: 不同于标准随机森林在最优切分点中做选择, ExtraTrees 在每个节点**随机生成切分阈值**, 从而进一步降低方差、抑制过拟合。本项目 522 维特征以连续型描述符为主, ExtraTrees 对连续特征的随机切分策略尤其高效, 且训练开销极低。

在 Gamma_max 任务中, CIF 的 Test $R^2 = 0.5956$, 在 10 个模型中排名**第 2** (仅次于 MLP 0.7515), 是树模型中的最佳者——显著优于其姊妹模型 RandomForest (0.4621) 与全部梯度提升树。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余 9 个模型完全一致, 保证公平对比。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**), 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)`, 固定随机种子。
- **训练缩放**: 训练脚本对 `y` 乘以 `Y_SCALE = 1e6` (`config.json` "`y_scale`": `1000000`), Optuna trial 值与最终训练评估均为缩放单位。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 48, CV RMSE = 1.0325, 缩放单位) :

参数	值
n_estimators	1827
max_depth	21
min_samples_split	7
min_samples_leaf	1
max_features	log2
bootstrap	False

调优过程观察: - 前几轮表现较差 (CV RMSE 1.24~1.40), 原因是搜索初期偏向 `bootstrap=True` + `max_features='sqrt'` 的组合; 随后快速收敛到 `bootstrap=False` + `max_features='log2'` 区域, Trial 12 起进入 1.04~1.06, **Trial 48 触底至 1.0325**。 - 与 RandomForest 同搜索空间、同最优参数组合, 但 CIF 的随机切分策略在 `Gamma_max` 上带来明显增益 (Test R^2 0.5956 vs 0.4621) ——**随机阈值对连续特征的探索更充分**。 - `bootstrap=False` (全样本训练) + `log2` 特征子空间在 549 条小样本上兼顾了树间差异与样本利用效率。 - 50 轮中 5 轮被 MedianPruner 剪枝, 单轮 5 折 CV 平均约 1.5 秒, 全程仅约 1.5 分钟, **调参效率极高**。

训练过程


由于 ExtraTrees 是**非迭代式**集成（一次性训练全部树、取平均），日志中无逐轮 loss 曲线，`Training Final Model` 阶段直接输出结果。这意味着：- 无过拟合检测器、无早停需求，超参确定后即一次成型；- 训练时间几乎全部来自 Optuna 搜索阶段，最终模型训练仅数秒。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.5956
参考 CV RMSE (Optuna 最优, 缩放单位)	1.0325

* 训练脚本对 y 乘以 1e6 (config 中 `y_scale=1000000`)，评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000；R² 无量纲，是唯一可信指标。metrics.json 的 `best_cv_rmse` 跨脚本不一致 (cif/histgb/ngboost/rf 等仍为缩放单位，本脚本为 1.0325)，因此本报告以日志中 Optuna Best-trial 值（缩放单位，约 1.0 量级）作为 CV 参考。

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test R² = 0.5956，解释了目标方差的约 60%，为树模型之最。随机切分 + 全样本训练的组合在本 target 上抑制了过拟合（对比梯度提升树普遍存在的验证/测试差距），是树模型路线在 Gamma_max 上的最优答案。

特征重要性 (Top 20)


日志输出 Top-20 特征重要度 (杂质减少口径)，数值全部显示为 0.0 (对缩放后 y 的杂质减少量级极小被四舍五入，属于**展示问题**，排序仍可信)。Top-5:

1. `AroRings` : 芳香环数
2. `atom_max_20` : 度数 = 4 (季碳/高支化) 原子占比最大值
3. `NumRings` : 环总数
4. `brics_10` : BRICS 碎片 bucket 10
5. `maccs_112` : MACCS 结构键 bit 112


紧随其后: `maccs_77`、`maccs_30`、`maccs_166`、`atom_max_16` (度数 = 0)、`atom_mean_54` (重原子邻居)、`maccs_83`、`atom_std_16`、`atom_min_54`、`atom_mean_40` (显价 = 3)、`atom_max_54`、`maccs_96`、`atom_std_44` (5 元环)、`atom_std_22` (形式电荷) 等。

物理分析: CIF 的重要性画像以**芳香/环结构** (`AroRings`、`NumRings`、多个 MACCS 结构键) 与**高支化碳** (`atom_max_20`) 为核心，与 HistGB 的“芳香性主导”结论相互印证。芳香环赋予分子平面刚性结构，影响其在气液界面的平铺堆积与最大表面超量；BRICS 片段 (`brics_10`) 与 MACCS 键补充了局部结构基元。整体指向“**刚性环状疏水骨架决定界面堆积**”的物理机制。


SHAP 图组由 `shap_cif.py` (TreeExplainer) 生成:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: AroRings、atom_max_20、NumRings 等位居前列, 与日志重要度一致。



Top-1 SHAP 依赖图：度数 = 4（高支化）原子占比最大值（atom_max_20）对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - **树模型最优：** Test $R^2 = 0.5956$ 排名第 2，仅次于 MLP (0.7515)，显著优于姊妹模型 RF (0.4621)。 - 方差控制出色：随机切分阈值 + `bootstrap=False` + 全样本训练，在小样本高维特征上过拟合最轻。 - 调参成本极低（约 1.5 分钟），特征归因完备（pred_vs_true + SHAP 图组），“芳香/环结构主导”的物理结论清晰。

不足： - 精度仍明显低于 MLP (0.7515)，深度模型在本 target 上反超树模型。 - 日志重要度数值显示异常（全 0.0），精确归因需依赖 SHAP 补充。 - 原始 RMSE/MAE 因目标量级太小失去判别意义，只能依赖 R^2 评价。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
1	MLP	0.7515
2	CIF (ExtraTrees)	0.5956
3	RandomForest	0.4621
4	LightGBM	0.3413

CIF 是 Gamma_max 上**树模型的最优选择**，以极低成本取得稳健的次优精度。若实际场景要求可解释、低延迟且拒绝黑盒，CIF 是最佳树模型候选；若追求极致精度，则应选用 MLP。