

Gamma_max HistGB 模型报告

HistGradientBoosting 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_histgb_20260805_172618
运行时间	17:26:18 ~ 17:52:43 (约 26 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

HistGradientBoosting (HistGB) 是 scikit-learn 基于直方图分箱实现的梯度提升回归器, 与 LightGBM 同源 (binning + GOSS 式加速), 接口简洁、无需类别预处理。本项目用 Optuna 50 轮 × 5 折 CV 对 learning_rate、max_iter、max_depth、max_leaf_nodes、min_samples_leaf、l2_regularization、max_bins 共 7 个超参联合调优。

在 Gamma_max 任务中, HistGB 的 Test R² = 0.1851, 在 10 个模型中排名第 8 (仅优于 Transformer 0.1086 与 RNN -0.01)。其性能在树模型中垫底, 对 Gamma_max 的拟合能力明显不足。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 $Y_SCALE = 1e6$ (`config.json` "y_scale": 1000000) , Optuna trial 值与最终训练评估均为缩放单位。

超参数与调优

Optuna 50 轮 $\times$ 5 折 CV (TPE 采样器 + MedianPruner) , 最优试验 (Trial 42, CV RMSE = 1.0800, 缩放单位) :

参数	值
learning_rate	0.0110
max_iter	2723
max_depth	14
max_leaf_nodes	215
min_samples_leaf	19
l2_regularization	9.0e-7
max_bins	134

调优过程观察: - 搜索从 Trial 0 (1.093) 起步, 中前期最优值长期停留在 1.093, 直至 **Trial 42 将 CV 收敛到 1.0800**; Trial 0 之外的多数试验 (1.15~1.24) 均差于 Trial 0, 说明超参空间对目标不敏感、搜索收益有限。 - 最优解取**大深度 (14) + 大叶节点数 (215)** 的强容量结构, 同时 L2 正则极小 ($9e-7$) , 几乎不设防——这与其最终过拟合的表现一致。 - 50 轮中 5 轮被 MedianPruner 剪枝; 单轮 5 折 CV 平均约 20 秒, 全程约 26 分钟, 在树模型中偏慢 (HistGB 全量迭代较耗算力) 。

训练过程

- **调参阶段**: 50 轮 Optuna, 最优 Trial 42 的 CV RMSE = 1.0800 (缩放单位) 。

- **最终训练**: 以 Trial 42 参数在 549 条数据上训练 (sklearn HistGB 定长 max_iter=2723, 无早停重复), 测试集评估输出 Test $R^2 = 0.1851$ 。


注意: Gamma_max 下 Optuna trial 值均为缩放单位 (约 1.0 量级); HistGB 的 best_cv_rmse (1.0800) 在 metrics.json 中仍为缩放单位 (未 $\div 1e6$), 与日志 Best-trial 值一致。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R^2	0.1851
参考 CV RMSE (Optuna 最优, 缩放单位)	1.0800

* 训练脚本对 y 乘以 $1e6$ (config 中 y_scale=1000000), 评估回到原始单位后取 4 位小数, 原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000; R^2 无量纲, 是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致 (cif/histgb/ngboost/rf 等仍为缩放单位, 本脚本为 1.0800), 因此本报告以日志中 Optuna Best-trial 值 (缩放单位, 约 1.0 量级) 作为 CV 参考。

图: 预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test $R^2 = 0.1851$ 为树模型中最低，仅解释了目标方差的约 18%。最优参数（大深度 + 无正则）在 CV 上尚可（1.0800），但测试集表现大幅滑落，说明模型在独立测试集上严重过拟合、泛化能力不足。

特征重要性 (Top 20)


日志输出 Top-20 特征重要度为**置换重要性 (permutation-based, 带 $\pm$ 标准差)**，口径与 CatBoost/LightGBM 的增益重要度不同，数值为 RMSE 下降幅度。Top-5:

1. `atom_mean_33` (0.4495 ± 0.0221) : 芳香原子占比均值
2. `atom_std_17` (0.2972 ± 0.0330) : 度数 = 1 (末端原子) 分布标准差
3. `atom_mean_20` (0.2014 ± 0.0615) : 度数 = 4 (季碳/高支化) 占比均值
4. `atom_mean_16` (0.1661 ± 0.0176) : 度数 = 0 原子占比均值
5. `atom_std_40` (0.1544 ± 0.0063) : 显价 = 3 分布标准差


紧随其后: `atom_std_25` (隐氢数 = 2)、`brics_10` (BRICS 片段)、`atom_mean_54` (重原子邻居)、`atom_mean_38` (显价 = 1)、`atom_mean_17` (度数 = 1)、`head_ratio`、`atom_std_35` (原子质量)、`HeavyAtoms`、`FracSP3`、`MolWt` 等。

物理分析: HistGB 的置换重要性将**芳香性 (`atom_mean_33`) 置于首位**，且重要度远超第二位 (0.45 vs 0.30) ——这是 10 个模型中芳香性信号最强的特征画像。芳香环对表面吸附的平面性贡献显著，符合 `Gamma_max` 的界面堆积直觉。其余靠前特征仍为碳骨架拓扑 (度数分布) 与头尾/尺寸描述符 (`head_ratio`、`HeavyAtoms`、`MolWt`、`FracSP3`)。


SHAP 图组由 `shap_histgb.py` (TreeExplainer) 生成:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_mean_33*、*atom_std_17*、*atom_mean_20* 等位居前列。



Top-1 SHAP 依赖图：度数 = 0 原子占比 (*atom_mean_16*) 对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - 调参完整 (Optuna 50 轮 × 5 折)，置换重要性带置信区间，可解释性输出规范。 - 芳香性主导的特征画像为理解 *Gamma_max* 提供独特视角（平面性对界面吸附的作用）。

不足： - Test $R^2 = 0.1851$ 为树模型中最低，排名第 8，预测能力明显不足。 - 最优参数“大深度 + 无正则”在测试集上严重过拟合，泛化差。 - 调参成本（约 26 分钟）与其精度不匹配，性价比低。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
6	NGBoost	0.3191
7	XGBoost	0.2821
8	HistGB	0.1851
9	Transformer	0.1086
10	RNN	-0.01

HistGB 处于树模型末位，仅勉强优于两个序列式深度模型。其对 Gamma_max 的过拟合倾向明显，建议在本 target 上弃用；若需树模型路线，LightGBM (0.3413) 与 RandomForest (0.4621) 是更稳妥的选择。