

Gamma_max LightGBM 模型报告

LightGBM 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_lightgbm_20260805_180756
运行时间	18:07:56 ~ 18:09:09 (约 1.5 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

LightGBM 是微软提出的梯度提升框架, 以**直方图 (Histogram) 分箱**、**单边梯度采样 (GOSS)** 与 **互斥特征捆绑 (EFB)** 著称, 训练速度在树模型中居首。本项目用 Optuna 50 轮 × 5 折 CV 对 boosting_type、max_depth、num_leaves、learning_rate、正则参数及 dart 专属参数等 16 个超参联合调优。

在 Gamma_max 任务中, LightGBM 的 Test $R^2 = 0.3413$, 在 10 个模型中排名第 4 (MLP、CIF、RF 之后), 是传统树模型中的较优者之一, 但显著弱于深度模型 MLP (0.7515)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 `Y_SCALE = 1e6` (config.json "y_scale": 1000000) , Optuna trial 值与最终训练评估均为缩放单位。

超参数与调优

Optuna 50 轮 × 5 折 CV (TPE 采样器 + MedianPruner) , 最优试验 (Trial 41, CV RMSE = 1.0865, 缩放单位) :

参数	值
boosting_type	gbdt
max_depth	8
num_leaves	126
learning_rate	0.0945
n_estimators	2736
subsample / subsample_freq	0.772 / 1
colsample_bytree	0.981
reg_alpha / reg_lambda	3.3e-4 / 2.9e-5
min_child_samples / min_child_weight	25 / 0.024
min_split_gain	0.048

调优过程观察: - 搜索从 Trial 0 (2.010) 快速收敛: Trial 1 (1.415) → Trial 16 (1.096) → **Trial 41 (1.0865)** , 中后期多数试验稳定在 1.10~1.13, 收敛充分。 - 最优解选择 **gbdt** (而非 dart) , 且 `num_leaves=126`、`max_depth=8` 构成中等容量的树结构; 正则项整体取值温和, 说明 522 维特征上 LightGBM 的过拟合压力小于 CatBoost。 - 每折均早停 (30 轮耐心) , 单轮 5 折 CV 秒级完成, 全程约 1.5 分钟——10 个模型中调参成本最低之一。

训练过程

- **调参阶段**: 50 轮 Optuna, 最优 Trial 41 的 CV RMSE = 1.0865 (缩放单位)。
- **最终训练**: 以 Trial 41 参数在 549 条数据上训练, **早停触发于第 158 轮迭代** (验证 RMSE = 1.4654, 缩放单位), 耐心值 50 轮。早停使模型以验证最优迭代交付, 未出现明显过拟合蔓延。


注意: Gamma_max 下 Optuna trial 值均为缩放单位 (约 1.0 量级); 最终训练验证 RMSE (1.4654) 高于 CV 最优 (1.0865), 为独立验证集上的通常表现。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.3413
参考 CV RMSE (Optuna 最优, 缩放单位)	1.0865

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000), 评估回到原始单位后取 4 位小数, 原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000; R² 无量纲, 是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致 (本脚本已 $\div 1e6$ 为 0.0), 因此本报告以日志中 Optuna Best-trial 值 (缩放单位, 约 1.0 量级) 作为 CV 参考。

图: 预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test $R^2 = 0.3413$ ，在树模型中排名靠前。结合 LogP/TPSA/MolWt 等高重要性描述符（见下节），LightGBM 主要依靠全局物化性质刻画目标，对中值区分子预测相对可靠。

特征重要性 (Top 20)


日志输出 Top-20 特征重要度 (split 口径)，Top-5：

1. `atom_std_25` (92.0)：隐氢数 = 2 的分布标准差
2. `head_ratio` (82.0)：头基原子数 / 总原子数
3. `atom_mean_35` (69.0)：原子质量 / 100 的均值
4. `LogP` (55.0)：脂水分配系数
5. `atom_mean_17` (53.0)：度数 = 1 (末端原子) 占比均值


紧随其后：`MolWt` (50.0)、`tail_ratio` (48.0)、`atom_mean_26` (43.0)、`atom_std_35` (41.0)、`atom_std_39` (显价 = 2)、`atom_mean_40` (显价 = 3)、`TPSA`、`atom_mean_54` (重原子邻居)、`RotBonds` 等。

物理分析：与 CatBoost 侧重原子聚合特征不同，LightGBM 的 Top-20 中**全局分子描述符密集出现**——`LogP`、`TPSA`、`MolWt`、`RotBonds` 同时进入前 20，配合 `head_ratio` (82.0) 与 `tail_ratio` (48.0)，形成“**疏水尾链 + 极性头基 + 分子尺寸/柔性**”的完整物化画像。这符合最大表面超量的界面物理：头尾结构决定取向，分子尺寸与柔性决定界面堆积效率。`atom_std_25` (隐氢数分布异质性) 居首则反映碳骨架的氢化状态差异。


SHAP 图组由 `shap_lightgbm.py` (TreeExplainer) 生成：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: atom_std_25、head_ratio、LogP 等位列前茅, 与日志重要度基本一致。



Top-1 SHAP 依赖图：度数 = 0 原子占比 (*atom_mean_16*) 对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - 树模型中排名第 4 ($R^2 = 0.3413$)，优于 CatBoost/NGBoost/XGBoost/HistGB 等多数树模型。 - 调参成本极低（约 1.5 分钟），gbdt + 中等容量树结构在 522 维特征上表现稳健。 - 特征归因完备（pred_vs_true + 完整 SHAP 图组），且重要性信号物理含义清晰。

不足： - Test $R^2 = 0.3413$ 与领先的 MLP (0.7515) 差距明显，对 Gamma_max 的预测能力有限。 - 最终验证 RMSE (1.4654) 明显高于 Optuna CV (1.0865)，过拟合压力在独立验证集上显现。 - 原始 RMSE/MAE 因目标量级太小失去判别意义，只能依赖 R^2 评价。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R ²
2	CIF (ExtraTrees)	0.5956
3	RandomForest	0.4621
4	LightGBM	0.3413
5	CatBoost	0.3308
6	NGBoost	0.3191

LightGBM 以极低调参成本换取树模型中靠前的精度，性价比突出；其依赖全局物化描述符的特征画像也为理解 Gamma_max 的物理驱动因素提供了有价值的视角。若需更高精度，应转向 MLP。