

Gamma_max MLP 模型报告

MLP 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_mlp_20260805_184149
调参日志	runs\Gamma_max\Gamma_max_mlp_tuning_20260805_181240\train.log (Optuna 50 轮)
运行时间	调参 18:12 ~ 18:41 (约 29 分钟), 最终训练 18:41:49 ~ 18:41:58 (约 1 分钟以内)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

MLP (多层感知机) 是 10 个模型中唯一的**前馈全连接深度网络**

(RNN/Transformer 为序列式深度模型)。架构为 Linear → BatchNorm → GELU → Dropout 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 Gamma_max 任务中，MLP 的 **Test R² = 0.7515**，在 10 个模型中排名第**1**，显著领先第二名 CIF (0.5956)。这是本项目所有 target 中**深度模型首次大幅反超树模型**——Gamma_max 数值量级极小 ($\sim 1\text{e-}6 \text{ mol/m}^2$)，其相关结构可能更适合神经网络而非树模型的区间切分表达。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征 (原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描述符 12)，从缓存加载，与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**)，测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)`，固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 `Y_SCALE = 1e6` (`config.json` `"y_scale": 1000000`)，在缩放空间训练与评估，输出时还原。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner)。这是深度模型中唯一使用 Optuna 的 (RNN/Transformer 用固定架构)。

最优试验 (Trial 30, CV RMSE = 0.8215, 缩放单位) :

参数	值
n_layers	5
hidden_dim	488
dropout	0.049
activation	relu
learning_rate	3.12e-4
weight_decay	1.12e-7
batch_size	95
Best CV RMSE (缩放单位)	0.8215

调优过程观察: - 早期试验 (Trial 0/1) 表现差 (CV RMSE 1.35 / 2.12)，根因是学习率过低 ($1.5\text{e-}5$ / $3.5\text{e-}5$) 导致欠拟合；搜索随后收敛到 $\text{lr} \in [1\text{e-}4, 1\text{e-}2]$ 的合理区间。 - 最优解偏好 **relu 激活 + 中等隐藏层 (~490) + 5 层**，dropout 压到很低 (0.049)，weight_decay 极小 ($1.1\text{e-}7$) ——即“更大容量

+ 更少显式正则” ， 靠早停控制过拟合。 - Trial 30 (0.8215) 与 Trial 41 (0.8228) 、 Trial 45 (0.8222) 的 CV RMSE 非常接近，说明搜索已收敛、对超参不敏感，**最优解稳定**。 - 深度网络单轮 5 折 CV 平均耗时约 0.5 分钟，调参全程约 29 分钟，成本低于 pCMC 任务的 90 分钟（本 target 样本更少）。

训练过程

最终模型以 Trial 30 最优参数在 549 条数据上训练，**早停在 epoch 335** 触发（验证集 RMSE = 0.6836，缩放单位）。训练约 335 个 epoch，早停机制确保以验证最优权重（而非末轮权重）作为交付模型，未出现过拟合蔓延。

说明：最终训练与调参在同一调参日志中连续执行（Trial 49 结束后直接进入最终训练段）， `Gamma_max_mlp_20260805_184149` 目录为最终运行的独立存档。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.7515
参考 CV RMSE (Optuna 最优, 缩放单位)	0.8215
Best val RMSE (缩放单位)	0.6836

* 训练脚本对 y 乘以 1e6（config 中 y_scale=1000000），评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 ~1e-6 mol/m² 被压成 0.0000；R² 无量纲，是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致（本脚本已 ÷1e6 为 0.0），因此本报告以调参日志中 Optuna Best-trial 值（缩放单位，约 1.0 量级）作为 CV 参考。

说明：本次 MLP 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（深度模型训练脚本不输出绘图文件）。如需可视化，可复用 `train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test $R^2 = 0.7515$ 是 10 个模型中的**最高值**，测试表现 (0.7515) 优于参考 CV (0.8215，缩放单位)，说明泛化良好、无过拟合迹象。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因（本次 Gamma_max 运行未生成 SHAP 图）。基于其余树模型的一致性结论（见各模型报告），可推断其预测主要由原子级聚合特征（如原子 Mean 序号 16/20/33、Std 序号 16）与头尾比、HBA 等描述符驱动——这些特征反映亲水头基与疏水尾链的构成比例，与最大表面超量的物理含义吻合。MLP 的领先表明该目标存在树模型难以捕捉的高阶非线性组合。

结论与评价

优点： - **全模型最优：** Test $R^2 = 0.7515$ ，位列 10 个模型第一，大幅领先所有树模型——深度模型在本 target 上首次显著胜出。 - 使用 Optuna 充分调参（vs 固定架构的 RNN/Transformer），超参选择有依据、结果可复现。 - 早停 + Dropout + weight_decay 三重正则，泛化稳健（Test 0.7515 vs 参考 CV 0.8215）。

不足： - 黑盒模型，可解释性差，特征归因只能靠跨模型推断。 - 调参成本（约 29 分钟）高于多数树模型，且深度网络训练具有随机性，需要固定种子复现。 - 原始尺度下 RMSE/MAE 因量级太小而不可用，精度只能以 R^2 横向比较。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
1	MLP	0.7515
2	CIF (ExtraTrees)	0.5956
3	RandomForest	0.4621

MLP 以显著优势登顶，是 Gamma_max 任务当前的最佳模型。对于量级 $\sim 1e-6$ mol/m² 的目标，神经网络对微小数值结构的学习能力明显优于树模型的区间切分；若实际应用（如分子筛选排序）可接受黑盒，应优先选用 MLP。