

Gamma_max NGBost 模型报告

NGBost 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_ngboost_20260805_192211
运行时间	19:22:11 ~ 20:15:48 (约 54 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

NGBost (Natural Gradient Boosting) 是概率性梯度提升框架: 以**自然梯度**优化概率分布的参数 (本项目为 Normal 分布, 同时预测 **mean 与 std 两个输出**), 从而在给出点预测的同时提供**不确定性估计**——这是其区别于其他 9 个模型的独特能力。本项目对 5 个新 target 的 NGBost 采用 Optuna 调参 (50 轮 × 5 折 CV, score_rule 在 LogScore/CRPScore 间选择)。

在 Gamma_max 任务中, NGBost 的 Test R² = 0.3191, 在 10 个模型中排名第 6 (MLP、CIF、RF、LightGBM、CatBoost 之后), 处于中游。相比其在 pCMC 任务中第 2 名的表现, 本 target 上优势不再。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 `Y_SCALE = 1e6` (config.json "y_scale": 1000000) , Optuna trial 值与最终训练评估均为缩放单位。
- **概率输出**: Normal 分布, 测试集平均预测标准差 Avg pred std = 0.2084 (缩放单位) 。

超参数与调优

Optuna 50 轮 × 5 折 CV (TPE 采样器 + MedianPruner) , 最优试验 (Trial 18, CV RMSE = 1.1241, 缩放单位) :

参数	值
n_estimators	749
learning_rate	0.4226
minibatch_frac	0.758
max_depth	4
min_samples_leaf	57
score_rule	LogScore

调优过程观察: - Trial 0 (1.139) 即成为较长一段时间的基线, 多数试验 (1.14~1.39) 无法超越; **Trial 18 收敛到 1.1241** 后保持至调参结束, 搜索稳定。 - 最优解偏好 **LogScore + 相对深 (max_depth=4) 的树 + 大 min_samples_leaf=57**——叶节点样本数大提供正则, 与 NGBoost 双输出 (mean+var) 对树形稳定的要求一致。 - CRPScore 的试验整体劣于 LogScore (1.30+) , 说明本任务中 CRPS 评分规则收益不明显。 - 50 轮中 5 轮被剪枝; 单轮 5 折 CV 平均约 1 分钟, 全程约 54 分钟, 为树模型中调参最慢者 (NGBoost 需对每个分布参数建基学习器) 。

训练过程

- **调参阶段**: 50 轮 Optuna, 最优 Trial 18 的 CV RMSE = 1.1241 (缩放单位) 。

- **最终训练**：以 Trial 18 参数在 549 条数据上训练，训练 loss（负对数似然）从 iter 0 的 1.78 持续下降至 iter 700 的 -0.39（对数似然上升），**700+ 轮完整收敛无早停**；最终以 Normal 分布（mean ± std）交付，测试集平均预测标准差 0.2084（缩放单位）。


注意：Gamma_max 下 Optuna trial 值均为缩放单位（约 1.0 量级）；
NGBoost 的 best_cv_rmse (1.1241) 在 metrics.json 中仍为缩放单位（未 ÷1e6），与日志 Best-trial 值一致。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.3191
参考 CV RMSE (Optuna 最优, 缩放单位)	1.1241
平均预测标准差 (缩放单位)	0.2084

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000)，评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 ~1e-6 mol/m² 被压成 0.0000；
R² 无量纲，是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致（cif/histgb/ngboost/rf 等仍为缩放单位，本脚本为 1.1241），因此本报告以日志中 Optuna Best-trial 值（缩放单位，约 1.0 量级）作为 CV 参考。

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test $R^2 = 0.3191$ ，解释了目标方差的约 32%，排名第 6。平均预测标准差 (0.2084) 相对目标的缩放尺度 (均值附近 ~ 1.0) 较小，说明其不确定性估计较为自信；但点预测精度仅为中游，远逊于 MLP。


特征重要性

NGBoost 的 `feature_importances_` 因双输出 (mean + var) 形状为 (2, 522)，日志打印时被跳过 (`unexpected shape (2, 522), skipping`)，未输出 Top-20 列表。特征归因以 `shap_ngboost.py` 的 SHAP 分析 (KernelExplainer) 为准，依 SHAP 依赖图文件名可归纳 **SHAP 排名 Top-5**：


1. `atom_mean_20`：度数 = 4 (季碳/高支化) 原子占比均值
2. `atom_mean_24`：隐氢数 = 1 原子占比均值
3. `atom_std_16`：度数 = 0 原子分布标准差
4. `atom_mean_16`：度数 = 0 原子占比均值
5. `HBA`：氢键受体数 / `n_atoms`

物理分析： NGBoost 的归因集中于**碳骨架拓扑 (度数分布)**，同时引入唯一的极性特征 **HBA**——亲水头基的氢键受体能力。这与“疏水尾链拓扑决定堆积 + 头基极性决定取向”的界面物理直觉吻合：最大表面超量同时受尾链支化/长度与头基氢键位点影响。注意其归因范围较窄 (主要依赖原子聚合与 HBA)，未见芳香性/尺寸描述符，可能是其精度受限的原因之一。


SHAP 图组 (由 `shap_ngboost.py` 生成, KernelExplainer)：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: atom_mean_20、atom_mean_24、HBA 等位居前列。



Top-1 SHAP 依赖图：度数 = 4（高支化）原子占比（atom_mean_20）对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - **唯一提供不确定性估计的模型**：输出 Normal 分布（mean $\pm$ std），Avg pred std = 0.2084，可用于可靠区间与风险规避场景。 - 本次采用 Optuna 充分调参（score_rule、树结构、学习率等），参数选择有依据。 - 双输出梯度提升机制天然适合“均值 + 不确定度”联合建模。

不足： - Test R^2 = 0.3191 排名第 6，明显低于其姊妹树模型 CIF (0.5956) 与 RF (0.4621)，更远逊于 MLP (0.7515)。 - 调参成本高（约 54 分钟），为树模型中最慢；特征归因范围窄，未见芳香性/尺寸等维度。 - 原始 RMSE/MAE 因目标量级太小失去判别意义，只能依赖 R^2 评价。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
4	LightGBM	0.3413
5	CatBoost	0.3308
6	NGBoost	0.3191
7	XGBoost	0.2821
8	HistGB	0.1851

NGBoost 处于中游。其点预测精度不占优，但在需要**不确定性量化**（如筛选时对置信度低的分子的二次确认）的场景下，其 Normal 双输出是独特价值；若仅追求精度，应选择 MLP 或 CIF。