

Gamma_max RandomForest 模型报告

RandomForest 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_rf_20260805_201928
运行时间	20:19:28 ~ 20:21:16 (约 2 分钟, 含 50 轮 Optuna + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RandomForest (随机森林) 是基于 **Bagging + 随机特征子空间** 的集成回归器：每棵树在自助采样子集上以随机特征子集分裂，平均多棵树输出。其不依赖梯度迭代，对噪声与过拟合天然稳健，是 10 个模型中“方差控制”最好的代表。本项目用 Optuna 50 轮 × 5 折 CV 对 n_estimators、max_depth、min_samples_split、min_samples_leaf、max_features、bootstrap、max_samples 联合调优。

在 Gamma_max 任务中，RandomForest 的 Test $R^2 = 0.4621$ ，在 10 个模型中排名第 3 (MLP 0.7515、CIF 0.5956 之后)，是树模型中性能最好的传统模型之一，明显优于其提升树对手。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 $Y_SCALE = 1e6$ (`config.json` "y_scale": 1000000) , Optuna trial 值与最终训练评估均为缩放单位。

超参数与调优

Optuna 50 轮 $\times$ 5 折 CV (TPE 采样器 + MedianPruner) , 最优试验 (Trial 48, CV RMSE = 1.1080, 缩放单位) :

参数	值
n_estimators	1827
max_depth	21
min_samples_split	7
min_samples_leaf	1
max_features	log2
bootstrap	False

调优过程观察: - 搜索从 Trial 0 (1.378) 快速收敛: Trial 12 (1.155) $\rightarrow$ Trial 27 (1.136) $\rightarrow$ **Trial 48 (1.1080)** , 收敛轨迹平稳。 - 最优解取 `bootstrap=False` (全样本训练) 配合 `max_features='log2'` (强随机特征子空间) ——这种“**不放回抽样 + 强特征随机化**”的组合有效增大树间差异, 同时避免小样本下 bootstrap 的重复样本浪费。 - `min_samples_leaf=1` (叶节点不设最小样本) 使树充分生长, 靠集成平均抑制方差; `min_samples_split=7` 提供适度分裂约束。 - 50 轮中 5 轮被 MedianPruner 剪枝; 单轮 5 折 CV 平均约 2 秒, 全程约 2 分钟, 成本极低。

训练过程

- **调参阶段**: 50 轮 Optuna, 最优 Trial 48 的 CV RMSE = 1.1080 (缩放单位) 。
- **最终训练**: 以 Trial 48 参数在 549 条数据上训练 (RF 无早停, 定长 1827 棵树后直接输出测试评估) , $Test R^2 = 0.4621$ 。


注意：Gamma_max 下 Optuna trial 值均为缩放单位（约 1.0 量级）；RF 的 best_cv_rmse (1.1080) 在 metrics.json 中仍为缩放单位（未 $\div 1e6$ ），与日志 Best-trial 值一致。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.4621
参考 CV RMSE (Optuna 最优, 缩放单位)	1.1080

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000)，评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000；R² 无量纲，是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致 (cif/histgb/ngboost/rf 等仍为缩放单位，本脚本为 1.1080)，因此本报告以日志中 Optuna Best-trial 值（缩放单位，约 1.0 量级）作为 CV 参考。

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test R² = 0.4621，解释了目标方差的约 46%，仅次于 MLP 与 CIF。RF 的方差控制特性在本 target 上表现突出——同样面对 522 维特征的小样本，RF 的过拟合程度明显轻于梯度提升类模型。

特征重要性 (Top 20)


日志输出 Top-20 特征重要度 (杂质减少口径), 数值全部显示为 0.0 (RF 对缩放后 y 的杂质减少量级极小被四舍五入, 属于**展示问题**, 排序仍可信)。Top-5:

1. `atom_mean_17` (度数 = 1 原子占比均值)
2. `atom_std_17` (度数 = 1 分布标准差)
3. `atom_std_35` (原子质量标准差)
4. `atom_std_16` (度数 = 0 分布标准差)
5. `atom_mean_54` (重原子邻居数 / 4 均值)


紧随其后: `MolWt`、`atom_mean_38` (显价 = 1)、`atom_mean_26` (隐氢数 = 3)、`atom_std_26`、`atom_mean_16` (度数 = 0)、`atom_mean_20` (度数 = 4)、`atom_mean_18` (度数 = 2)、`atom_std_20`、`atom_mean_46` (Gasteiger 电荷) 等。

物理分析: RF 的重要性画像**高度集中于碳骨架拓扑**——度数 = 0/1/2/4 的均值与标准差占据 Top-20 的半壁江山, 配合原子质量 (`atom_std_35`)、重原子邻居 (`atom_mean_54`) 与 `MolWt`, 指向“**疏水碳链的长度、支化度与分子尺寸**”对最大表面超量的主导作用。这与 Gamma_max 的物理直觉一致: 尾链越长、支化越复杂, 界面堆积密度与吸附行为变化越显著。RF 对芳香性 (AtomMean 33) 与极性头基 (head_ratio) 的依赖弱于 HistGB/LightGBM, 体现其“尺寸/拓扑优先”的归纳偏好。


SHAP 图组由 `shap_rf.py` (TreeExplainer) 生成:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: atom_mean_17、atom_std_35、MolWt 等位居前列。



Top-1 SHAP 依赖图：度数 = 4（高支化）原子占比（atom_mean_20）对预测的边际效应及其与交互特征的分布。

结论与评价

优点： - Test $R^2 = 0.4621$ 排名第 3，是树模型中的优秀者，仅逊于同门的 ExtraTrees (CIF) 与深度模型 MLP。 - 方差控制出色： `bootstrap=False + max_features='log2'` 的随机化组合在小样本高维特征上泛化稳健，过拟合明显轻于梯度提升树。 - 调参成本极低（约 2 分钟），特征归因完备（pred_vs_true + SHAP 图组）。

不足： - 精度仍明显低于 MLP (0.7515) 与 CIF (0.5956)。 - 日志重要度数值显示异常（全 0.0），精确归因需依赖 SHAP 补充。 - 原始 RMSE/MAE 因目标量级太小失去判别意义，只能依赖 R^2 评价。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
1	MLP	0.7515
2	CIF (ExtraTrees)	0.5956
3	RandomForest	0.4621
4	LightGBM	0.3413
5	CatBoost	0.3308

RF 以极低成本取得树模型第二好的成绩（仅次于 ExtraTrees），其“尺寸/拓扑主导”的特征画像与稳健泛化使其成为 Gamma_max 上一个值得保留的**基线与交叉验证模型**；若追求更高精度则应选用 CIF 或 MLP。