

Gamma_max Transformer 模型报告

Transformer 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_transformer_20260805_202831
运行时间	20:28:31 ~ 20:35:56 (约 7.5 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

Transformer 采用 **3 层 Transformer Encoder** (d_model=128、4 头注意力、FFN 256、GELU 激活), 与 RNN 相同, 将 522 维特征向量重塑为 (batch, 522, 1) 的序列输入, 通过**自注意力机制**建模特征维度间的依赖关系, 末层池化后映射为 Gamma_max。训练使用 CosineAnnealingLR 学习率调度与梯度裁剪 (grad_clip=5.0)。

在 Gamma_max 任务中, Transformer 的 Test R² = 0.1086, 在 10 个模型中排名第 9 (仅优于 RNN -0.01), 是所有深度模型中表现次差者。相比其在 pCMC 任务中的 R² 0.6951, 本 target 上大幅崩坏。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (**549 训练 + 79 验证**) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **训练缩放**: 训练脚本对 y 乘以 $Y_SCALE = 1e6$ (`config.json` "`y_scale`": `1000000`) , 验证与测试评估均为缩放单位。

超参数与调优

Transformer 使用**固定架构, 不经过 Optuna**:

参数	值
d_model	128
Encoder 层数	3
注意力头数	4
FFN 维度	256
激活	GELU
dropout	0.1
learning_rate	1e-3
weight_decay	1e-5
batch_size	16
训练轮数	500 (早停触发于 epoch 160)
调度器	CosineAnnealingLR
梯度裁剪	5.0

固定超参 + 小 batch (16) + 单头规模 128, 整体容量与训练策略均未针对 Γ_{max} 优化。

训练过程

日志记录每 5 轮的验证 RMSE (缩放单位) , **收敛极弱、近乎停滞**:

Epoch	Val RMSE	备注
5	3.5479 (best 3.5479)	初始
10	2.0996 (best 2.0996)	快速触底
50	2.1164	此后反复在 2.10~2.24 波动
100	2.1286	无下降
155	2.2219	回升
160	2.2364	早停触发

关键观察： - epoch 10 即达到 best val RMSE = 2.0996，此后 **130 轮内最优值从未被刷新**——模型在验证集上无任何实质学习，早停在 epoch 160 触发。 - **2.10 接近目标缩放后的标准差量级 (~2.13)**：Transformer 同样基本退化为“预测常量均值”，Test R² 仅 0.1086 正源于其对均值附近分布的微弱偏置。 - 相比 pCMC 任务（395 轮收敛至 0.5501），本任务上注意力机制完全未能提取特征间的有效依赖。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.1086
Best val RMSE (缩放单位)	2.0996

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000)，评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 ~1e-6 mol/m² 被压成 0.0000；R² 无量纲，是唯一可信指标。Transformer 不使用 Optuna，metrics.json 无有效 best_cv_rmse，故以日志 Best val RMSE (缩放单位) 作为参考。

说明：本次 Transformer 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（深度模型训练脚本不输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

Test $R^2 = 0.1086$ ，仅解释了目标方差的约 11%，与 RNN 同属“预测均值级”失败（RNN 为 -0.01 ，Transformer 略好）。两个序列式深度模型在 Gamma_max 上双双崩溃，而全连接 MLP 却以 0.7515 登顶——深度模型路线的成败完全取决于架构与特征形态是否匹配。

特征重要性

Transformer 依赖注意力权重，但日志未输出注意力归因。其自注意力会为 522 个特征维度计算两两关联，理论上可做可解释性分析（attention rollout），但本项目未生成相应图。鉴于模型在本任务上近乎失效（ $R^2 \approx 0.11$ ），其特征级解释的参考价值有限。可推断其失败根源与 RNN 相同：522 维异构特征**无自然序列关系**，自注意力在“伪时间步”上建立的依赖缺乏物理意义，且 Transformer 参数量大、对 549 条小样本更易欠拟合/不收敛。

结论与评价

- 优点：** - 作为注意力机制的探索性 baseline，进一步印证了“序列化 + 自注意力”路线在本任务的**不适用性**。 - 训练约 7.5 分钟，早停及时止损。
- 不足：** - **性能垫底级**：Test $R^2 = 0.1086$ ，排名第 9，仅优于 RNN；best val（2.0996）接近目标标准差，近乎预测均值。 - 收敛极弱：epoch 10 即触底、此后 130 轮零进步，早停结束训练。 - 与 RNN 相同的结构性问题：522 维异构特征**无自然时序关系**；Transformer 强项在长程依赖与大规模预训练，本任务小样本 + 无意义序列恰好落在其盲区。

横向定位（10 个模型中按 Test R^2 降序）：

排名	模型	Test R^2
7	XGBoost	0.2821
8	HistGB	0.1851
9	Transformer	0.1086
10	RNN	-0.01

方法论结论： 三个深度模型（MLP 0.7515 / Transformer 0.1086 / RNN -0.01 ）在 Gamma_max 上的排序进一步强化了 pCMC 任务的结论——对 522 维 PharmHGT 扁平特征，**全连接（MLP）** $\gg$ **注意力（Transformer）** $\gg$ **循环**

(LSTM)。Transformer 在本 target 上应被排除出生产预测方案；若未来引入图结构 (AttentiveFP) 等有内在依赖的分子表示，方可重新评估注意力路线的价值。