

Gamma_max XGBoost 模型报告

XGBoost 模型报告 — Gamma_max 预测

报告信息

项目	内容
目标变量	Gamma_max (最大表面超量, 单位 mol/m ² , 量级 ~1e-6)
运行目录	runs\Gamma_max\Gamma_max_xgboost_20260805_204250
运行时间	20:42:50 ~ 21:06:20 (约 24 分钟, 含 200 轮 Optuna + Top-K 筛选 + 最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

XGBoost 是陈天奇提出的梯度提升框架, 以其对**二阶泰勒展开**、稀疏感知与列块并行的实现著称。本项目为 XGBoost 配置了**全模型最复杂的调参管线**: 200 轮 Optuna × 5 折 CV (CV 样本 565), 配合 **Top-K holdout 泛化性筛选** (独立 holdout 63 样本 + 训练-验证差距惩罚, 防止过拟合的“虚高”参数被选中)。

在 Gamma_max 任务中, XGBoost 的 Test R² = 0.2821, 在 10 个模型中排名第 7 (MLP、CIF、RF、LightGBM、CatBoost、NGBoost 之后)。尽管调参管线最严谨, 其性能仍处于中下游, 说明对 Gamma_max 而言正则化复杂的树模型并不占优。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 628 条 (549 训练 + 79 验证) , 测试集 70 条; 调参阶段进一步划分 **CV 565 / Holdout 63**, 最终模型在 565 条上训练。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

Optuna 200 轮 × 5 折 CV (multivariate TPE + gap 惩罚) , Top-5 候选在 holdout 上复评后选中最优参数:

参数	值
n_estimators	2050
max_depth	12
learning_rate	0.0199
subsample	0.802
colsample_bytree / bylevel / bynode	0.708 / 0.797 / 0.938
min_child_weight	1.112
gamma	0.422
reg_alpha / reg_lambda	1.0e-4 / 2.2e-4
max_delta_step	0.686
booster	gbtree

Optuna 参数重要度:

参数	重要度
min_child_weight	0.3041
gamma	0.2096
max_delta_step	0.1400
colsample_bynode	0.0933
colsample_bytree	0.0714
其余 (lr / colsample_bylevel / max_depth 等)	< 0.05

参数重要度显示 **min_child_weight** (叶节点最小样本权重) 与 **gamma** (分裂最小损失增益) 合计 **0.51** 主导——与 pCMC 任务“gamma 独大”不同，本任务中叶节点样本量约束与增益阈值共同承担过拟合压制。最终选中 `booster='gbtree'` (而非搜索中频繁出现的 `dart`)，Top-K holdout 复评表明 `gbtree` 在独立验证集上泛化更稳。

训练过程

- **调参阶段**：200 轮 Optuna 从 Trial 0 (1.151) 逐步收敛，Top-5 候选的 CV RMSE 落在 [0.9929, 1.0255] (缩放单位)；经 63 样本 holdout 复评，选中 holdout R² 最高 (0.5766) 的参数组合。
- **最终训练**：以选中参数在 565 条样本上训练 (无早停重复，`gbtree` 定长迭代)，测试集评估输出 Test R² = 0.2821。


注意：Gamma_max 下 Optuna trial 值均为缩放单位 (约 1.0 量级)；holdout RMSE 与 Test RMSE 因目标量级 ~1e-6 被压成 0.0000，holdout R² 无量纲可信 (最优 0.5766)。

测试结果

指标	值
Test RMSE	0.0000 *
Test MAE	0.0000 *
Test R ²	0.2821
参考 CV RMSE (Optuna 最优, 缩放单位)	0.9929

* 训练脚本对 y 乘以 1e6 (config 中 y_scale=1000000)，评估回到原始单位后取 4 位小数，原始 RMSE/MAE 量级 $\sim 1e-6$ mol/m² 被压成 0.0000；R² 无量纲，是唯一可信指标。metrics.json 的 best_cv_rmse 跨脚本不一致（本脚本已 $\div 1e6$ 为 0.0），因此本报告以日志中 Optuna Best-trial 值（缩放单位，约 1.0 量级）作为 CV 参考。

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test R² = 0.2821，仅解释了目标方差的约 28%。选中的 gbtrees 参数在 holdout 上 R² 达 0.5766，但测试集回落明显，说明 Top-K 筛选的“泛化最优”参数在测试集上仍有差距，模型对 Gamma_max 的拟合能力整体有限。

特征重要性 (Top 20)

日志输出的 Top-20 特征重要度数值**全部接近 0.0** (0.1 / 0.0)，与 pCMC 任务中 XGBoost 的重要性展示问题一致 (weight 口径输出异常，属于日志展示缺陷)；但排序仍指示有效信息，Top-5：

1. **atom_max_20** (0.1)：原子度数 = 4 (季碳/高支化) 的最大值
2. **maccs_112** (0.1)：MACCS 结构键 bit 112
3. **atom_max_54** (0.1)：重原子邻居数 / 4 的最大值
4. **atom_std_20** (0.0)：度数 = 4 的分布标准差
5. **atom_mean_20** (0.0)：度数 = 4 的占比均值

紧随其后：**bond_mean_12**、**maccs_105**、**AroRings**、**atom_max_35** (原子质量)、**atom_std_16**、**NumRings** 等。

物理分析：靠前的度数 = 4 原子 (**atom_max_20** / **atom_mean_20**)、重原子邻居 (**atom_max_54**) 与环/芳香结构 (**AroRings**、**NumRings**、**MACCS 键**) 共同指向**疏水骨架的分支度与环结构**——这与最大表面超量受疏水部分界面堆积行为

影响吻合。若要精确归因，应改用 `shap_xgboost.py` 的 SHAP 分析 (TreeExplainer) 补充；本次 Gamma_max 运行**未生成 SHAP 图**。

结论与评价

优点： - 调参管线最严谨：200 轮 + Top-K 泛化筛选 + gap 惩罚，参数选择可信度高、过拟合风险被主动压制。 - holdout 复评选中 gbtree 而非 dart，体现数据驱动的选择逻辑；参数重要度 (min_child_weight + gamma 合计 0.51) 给出清晰的正则方向。 - 运行高效：200 轮 Optuna 全程仅约 24 分钟。

不足： - Test $R^2 = 0.2821$ 仅列第 7，与其在 pCMC 任务中第 3 名的表现相比大幅下滑，复杂的调参管线未能在本目标转化为精度优势。 - 测试 R^2 (0.2821) 显著低于 holdout R^2 (0.5766)，泛化存在落差。 - 特征重要性输出异常 (全近 0)，且本次未生成 SHAP 图，可解释性文档化受限。

横向定位 (10 个模型中按 Test R^2 降序)：

排名	模型	Test R^2
5	CatBoost	0.3308
6	NGBoost	0.3191
7	XGBoost	0.2821
8	HistGB	0.1851
9	Transformer	0.1086

XGBoost 处于中下游，仅优于 HistGB 与 Transformer。其最严谨的调参管线在本 target 上并未带来领先，说明 Gamma_max 的相关结构更依赖模型归纳偏置 (如 MLP 的非线性组合) 而非调参强度；XGBoost 适合作为**调参基线**与过拟合防控的参照系。