

pC20 CatBoost 模型报告

CatBoost 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_catboost_20260806_104441
运行时间	10:44 ~ 12:04 (约 80 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CatBoost 是 Yandex 提出的梯度提升框架, 以**对称树 (oblivious tree)**、**有序提升 (Ordered Boosting)** 对类别特征的原生支持著称。在本项目 522 维全数值特征下, 其有序提升天然抑制预测偏移, 配合 Optuna 50 轮 $\times$ 5 折交叉验证调参。

在 pC20 任务中, CatBoost 的 $\text{Test } R^2 = 0.7237$ 、 $\text{Test RMSE} = 0.6276$, 在 10 个模型中排名第 2, 仅落后最优 MLP (0.8127), 是**树模型中的最优者**。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 刻画分子在界面上的“高效性”, 其预测价值与疏水尾结构强相关。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征。本模型是 pC20 target 的**首个运行**, 日志显示 [Cache MISS] Computing features... (564/564 训练分子、70/70

测试分子全部有效)，特征计算完成后写入缓存

data/features/surfpro/pC20/，供后续模型复用。

- **数据规模**：训练池 564 条（493 训练 + 71 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner）。

最优试验（Trial 15, CV RMSE = 0.5527）：

参数	值
depth	7
learning_rate	0.0327
iterations	2023
l2_leaf_reg	5.3555
random_strength	6.3216
bagging_temperature	0.2091
border_count	140
one_hot_max_size	17
leaf_estimation_iterations	3
min_data_in_leaf	38

Optuna 参数重要度：

参数	重要度
random_strength	0.3798
l2_leaf_reg	0.2597
iterations	0.0813
learning_rate	0.0732
one_hot_max_size	0.0589
depth	0.0539
其余 (min_data_in_leaf 等)	< 0.06

参数重要度显示 **random_strength (随机强度)** 与 **l2_leaf_reg (叶子 L2 正则)** 合计贡献约 **0.64**，是决定 pC20 预测质量的两大因素——两者共同抑制分裂随机性与叶子过拟合，说明 522 维特征上的树模型依旧对正则敏感。最优解 depth=7 (中等深度)、iterations=2023、lr=0.0327 的组合体现了“足够深但不过分”的取舍，与 pCMC 任务中的 CatBoost 结论一致。


训练过程

- **调参阶段**：50 轮 Optuna 中 21 轮被剪枝。最优 Trial 15 (CV RMSE 0.5527) 在早期即建立优势，此后 Trial 13 (0.5574)、Trial 36 (0.5549)、Trial 44 (0.5541) 多次逼近但均未超越，搜索在深度 7、lr≈0.03 附近收敛稳定。
- **最终训练**：以最优参数在 493 条数据上训练，**过拟合检测器在第 150 轮等待后触发早停** (Stopped by overfitting detector)，bestTest = 0.5479660 出现在 **bestIteration = 1066**，模型收缩至前 1067 轮迭代——最终实际用于预测的树数与调参设定的 2023 相比被大幅截断，有效抑制了过拟合。

测试结果

指标	值
Test RMSE	0.6276
Test MAE	0.4220
Test R ²	0.7237
Best CV RMSE	0.5527

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (0.6276) 高于调参 CV (0.5527) 约 0.075, 且 Test R² (0.7237) 明显低于 CV 隐含水平, 存在一定**调参-测试口径差距**——这与 pC20 训练池仅 564 条、测试集仅 70 条有关, 小样本下测试波动被放大。Test MSE = 0.3939 与之印证。

特征重要性 (Top 20)


日志输出的 Top-20 特征重要度:

1. **HeavyAtoms** (重原子数) 5.0
2. **MolWt** (分子量) 4.4
3. **LogP** (脂水分配系数) 3.8
4. **TPSA** (极性表面积) 1.7
5. **atom_mean_46** 1.5
6. **atom_mean_35** 1.5
7. **atom_std_40** 1.5
8. **atom_std_54** 1.4
9. **atom_std_20** 1.3


10. brics_7 1.3

Top-3 均为**全局疏水性/尺寸描述符** (HeavyAtoms、MolWt、LogP) , 与 pC20 的物理机制高度吻合: pC20 衡量表面活性剂降低表面张力的效率, **疏水尾越长 (重原子越多、LogP 越高) , C20 越低、pC20 越大**。TPSA 与原子级特征 (atom_mean_35 等) 次之, 说明极性与局部电子结构对界面效率也有调节作用。

SHAP 分析 (TreeExplainer) 给出了更精确的归因:



SHAP 蜜蜂图: 每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、HeavyAtoms、MolWt 位列前三, 与重要度排序一致。

结论与评价

优点: - **树模型最优:** $R^2 = 0.7237$, 在 10 个模型中排名第 2, 是除 MLP 外精度最高的模型。 - 有序提升 + 早停 + 强正则 (l2_leaf_reg、random_strength), 对 522 维小样本任务过拟合控制到位。 - 调参稳定: 最优解收敛明确, 21 轮被剪枝佐证搜索高效。

不足: - 调参成本高 (约 80 分钟), 为所有模型中最长之一 (Optuna 50 轮 $\times$ 5 折 + CatBoost 训练偏慢)。 - 相对最优 MLP (0.5168 / 0.8127) 仍有约 0.11 的 RMSE 差距, 未登顶——pC20 是深度模型胜出的 target。 - 调参 CV (0.5527) 与测试 (0.6276) 存在约 0.075 的差距, 小样本下测试波动明显。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
1	MLP	0.5168	0.8127
2	CatBoost	0.6276	0.7237
3	CIF (ExtraTrees)	0.6422	0.7108
4	XGBoost	0.6498	0.7039

CatBoost 以树模型最优的成绩紧追 MLP，是**追求可解释性时的首选**；其 SHAP 归因与 Top-20 重要度共同确认了疏水性/尺寸描述符对 pC20 的主导作用。若可接受黑盒模型，MLP 精度更高；若需兼顾稳健与可解释，CatBoost 是最佳折中。