

pC20 CIF (ExtraTrees) 模型报告

CIF 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C_{20})$)
运行目录	runs\pC20\pC20_cif_20260806_120523
运行时间	12:05 ~ 12:07 (约 2.5 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CIF (Conditional Inference Forest, 条件推断森林) 是基于 **Extremely Randomized Trees (极端随机树)** 思想的树集成模型: 在每棵树的节点分裂时 **随机抽取分裂阈值** 而非遍历最优切分点, 进一步降低单树相关性、抑制过拟合, 对小样本高维特征尤为稳健。本项目采用 Optuna 50 轮 $\times$ 5 折交叉验证, 搜索空间与 RandomForest 一致 (`n_estimators`、`max_depth`、`min_samples_split`、`min_samples_leaf`、`max_features`、`bootstrap`)。

在 pC20 任务中, CIF 的 $\text{Test } R^2 = 0.7108$ 、 $\text{Test RMSE} = 0.6422$, 在 10 个模型中排名第 3, 是**树模型中的第一梯队成员**。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 训练池仅 564 条, 极端随机化对这类小样本任务的方差抑制效果突出。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 564 条 (493 训练 + 71 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 46, CV RMSE = 0.5815) :

参数	值
n_estimators	273
max_depth	21
min_samples_split	9
min_samples_leaf	1
max_features	None (全部特征)
bootstrap	False

调优过程观察: - 最优解偏好 `max_features=None` (**每节点使用全部特征**) + `bootstrap=False` (**不重采样**) : CIF 的随机性主要来自阈值抽取, 因此无需再靠特征子集与重采样增熵——这与 RF 的 `log2` 配置形成鲜明对比, 体现了 CIF 算法特性。 - 调参呈现清晰的两段式收敛: Trial 0~21 在 0.77~1.02 区间挣扎, Trial 22 起跃升至 0.69, 随后 Trial 23→24→25→27 单调改善至 **0.6119 (Trial 27)** , Trial 46 再刷新至 0.5815——搜索后期仍有增益。 - 50 轮中 16 轮被剪枝 (32%) , 剪枝率适中, 说明参数空间有效区域较广。


训练过程

最终模型以最优参数 (273 棵树) 在 493 条数据上训练。与随机森林相同, CIF 无迭代式早停概念, 直接以完整森林输出; 训练耗时极短 (不足 1 分钟) 。

测试结果

指标	值
Test RMSE	0.6422
Test MAE	0.4610
Test R ²	0.7108
Best CV RMSE	0.5815


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.6422) 高于调参 CV (0.5815) 约 0.06，属于小测试集（70 条）下的正常波动，整体泛化良好。Test MSE = 0.4124 与之印证。

特征重要性（说明）

当前日志输出的 Top-20 特征重要度数值接近 0（仅 `maccs_77`=0.2 非零，其余全为 0.0），属于该脚本对重要性（默认口径）的输出展示缺陷，但排序仍指示 **maccs_77（药效团特征）高居第 1**，其后为 `NAtoms`、`MolWt`、`HeavyAtoms`、`LogP` 等疏水性/尺寸描述符与原子级统计特征——`maccs_77` 的突出地位在 CIF 的 SHAP 依赖图中同样可见。若要精确归因，应改用 `shap_cif.py` 的 SHAP 分析（TreeExplainer）。下方 SHAP 图即为该分析的实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *maccs_77*、*NAtoms*、*LogP* 位列前三, 药效团与疏水性/尺寸特征共同主导 *pC20*。

结论与评价

优点: - 精度第 3 ($R^2 = 0.7108$) , 与第 2 名 CatBoost (0.7237) 差距仅 0.013, 是**性价比最高的高精度树模型**。 - 调参成本极低 (约 2.5 分钟) , 50 轮调参 + 训练一气呵成。 - 极端随机化 + 全特征 + 不重采样的组合, 在小样本上方差抑制出色, 泛化稳健。

不足: - 相对最优 MLP (0.8127) 仍有约 0.10 的 R^2 差距, 未登顶。 - 特征重要性输出异常 (数值接近归零) , 可解释性文档化需依赖 SHAP 补充。 - 最优参数出现在倒数第 5 轮附近, 搜索后期仍有增益, 空间未被完全穷尽。

横向定位 (10 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
1	MLP	0.5168	0.8127
2	CatBoost	0.6276	0.7237
3	CIF (ExtraTrees)	0.6422	0.7108
4	XGBoost	0.6498	0.7039
5	RF	0.6644	0.6904

CIF 以**几乎最低的调参成本取得第一梯队精度**，是 pC20 任务上“快速高精度”的最佳折中：它在 10 个模型中成本最低的梯队（2.5 分钟）内给出了仅次于 MLP/CatBoost 的表现。若追求极致精度选 MLP，追求可解释性选 CatBoost，追求性价比则 CIF 是首选。