

pC20 HistGB 模型报告

HistGradientBoosting 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_histgb_20260806_120916
运行时间	12:09 ~ 12:29 (约 20 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

HistGradientBoosting (HistGB) 是 scikit-learn 基于 **Histogram 直方图算法** 的梯度提升实现, 与 LightGBM 同源但集成在 sklearn 生态, 支持内置的**验证集早停**与原生缺失值处理。本项目采用 Optuna 50 轮 $\times$ 5 折交叉验证, 对 learning_rate、max_iter、max_depth、max_leaf_nodes、min_samples_leaf、l2_regularization、max_bins 等参数联合搜索。

在 pC20 任务中, HistGB 的 Test $R^2 = 0.6116$ 、Test RMSE = 0.7441, 在 10 个模型中排名第 8, 处于中下游, 仅优于深度模型 RNN 与 Transformer。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 训练池仅 564 条, 对小样本的拟合要求较高。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载（[Cache HIT]），与其余模型一致。
- **数据规模**：训练池 564 条（493 训练 + 71 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner）。

最优试验（Trial 26, CV RMSE = 0.5976）：

参数	值
learning_rate	0.231
max_iter	740
max_depth	5
max_leaf_nodes	255
min_samples_leaf	5
l2_regularization	0.787
max_bins	164

调优过程观察： - 最优解偏好 **较浅树（max_depth=5） + 大学习率（0.231） + 大量叶子（255）**，依赖浅树 + 高 lr 的“快速拟合”策略，而非深层小步长。 - Trial 4（0.6100）→ Trial 11（0.6034）→ Trial 12（0.6011）→ Trial 17（0.5990）→ Trial 26（0.5976），CV 单调缓降，搜索稳定收敛。 - 50 轮中 **29 轮被剪枝（58%）**，占比为所有模型中最高——多数试验在早期即被 MedianPruner 判定无法超越当前最优，说明 522 维特征上 HistGB 的参数敏感度较高、无效区域大。


训练过程

最终模型以最优参数在 493 条数据上训练。HistGradientBoostingRegressor 采用**内置基于验证集的早停**（日志未输出具体 best iteration），训练自动在验证指标不再改善时截断。该模型未配置额外早停日志，属于 sklearn 内部机制，交付模型为验证最优状态。

测试结果

指标	值
Test RMSE	0.7441
Test MAE	0.5235
Test R ²	0.6116
Best CV RMSE	0.5976

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (0.7441) 明显高于调参 CV (0.5976) 约 0.15，是 10 个模型中测试-调参差距最大的之一，说明其在小测试集（70 条）上的泛化表现不及 CV 暗示的水平——浅树高 lr 配置在小样本上对分布偏移较敏感。Test MSE = 0.5537 与之印证。

特征重要性 (Top 20)


HistGB 采用 **permutation-based 置换重要度**（数值为对指标下降的贡献，含标准差），比其余模型的树内增益口径更稳健：

1. **LogP** (脂水分配系数) 0.2600 ± 0.0361
2. **HeavyAtoms** (重原子数) 0.1720 ± 0.0375
3. **MolWt** (分子量) 0.1553 ± 0.0329
4. **TPSA** (极性表面积) 0.0620 ± 0.0129
5. **atom_mean_54** 0.0586 ± 0.0297
6. **tail_ratio** (尾部碳比例) 0.0579 ± 0.0184
7. **atom_mean_35** 0.0556 ± 0.0124
8. **atom_std_35** 0.0528 ± 0.0197


9. atom_mean_25 0.0438 ± 0.0080
10. atom_mean_46 0.0378 ± 0.0099

Top-3 (LogP、HeavyAtoms、MolWt) 为全局疏水性/尺寸描述符，与 pC20 物理机制（疏水尾越长、界面效率越高）高度吻合，也与 CatBoost、LightGBM 等模型结论一致；tail_ratio 位列第 6，延续了 LightGBM 对“疏水尾占比”重要性的强调。TPSA 与 HBA（氢键受体）表明极性因素亦有一定贡献。

SHAP 分析 (TreeExplainer) 给出了更精确的归因：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、MolWt、HeavyAtoms 位列前三, 与置换重要度排序一致。

结论与评价

优点: - 采用 permutation-based 重要度, 比树内增益口径更稳健, 可解释性输出可信度高。 - sklearn 原生实现 + 内置早停, 接口统一、易集成。 - 调参收敛明确 (CV 从 0.61 单调降至 0.5976), 搜索过程稳定。

不足: - 精度仅第 8 ($R^2 = 0.6116$), 显著落后 MLP (0.8127) 与 CatBoost (0.7237), 处于中下游。 - Test (0.7441) 与 CV (0.5976) 差距约 0.15, 为所有模型最大之一, 小样本泛化压力明显。 - 剪枝率高达 58%, 参数空间大量无效区域, 说明浅树高 lr 策略在该任务上欠稳。

横向定位 (10 个模型中按 Test RMSE 排序):

排名	模型	Test RMSE	Test R ²
6	NGBoost	0.6652	0.6897
7	LightGBM	0.6919	0.6643
8	HistGB	0.7441	0.6116
9	RNN	0.8516	0.4913
10	Transformer	1.0480	0.2297

HistGB 在 pC20 上表现平庸：与同源的 LightGBM（0.6643）相比差距明显，主要受制于小样本下浅树高 lr 配置的泛化短板。作为 sklearn 生态的梯度提升默认选择，其**集成便利性**是主要价值；追求精度时应优先 MLP/CatBoost，追求速度可优先 LightGBM。