

pC20 LightGBM 模型报告

LightGBM 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_lightgbm_20260806_123004
运行时间	12:30 ~ 12:32 (约 2 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

LightGBM 是微软开源的梯度提升框架, 以 **Histogram-based 直方图算法** (将特征离散化为 bins)、**Leaf-wise 按叶子生长** 与原生稀疏支持著称, 训练速度通常为传统提升树的数倍。本项目采用 Optuna 50 轮 $\times$ 5 折交叉验证, 搜索空间同时覆盖 **gbdt 与 dart** 两种 boosting 方式。

在 pC20 任务中, LightGBM 的 Test $R^2 = 0.6643$ 、Test RMSE = 0.6919, 在 10 个模型中排名第 7, 处于中游。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 与 pCMC 强相关 ($r \approx 0.76$), 本任务训练池仅 564 条, 对模型的正则能力要求较高。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。

- **数据规模**: 训练池 564 条 (493 训练 + 71 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , boosting 方式在 gbdt / dart 间随机选择。

最优试验 (Trial 49, CV RMSE = 0.5869) :

参数	值
boosting_type	gbdt
max_depth	12
num_leaves	64
learning_rate	0.00855
n_estimators	1075
subsample / subsample_freq	0.928 / 4
colsample_bytree	0.697
reg_alpha / reg_lambda	7.6e-6 / 1.1e-6
min_child_samples	5
cat_smooth / cat_l2	43.9 / 13.7

调优过程观察: - 早期 Trial 0/1 表现极差 (CV RMSE 2.61 / 1.20) , 原因是 dart + 过深树 (depth 12) 组合在小样本上极度不稳定; **搜索迅速转向 gbdt + 中等叶子 (64 叶)** 的稳健配置。 - 最优 Trial 49 在**最后一轮**才被刷新 (50 轮末 CV 0.5869) , 说明搜索全程在 0.58~0.66 区间缓慢收敛, 缺乏单调下降趋势——小样本 (564) 下 LightGBM 的调参收益有限。 - 50 轮中仅 8 轮被剪枝; 单轮 5 折 CV 平均约 2 秒, LightGBM 是**调参成本最低的树模型** (全程约 2 分钟) 。

训练过程


最终模型以最优参数在 493 条数据上训练, LightGBM 内置早停 (验证集 50 轮不改善即停) , **best iteration = 531** (valid_0 RMSE = 0.59575) 。从收敛曲线看, 验证 RMSE 在 400 轮左右进入平台期 (0.5995 → 0.5958) , 随后早停在

531 轮截断，未过度训练。

测试结果

指标	值
Test RMSE	0.6919
Test MAE	0.4882
Test R ²	0.6643
Best CV RMSE	0.5869

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (0.6919) 高于调参 CV (0.5869) 约 0.105，是 10 个模型中测试-调参差距较大的之一，反映小测试集（70 条）下的波动以及 LightGBM 在小样本上的泛化压力。Test MSE = 0.4787 与之印证。

特征重要性 (Top 20)


日志输出的 Top-20 特征重要度 (gain 口径)：

1. **MolWt** (分子量) 1586
2. **tail_ratio** (尾部碳比例) 1254
3. **LogP** (脂水分配系数) 1254
4. atom_mean_35 1028
5. atom_std_54 759
6. atom_std_25 747
7. atom_mean_54 717
8. RotBonds 708


9. atom_mean_41 661
10. atom_std_35 639

Top-3 中 **tail_ratio** 高居第 2 是 LightGBM 区别于其余模型的最大特色——该特征直接刻画表面活性剂疏水尾占比，是 pC20 物理机制（疏水尾越长、界面效率越高）的最直接编码。MolWt、LogP、RotBonds 等疏水性/尺寸描述符整体靠前，与 CatBoost、RF 等模型结论一致。

SHAP 分析 (TreeExplainer) 给出了更精确的归因：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、LogP、maccs_77 位列前三, 其中 maccs_77 为代表的药效团特征亦有贡献。

结论与评价

优点: - 调参成本全模型最低: 全程约 2 分钟, 50 轮调参 + 最终训练一气呵成, 性价比极高。 - Leaf-wise 生长 + gbd 稳健配置, 早停机制成熟, 训练过程稳定。 - Top-20 重要度揭示 **tail_ratio** 的关键作用, 为 pC20 物理机制提供了与其余模型互补的证据。

不足: - 精度仅第 7 ($R^2 = 0.6643$), 明显落后 MLP (0.8127) 与 CatBoost (0.7237), 处于中游。 - Test (0.6919) 与 CV (0.5869) 差距约 0.105, 为所有模型最大之一, 小样本下泛化压力明显。 - 调参曲线收敛缓慢 (最优出现在最后一轮), 说明参数空间未完全稳定。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R²
5	RF	0.6644	0.6904
6	NGBoost	0.6652	0.6897
7	LightGBM	0.6919	0.6643
8	HistGB	0.7441	0.6116
9	RNN	0.8516	0.4913

LightGBM 在 pC20 上表现中规中矩：若以“秒级调参 + 可接受精度”为目标，它是首选；但追求精度时应优先 MLP/CatBoost。其 tail_ratio 特征的高重要度提示，pC20 预测中“疏水尾占比”这类直接物理量应被后续模型充分保留。