

pC20 MLP 模型报告

MLP 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_mlp_20260806_130514
调参日志	runs\pC20\pC20_mlp_tuning_20260806_123326\train.log
运行时间	调参 12:33 ~ 13:05 (约 32 分钟), 最终训练 13:05:14 ~ 13:05:25
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

MLP (多层感知机) 是 10 个模型中唯一的**前馈全连接深度网络** (RNN/Transformer 为序列式深度模型)。架构为 Linear $\rightarrow$ BatchNorm $\rightarrow$ GELU $\rightarrow$ Dropout 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 pC20 任务中, MLP 的 Test $R^2 = 0.8127$ 、Test RMSE = 0.5168, **在 10 个模型中排名第 1, 是 pC20 的最优模型**——这是本项目少有的深度模型全面胜出的 target。它同时验证了 pC20 结构-活性关系中存在树模型难以捕捉的非线性结构。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载, 与其余模型一致。
- **数据规模**: 训练池 564 条 (493 训练 + 71 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。这是深度模型中唯一使用 Optuna 的 (RNN/Transformer 用固定架构) 。

最优试验 (Trial 3, CV RMSE = 0.5062) :

参数	值
n_layers	4
hidden_dim	659
dropout	0.0232
activation	relu
learning_rate	0.00703
weight_decay	6.73e-4
batch_size	107
Best CV RMSE	0.5062

调优过程观察: - Trial 0/1 表现极差 (CV RMSE 1.42 / 2.63) , 原因是学习率过低 ($1.5e-5$ / $3.5e-5$) 导致欠拟合; **搜索快速收敛到 $lr \in [0.001, 0.009]$ 的合理区间。** - 最优解显著偏好 **relu/leaky_relu 激活 + 中等隐藏层 (400~700) + 4 层左右**的结构, dropout 较低 (0.02) 以充分拟合仅有 564 条样本的任务。 - 最优 Trial 3 在 50 轮中一骑绝尘 (CV RMSE 0.5062) , 其后仅有 Trial 25 (0.5096) 、 Trial 33 (0.5081) 、 Trial 40 (0.5090) 等逼近, 整体搜索稳定、无过拟合于调参集。 - 50 轮中 20 轮被剪枝, 占比 40%; 后期大量试验因无法超过当前最优被早停, 说明搜索后期已收敛。

训练过程

最终模型以最优参数在 493 条数据上训练，**早停在 epoch 465 触发**（日志最终记录 `Epoch 300/3000 - Val RMSE: 0.5312 (best: 0.4742)`），最终最优验证 RMSE 提升至 **0.4625**）。网络需要数百个 epoch 才能收敛，但由于早停机制未出现过拟合蔓延；最终以验证最优权重（而非末轮权重）作为交付模型。

说明：最终训练与调参在同一脚本中连续执行（调参日志末尾包含最终训练段），`pC20_mlp_tuning` 目录即本次调参过程存档。

测试结果

指标	值
Test RMSE	0.5168
Test MAE	0.3804
Test R ²	0.8127
Best CV RMSE	0.5062
Best val RMSE	0.4625

说明：本次 MLP 运行**未生成** `pred_vs_true` 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用 `train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (0.5168) 与 CV (0.5062) 相当，且明显优于验证 RMSE (0.4625) 口径外的表现，泛化良好。Test MSE = 0.2671 与之印证。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因（`shap_mlp.py` 路径下可生成，但本次 pC20 运行未生成 SHAP 图）。基于其余模型的一致性结论，可推断其预测主要由 LogP、HeavyAtoms、MolWt、NAtoms 等全局疏水性/尺寸描述符驱动——这与 pC20（疏水尾越长、界面效率越高）的物理机制吻合。

结论与评价

优点： - **pC20 最优模型**： $R^2 = 0.8127$ 、RMSE 0.5168，排名第 1，且较第 2 名 CatBoost (0.7237) 领先近 0.09 个 R^2 ，优势明显。 - 使用 Optuna 充分调参 (vs 固定架构的 RNN/Transformer)，超参选择有依据、结果可复现。 - 早停 + Dropout + weight_decay 三重正则，泛化稳健，Test 与 CV 指标吻合。

不足： - 调参成本不低 (约 32 分钟，虽低于 pCMC 任务的 90 分钟)，仍显著高于多数树模型。 - 黑盒模型，可解释性差；MAE (0.3804) 虽全模型最优，但绝对误差仍达 0.38 个 pC20 单位。 - 不提供不确定性估计 (对比 NGBoost)。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
1	MLP	0.5168	0.8127
2	CatBoost	0.6276	0.7237
3	CIF (ExtraTrees)	0.6422	0.7108

MLP 在 pC20 任务上以明显优势登顶，是**深度模型在此 target 胜出的关键证据**。RNN/Transformer 的垫底说明“能否胜出”取决于序列化方式与特征形态：MLP 以扁平 522 维整体输入，恰好契合手工特征的非序列本质；这也提示 pC20 的预测价值值得围绕 MLP 进一步挖掘。