

pC20 NGBost 模型报告

NGBost 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C_{20})$)
运行目录	runs\pC20\pC20_ngboost_20260806_133537
运行时间	13:35 ~ 14:50 (约 75 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

NGBost (Natural Gradient Boosting) 是斯坦福提出的**概率梯度提升**框架: 以自然梯度优化参数分布 (默认 Normal 分布), 最终**同时输出预测均值与方差 ($\text{mean} \pm \text{std}$)**, 为每个分子提供不确定性估计——这是其余模型不具备的能力。与 pCMC 任务不同, 本 target 的 NGBost 采用 **Optuna 50 轮 $\times$ 5 折交叉验证调参** (pCMC 时为预调优固定参数)。

在 pC20 任务中, NGBost 的 Test $R^2 = 0.6897$ 、Test RMSE = 0.6652, 在 10 个模型中排名第 6, 处于中上游。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 训练池仅 564 条, 概率输出在数据稀缺场景下对不确定性的刻画尤显价值。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 564 条 (493 训练 + 71 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) , 搜索 `n_estimators`、`learning_rate`、`minibatch_frac`、`max_depth`、`min_samples_leaf` 与 `score_rule` (LogScore / CRPScore) 。

最优试验 (Trial 32, CV RMSE = 0.5775) :

参数	值
<code>n_estimators</code>	1592
<code>learning_rate</code>	0.0385
<code>minibatch_frac</code>	0.795
<code>max_depth</code>	7
<code>min_samples_leaf</code>	5
<code>score_rule</code>	LogScore

调优过程观察: - 早期 Trial 0~4 表现差 (CV 0.64~0.92) , **CRPScore 的所有试验均明显劣于 LogScore**, 最优解最终收敛于 LogScore 分数规则——LogScore (对数似然) 在小样本下对分布拟合更稳定。 - Trial 10 (0.5839) 确立领先, Trial 21 (0.5828) 、 Trial 30 (0.5826) 、 Trial 32 (0.5775) 逐步改善, 搜索在 `max_depth=7`、`lr`≈0.03 附近收敛。 - 50 轮中 **28 轮被剪枝 (56%)** ; 单轮 5 折 CV 平均约 1.5 分钟, **NGBoost 调参成本 (约 75 分钟) 为所有树模型中最高的**——自然梯度更新在 522 维特征上开销巨大。

训练过程


最终模型以最优参数 (1592 棵) 在 493 条数据上训练, 训练损失从 [iter 0] `loss=1.5808` 单调下降至 [iter 1500] `loss=-2.9181` , 收敛平稳; NGBoost 内置学习率衰减 (`scale` 从 1.0 逐段降至 0.0625) 。测试阶段输出 **Normal 分布**

(mean ± std) , 平均预测标准差 = 0.0172——远小于 Test RMSE (0.6652) , 说明模型对自身预测高度自信, 这在小样本上可能低估真实不确定性。

测试结果

指标	值
Test RMSE	0.6652
Test MAE	0.4741
Test R ²	0.6897
Best CV RMSE	0.5775


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.6652) 高于调参 CV (0.5775) 约 0.088, 小测试集 (70 条) 下的波动与概率分布校准不足共同导致了该差距。Test MSE = 0.4425 与之印证。

特征重要性

当前日志未输出 Top-20 特征重要度 (脚本报告 `unexpected shape (2, 522), skipping` , 因 NGBoost 对均值与方差各维护一组参数, 重要性数组形状为 (2, 522) 而被跳过) 。精确归因需依赖 `shap_ngboost.py` 的 SHAP 分析。下方 SHAP 图为该分析的实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、MolWt、RotBonds 位列前三, 与其余树模型结论一致 (疏水性/尺寸主导 pC20)。

结论与评价

优点: - **唯一提供不确定性估计的模型:** 输出 Normal 分布 ($\text{mean} \pm \text{std}$), 可为高/低置信度分子的筛选提供依据, pC20 数据稀缺场景下尤具价值。 - 精度第 6 ($R^2 = 0.6897$), 处于中上游, 与 RF (0.6904) 几乎持平。 - 采用 Optuna 充分调参 (vs pCMC 任务的固定参数), 且明确揭示 **LogScore 优于 CRPScore** 的结构性结论。

不足: - 调参成本最高 (约 75 分钟), 为所有树模型中唯一需要“小时级”调参的。 - 平均预测标准差 (0.0172) 远小于 Test RMSE (0.6652), 概率分布严重欠校准, 不确定性估计目前参考价值有限。 - 特征重要性无法直接从日志输出, 需依赖 SHAP 补充。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R²
4	XGBoost	0.6498	0.7039
5	RF	0.6644	0.6904
6	NGBoost	0.6652	0.6897
7	LightGBM	0.6919	0.6643
8	HistGB	0.7441	0.6116

NGBoost 的精度 (0.6897) 与 RF 几乎一致，但**调参成本高出 30 倍**，纯精度视角下性价比低。其价值在于**不确定性输出的独特性**——在 pC20 这类小样本、高风险预测场景，若后续能校准概率分布（如温度缩放、共形预测），NGBoost 将从“第 6 名模型”转化为“可信度最高的预测工具”。