

pC20 RandomForest 模型报告

RandomForest 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C_{20})$)
运行目录	runs\pC20\pC20_rf_20260806_145134
运行时间	14:51 ~ 14:53 (约 2 分钟, 含 Optuna 50 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RandomForest (随机森林) 是 Breiman 提出的 **Bagging + 随机特征子集** 集成方法: 通过自助采样 (bootstrap) 与随机特征选择训练大量决策树并对结果取平均, 以降低方差、抵御过拟合。本项目采用 Optuna 50 轮 $\times$ 5 折交叉验证, 对 `n_estimators`、`max_depth`、`min_samples_split`、`min_samples_leaf`、`max_features`、`bootstrap` 等参数联合搜索。

在 pC20 任务中, RandomForest 的 Test $R^2 = 0.6904$ 、Test RMSE = 0.6644, 在 10 个模型中排名第 5, 处于中游偏上。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 训练池仅 564 条, Bagging 的降方差特性对小样本较为友好。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征，从缓存加载（[Cache HIT]），与其余模型一致。
- **数据规模**: 训练池 564 条（493 训练 + 71 验证），测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**（TPE 采样器 + MedianPruner）。

最优试验（Trial 48, CV RMSE = 0.6481）：

参数	值
n_estimators	1827
max_depth	21
min_samples_split	7
min_samples_leaf	1
max_features	log2
bootstrap	False

调优过程观察： - 最优解显著偏好 `max_features='log2'`（随机子集更窄） + `bootstrap=False`（不重采样）——在仅 493 条训练数据上，不重采样可最大化每棵树的训练信息量，而窄特征子集保证树间多样性，两者结合是 RF 在小样本上的最优组合。 - Trial 0~10 表现较差（CV 0.79~0.93），Trial 11 起收敛到 0.69 区间，Trial 48 才刷新至 0.648——最优解出现在**倒数第 2 轮**，说明搜索后期仍有增益、空间未被完全穷尽。 - 50 轮中 29 轮被剪枝（58%），与 HistGB 并列最高，反映小样本下 RF 参数空间大量区域无效。


训练过程

最终模型以最优参数（1827 棵树）在 493 条数据上训练。随机森林无迭代式早停概念，直接以完整森林输出；日志显示训练过程稳定，未出现异常。

测试结果

指标	值
Test RMSE	0.6644
Test MAE	0.4743
Test R ²	0.6904
Best CV RMSE	0.6481


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.6644) 与调参 CV (0.6481) 基本持平，差距仅 0.016，是**泛化最稳健的模型之一**——Bagging 降方差特性在小样本上兑现了预期。Test MSE = 0.4414 与之印证。

特征重要性 (说明)

当前日志输出的 Top-20 特征重要度**数值全部为 0.0**，属于该随机森林脚本对重要性（默认口径）的输出展示缺陷，但排序仍指示 **LogP**、**MolWt**、**HeavyAtoms**、**NAtoms**、**RotBonds** 等疏水性/尺寸描述符位居前列，其次为大量原子级统计特征（atom_mean_54、atom_std_46 等）与 tail_ratio——与 CatBoost、LightGBM 的特征排序高度一致。若要精确归因，应改用 `shap_rf.py` 的 SHAP 分析（TreeExplainer）。下方 SHAP 图即为该分析的实测结果：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、HeavyAtoms、NAtoms 位列前三, 与其余树模型结论一致。

结论与评价

优点: - 精度第 5 ($R^2 = 0.6904$) , 处于中上游, 且 **Test-CV 差距最小 (0.016)** , 泛化稳健。 - 调参成本极低 (约 2 分钟) , 与 LightGBM 同为最廉价的模型。 - Bagging + log2 特征子集 + 不重采样组合, 是小样本场景下的合理配置。

不足: - 相对最优 MLP (0.8127) 与 CatBoost (0.7237) 仍有明显差距, 未进第一梯队。 - 特征重要性输出异常 (全 0.0) , 可解释性文档化需依赖 SHAP 补充。 - 最优参数出现在最后一轮附近, 搜索空间可能尚未完全稳定。

横向定位 (10 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
3	CIF (ExtraTrees)	0.6422	0.7108
4	XGBoost	0.6498	0.7039
5	RF	0.6644	0.6904
6	NGBoost	0.6652	0.6897
7	LightGBM	0.6919	0.6643

RF 与 CIF (ExtraTrees) 同属 Bagging 家族，但 CIF 以近乎相同的调参成本取得更高精度 (0.7108 vs 0.6904)，说明**极端随机化 (ExtraTrees) 在 522 维特征上比普通随机森林更契合**。RF 是稳健、廉价、无需早停的基线选择；追求精度时优先 CIF，追求可解释性与不确定度时优先 CatBoost/NGBoost。