

pC20 RNN-LSTM 模型报告

RNN (LSTM) 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C_{20})$)
运行目录	runs\pC20\pC20_rnn_20260806_145717
运行时间	14:57 ~ 14:59 (约 2 分钟, 固定架构 800 epoch 训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

RNN (LSTM, 长短期记忆网络) 是 10 个模型中三个深度模型之一。本项目将 **522 维特征向量重塑为序列 (batch, 522, 1)**, 把每个特征维度当作一个时间步输入 3 层 LSTM, 末层映射到单值输出——即“把特征当序列看”的序列式深度网络。与 MLP (扁平输入) 不同, LSTM 会沿特征维引入隐式的“顺序依赖”, 这与 522 维手工特征无天然顺序的本质存在错配。

在 pC20 任务中, RNN 的 Test $R^2 = 0.4913$ 、Test RMSE = 0.8516, 在 10 个模型中排名第 9, 仅优于 Transformer, 是 pC20 上表现不佳的深度模型之一。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- 数据规模**: 训练池 564 条 (493 训练 + 71 验证), 测试集 70 条。

- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **输入重塑**: 522 维 $\rightarrow$ (batch, 522, 1), 每维作为一个时间步。

超参数与调优

本模型采用**固定架构，不进行 Optuna 调参**（深度模型中的 RNN/Transformer 均如此），超参数直接给定：

参数	值
LSTM 层数	3
hidden_dim	64
learning_rate	1e-3
weight_decay	1e-5
batch_size	32
epochs	800

说明：与 pCMC 任务的 RNN 相同，本模型未搜索超参数空间。固定 64 维隐藏状态对 522 步序列而言容量偏小，无法充分捕捉特征间的非线性关系，这也是其精度受限的先天因素之一。

训练过程

模型在 493 条数据上训练 **800 个 epoch**（固定轮数，无早停）。收敛曲线缓慢而震荡：

- Epoch 0~150: Val RMSE 稳定在 1.141.15，几乎无改善；
- Epoch 200 起进入下降通道（0.96 $\rightarrow$ 0.93 $\rightarrow$ 0.90），期间多次反弹（如 Epoch 250 回升至 1.05）；
- Epoch 650~800: Val RMSE 从 0.763 逐步降至 **0.6843 (Epoch 800, 最后一个 epoch)**。

最优验证 RMSE 0.6843 出现在**最后一轮**，说明 800 epoch 恰好踩在模型能力边界附近——若训练更长，验证指标仍有改善空间；但也暗示序列式 LSTM 在 522 步长任务上收敛极慢、容量利用不充分。

测试结果

指标	值
Test RMSE	0.8516
Test MAE	0.5886
Test R ²	0.4913
Best val RMSE	0.6843

说明：本模型训练脚本**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（深度模型脚本无绘图输出）。如需可视化，可复用

`train_rnn_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (0.8516) 显著高于验证 RMSE (0.6843) 约 0.17，**过拟合迹象明显**——LSTM 在 522 步序列上记住了训练集的模式，却未泛化到测试集。Test MSE = 0.7253 与之印证。

特征重要性

RNN 为黑盒循环网络，日志未输出特征重要性，且深度模型脚本不生成 SHAP 图。基于其余模型的一致性结论，可推断 pC20 主要受 LogP、HeavyAtoms、MolWt、NAtoms 等疏水性/尺寸描述符驱动；RNN 的问题不在于特征信息不足，而在于**序列式结构无法像 MLP 那样对 522 维特征做整体非线性变换**——同为深度模型，MLP (R² 0.8127) 与 RNN (0.4913) 的巨大差距直接印证了这一点。

结论与评价

优点： - 具备序列建模能力，理论上可捕捉特征间隐式顺序关系（但 522 维手工特征并无真实顺序，此能力无处发挥）。 - 训练成本低（约 2 分钟），与固定架构、固定轮数的简单配置相匹配。

不足： - **精度第 9 (R² = 0.4913)**，在 10 个模型中倒数第 2，显著落后 MLP (0.8127) ——序列式结构对 522 维扁平特征严重错配。 - Test (0.8516) 与验证 (0.6843) 差距约 0.17，过拟合明显，泛化失败。 - 无 Optuna 调参、无早停、无特征重要性输出，可解释性与可控性均弱。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R ²
7	LightGBM	0.6919	0.6643
8	HistGB	0.7441	0.6116
9	RNN	0.8516	0.4913
10	Transformer	1.0480	0.2297

RNN 在 pC20 上是明确的反面教材：“把特征当序列”的建模假设在本项目 522 维手工特征上不成立。pC20 的深度模型胜出应由 MLP 的扁平全连接结构承担，RNN/Transformer 的垫底则说明序列式深度模型不适用于此类特征形态。除非未来改用真正的分子序列输入（如 SMILES token 序列），否则不建议继续投入 RNN 方向。