

pC20 Transformer 模型报告

Transformer 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_transformer_20260806_150057
运行时间	15:00 ~ 15:09 (约 9 分钟, 固定架构训练, 早停于 epoch 210)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

Transformer Encoder 是 10 个模型中三个深度模型之一。本项目将 **522 维特征向量重塑为序列 (batch, 522, 1)**, 输入 3 层 Transformer Encoder (d_model=128、4 头自注意力、FFN 256、GELU), 末层映射到单值输出——即“把特征当 token 序列”的序列式深度网络。自注意力机制理论上可对特征间关系做全局建模, 但这以**足够大的训练数据**为前提。

在 pC20 任务中, Transformer 的 Test $R^2 = 0.2297$ 、Test RMSE = 1.0480, **在 10 个模型中排名垫底 (第 10)**。pC20 训练池仅 564 条, 远不足以支撑 Transformer 的参数量, 这是其失利的根本原因。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 564 条 (493 训练 + 71 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。
- **输入重塑**: 522 维 $\rightarrow$ (batch, 522, 1), 每维作为一个 token。

超参数与调优

本模型采用**固定架构, 不进行 Optuna 调参**, 超参数直接给定:

参数	值
Encoder 层数	3
d_model	128
注意力头数	4
FFN 维度	256
激活函数	GELU
learning_rate / weight_decay	1e-3 / 1e-5
batch_size	16
最大 epoch	500 (早停)
学习率调度	CosineAnnealingLR
grad_clip	5.0

说明: 与 RNN 相同, Transformer 未做超参搜索。d_model=128、4 头自注意力在 522 个 token 上产生大量可训练参数, 而训练样本仅 493, 参数量/数据量比例严重失衡。

训练过程

模型在 493 条数据上训练, **早停在 epoch 210 触发** (验证集 150 轮不改善即停) 。收敛过程暴露了严重的训练不稳定性:

- Epoch 5~60: Val RMSE 从 1.157 降至 **0.9600 (Epoch 60, 最优验证点)** , 短暂有效;

- Epoch 60 之后：验证 RMSE 在 1.0~1.6 之间**剧烈震荡**（如 Epoch 150 达 1.513、Epoch 155 达 1.602、Epoch 205 达 1.523），最优值 0.9600 此后 150 轮从未被刷新，最终触发早停。

这种“先下降后震荡恶化”的模式表明模型在小样本上**严重过拟合**，且 CosineAnnealingLR + 高容量自注意力的组合无法稳定收敛。最优验证 RMSE 0.9600 也远高于 MLP (0.4625) 与 RNN (0.6843)，从源头就限制了最终精度。

测试结果

指标	值
Test RMSE	1.0480
Test MAE	0.8417
Test R ²	0.2297
Best val RMSE	0.9600

说明：本模型训练脚本**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（深度模型脚本无绘图输出）。如需可视化，可复用 `train_transformer_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (1.0480) 进一步高于验证 RMSE (0.9600)，且 **Test R² 仅 0.2297**——模型几乎不具备预测能力 (R² 接近 0 即相当于“预测均值”的基线水平)。Test MSE = 1.0982 与之印证。

特征重要性

Transformer 为黑盒注意力网络，日志未输出特征重要性，且深度模型脚本不生成 SHAP 图。基于其余模型的一致性结论，pC20 主要受 LogP、HeavyAtoms、MolWt 等疏水性/尺寸描述符驱动；Transformer 的问题不在特征信息缺失，而在**高容量自注意力在 564 条小样本上无法学习到稳定的特征-目标映射**。同为深度模型，MLP (R² 0.8127，扁平全连接) 以低得多的参数量取得了全场最优，反衬出序列式 Transformer 在本任务中的结构性劣势。

结论与评价

优点： - 具备全局自注意力建模能力，理论表达力最强（但小样本下无法兑现）。 - 早停机制有效防止了无界过拟合（epoch 210 及时截断）。

不足： - **精度垫底 ($R^2 = 0.2297$)**，在 10 个模型中排名第 10，是所有模型中唯一 $R^2 < 0.3$ 的。 - 训练极不稳定：Epoch 60 后验证 RMSE 震荡至 1.6，早停虽触发但最优点已不佳。 - 参数量/数据量严重失衡（493 训练样本 vs 高容量注意力网络），无 Optuna 调参，可解释性弱。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
8	HistGB	0.7441	0.6116
9	RNN	0.8516	0.4913
10	Transformer	1.0480	0.2297

Transformer 在 pC20 上全面垫底，与 RNN 共同证明：**序列式深度模型不适用于本项目 522 维扁平手工特征**，尤其在仅 564 条样本下。Transformer 的价值应留给数据量充足（如上万级分子库）或真正序列化输入（SMILES token）的场景。在 pC20 任务中，深度模型的代表是 MLP——它用最简洁的架构取得了最优成绩，而 Transformer/RNN 的失败为“模型-数据-特征匹配”提供了反面教材。