

pC20 XGBoost 模型报告

XGBoost 模型报告 — pC20 预测

报告信息

项目	内容
目标变量	pC20 (表面活性剂效率, $\log(1/C20)$)
运行目录	runs\pC20\pC20_xgboost_20260806_151000
运行时间	15:10 ~ 15:26 (约 16 分钟, 含 Optuna 200 轮调参)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

XGBoost 是陈天奇提出的梯度提升框架, 以其对**二阶泰勒展开**、稀疏感知与列块并行的实现著称。本项目为 XGBoost 配置了**全模型最复杂的调参管线**: 200 轮 Optuna $\times$ 5 折 CV (CV 样本 507), 配合 **Top-K holdout 泛化性筛选** (独立 holdout 57 样本 + 训练-验证差距惩罚, 防止过拟合的“虚高”参数被选中)。

在 pC20 任务中, XGBoost 的 Test $R^2 = 0.7039$ 、Test RMSE = 0.6498, 在 10 个模型中排名第 4, 处于第一梯队 (MLP、CatBoost、CIF 之后)。pC20 是表面活性剂效率 (使表面张力降低 20 mN/m 所需浓度的负对数), 与 pCMC 强相关 ($r \approx 0.76$), 但训练样本仅 564 条, 样本更稀疏。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。

- **数据规模**：训练池 564 条，测试集 70 条；调参阶段进一步划分 CV 507 / Holdout 57，最终模型以 507 条训练（holdout 仅用于参数筛选，不参与训练）。
- **数据划分**： `train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 200 轮 × 5 折 CV (multivariate TPE) + gap penalty (训练-验证差距惩罚) + Top-K holdout 泛化筛选**，是全项目最严谨的调参管线。

调参最优试验 (Trial 180, CV RMSE = 0.6101)：

参数	值
n_estimators	2199
max_depth	6
learning_rate	0.0252
subsample	0.606
colsample_bytree / bylevel / bynode	0.832 / 0.903 / 0.452
min_child_weight	1.053
gamma	0.00146
reg_alpha / reg_lambda	4.7e-6 / 3.1e-6
max_delta_step	0.331
booster	dart

Top-5 Holdout 泛化筛选 (独立 57 样本复评，最终选中)：

排名	CV RMSE	Holdout RMSE	Holdout R ²
1	0.6062	0.6231	0.7631
2	0.6082	0.6710	0.7253
3	0.6084	0.6056	0.7763
4	0.6097	0.6586	0.7354
5	0.6101	0.6076	0.7748

最终选中的参数并非 CV 最优（第 5 名 0.6101），而是 **holdout 上泛化最佳的第 3 名 (0.6056)**，且最终改为 `booster='gbtree'`、`n_estimators=2373`、`max_depth=6`、`lr=0.0264`、`subsample=0.744`。这正是 Top-K 筛选的设计意图：**选择最泛化的参数而非虚高 CV**。

Optuna 参数重要度：

参数	重要度
gamma	0.6303
max_depth	0.0957
max_delta_step	0.0518
subsample	0.0438
colsample_bynode	0.0381
其余 (reg_alpha、n_estimators 等)	< 0.04

参数重要度显示 **gamma（分裂最小损失增益）对 XGBoost 表现的影响压倒性 (0.63)** ——与 pCMC 任务结论 (0.80) 一脉相承，说明 522 维特征上的分裂极易过拟合，必须依赖 gamma 强制每次分裂带来足够信息增益；这也是 Top-K holdout 机制存在的原因。


训练过程

- **调参阶段**：200 轮 Optuna 中 82 轮被剪枝。最优 CV 试验为 Trial 180 (0.6101)，随后进入 Top-5 Holdout 泛化筛选，最终选中 holdout RMSE 0.6056 的参数组合 (gbtree, 2373 棵树)。
- **最终训练**：以选中参数在 **507 条数据**上训练 (holdout 57 条退出训练仅作筛选)，未触发早停，直接输出测试评估。

测试结果

指标	值
Test RMSE	0.6498
Test MAE	0.4665
Test R ²	0.7039
Best CV RMSE	0.6101
Holdout RMSE	0.6056


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.6498) 略高于 Holdout (0.6056) 与 CV (0.6101)，属于小样本（测试 70 条）下的正常波动，整体泛化水平与筛选口径基本一致。Test MSE = 0.4222 与之印证。

特征重要性（说明）

当前日志输出的 Top-20 特征重要度数值接近 0（仅 atom_std_44=0.2、maccs_137=0.1 等少数非零，其余全为 0.0），但排序仍指示 atom_std_44、maccs_137、atom_max_44、maccs_77 等原子级统计特征与 MACCS 药效团特征靠前。数值接近归零的原因是 XGBoost 对特征重要性（默认 weight/分类型）的口径输出异常，属于**日志展示缺陷**；若要精确归因，应改用 `shap_xgboost.py` 的 SHAP 分析（TreeExplainer）。下方 SHAP 图即为该分析的实测结果，可据此完成精确归因：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: MolWt、LogP、maccs_77 位列前三, 与其余树模型结论一致 (疏水性/尺寸主导 pC20) 。

结论与评价

优点: - 精度第 4 ($R^2 = 0.7039$) , 处于第一梯队, 与 CIF (0.7108) 几乎持平。 - 最严谨的调参流程 (200 轮 + Top-K 泛化筛选 + 差距惩罚) , 参数选择可信度高、过拟合风险被主动压制。 - 参数重要度 (gamma=0.63) 给出极具洞察的结论, 指导了正则方向。

不足: - 调参成本高 (200 轮约 16 分钟虽快于 pCMC 的 34 分钟, 但仍为最长之一) 。 - 特征重要性输出异常 (数值接近归零) , 可解释性文档化需依赖 SHAP 补充。 - 相对最优 MLP (0.5168 / 0.8127) 仍有约 0.13 的 RMSE 差距, 未进前三。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
2	CatBoost	0.6276	0.7237
3	CIF (ExtraTrees)	0.6422	0.7108
4	XGBoost	0.6498	0.7039
5	RF	0.6644	0.6904
6	NGBoost	0.6652	0.6897

XGBoost 与 CatBoost、CIF 共同构成 pC20 的“树模型第一梯队”，三者 RMSE 仅差 0.022。作为调参最充分的模型，XGBoost 适合作为**精度基准**；若追求极致精度可优先 MLP，追求可解释性可优先 CatBoost。