

pCMC_catboost_report 模型报告

CatBoost 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_catboost_20260802_121541
运行时间	2026-08-02 12:15 ~ 13:26 (约 71 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

CatBoost 是 Yandex 开发的梯度提升树 (GBDT) 算法，其核心优势在于采用**对称树**结构 (oblivious trees)、原生支持**有序目标统计量** (ordered target statistics) 处理类别特征，并通过 ordered boosting 缓解预测偏移。本项目中的输入是 522 维扁平特征向量 (无显式类别列)，因此主要发挥的是 CatBoost 对数值特征的高效分箱 (border_count)、叶子估计迭代 (leaf_estimation_iterations) 与 L2 正则 (l2_leaf_reg) 等机制。

在 pCMC 预测任务中，CatBoost 的测试 $R^2 = 0.8548$ ，在 10 个模型中排名第 4，属于性能稳定的第一梯队成员。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征 (原子聚合 220 + 键聚合 56 + 药效团 MACCS 194 + 反应活性 BRICS 34 + 表面活性剂类型 4 + 头尾比 2 + 分子描

述符 12) , 通过 `load_or_compute_features()` 从缓存加载 ([Cache HIT]) 。

- **数据规模**: 训练集 1204 条 (其中 1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 随机种子固定, 与其他模型一致, 保证可比性。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner, 配置见 `config.json`) 。

最优试验 (Trial 17, CV RMSE = 0.4622) :

参数	值
depth	5
learning_rate	0.0366
iterations	1566
l2_leaf_reg	5.957
random_strength	1.227
bagging_temperature	9.027
border_count	224
one_hot_max_size	43
leaf_estimation_iterations	9
min_data_in_leaf	42

Optuna 参数重要度排序:

参数	重要度
one_hot_max_size	0.3189
l2_leaf_reg	0.2358
min_data_in_leaf	0.1356
learning_rate	0.1057
iterations	0.0897
其余 (random_strength 等)	< 0.05

参数重要度显示，**one_hot_max_size** 与 **l2_leaf_reg** 对 CV 表现影响最大，说明 522 维特征中存在部分高基数离散型变量（如 MACCS/BRICS 的类别性分桶特征），类别处理的粒度与正则强度是决定性能的关键；深度（depth）本身重要度很低（0.0079），表明浅树即可捕捉结构，过深反而易过拟合。


训练过程

- **调参阶段**：50 轮试验中 5 轮被 MedianPruner 提前剪枝（Trial 7/25/35/39/40），其 CV RMSE 普遍偏高（0.48~0.68），剪枝机制有效节约了约 10% 算力。CV RMSE 从 Trial 0 的 0.4876 逐步收敛至最优 0.4622。
- **最终训练**：使用最优参数在 1053 条训练集上重新训练。CatBoost 内置**过拟合检测器**在迭代 800 轮时触发（150 轮等待窗口），在 **bestIteration = 681** 处取得最佳验证损失（bestTest = 0.4963），模型收缩至 682 棵树的集成。训练曲线显示：learn 损失从 1.054 单调降至 0.179，test 损失在迭代 681 附近触底后轻微回升，过拟合控制得当。

测试结果

指标	值
Test RMSE	0.4235
Test MAE	0.2953
Test R ²	0.8548
Best CV RMSE	0.4622

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



值得注意的是，测试 RMSE (0.4235) **低于**交叉验证 RMSE (0.4622)，说明模型泛化能力良好，未见明显过拟合；Test MSE = 0.1794 与 RMSE 相互印证。


特征重要性 (Top 20)

CatBoost 输出基于分裂次数加权的特征重要性，Top 5 为：


1. **LogP** (10.7) — 脂水分配系数，与表面活性剂降低界面张力的能力直接相关
2. **HeavyAtoms** (8.5) — 重原子数，反映分子大小
3. **NAtoms** (5.1) — 原子总数
4. **MolWt** (5.1) — 分子量
5. **tail_ratio** (2.8) — 疏水尾链碳占比，表面活性剂“头亲水尾疏水”结构的直接度量

前 4 个特征全部是分子尺度的全局描述符，说明 **pCMC 主要由分子整体疏水性与尺寸决定**，这与胶束化自由能的物理本质一致；药效团 MACCS 特征 (maccs_101/105)、原子聚合特征 (atom_mean_16/46 等) 也进入前 20，贡献为辅。

SHAP 特征重要性可视化（基于测试集的 TreeExplainer 归因，与日志特征重要性互为补充）：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值 (>0 推高 $pCMC$, <0 拉低)，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、HeavyAtoms 显著领先, 与日志输出一致。

结论与评价

优点: - 内置过拟合检测器自动确定迭代轮数, 无需人工早停, 训练稳定。 - 参数重要度诊断清晰, 便于理解特征/参数结构。 - 测试性能优于交叉验证, 泛化稳健, 无过拟合迹象。

不足: - 对称树结构对高维连续特征 (522 维) 的表征效率不如非对称 GBDT (LightGBM 的 leaf-wise 生长)。 - 训练耗时约 71 分钟 (含 50 轮 Optuna), 在 10 个模型中属于中等偏长。

横向定位 (10 个模型中按 Test RMSE 排序):

排名	模型	Test RMSE	Test R ²
1	CIF (ExtraTrees)	0.3928	0.8751
2	NGBoost	0.4150	0.8605
3	XGBoost	0.4199	0.8572
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543
6	LightGBM	0.4311	0.8495

CatBoost 以微小差距 (RMSE 差 < 0.004) 落后于 XGBoost, 与 MLP 几乎持平, 是**稳定可靠的中游偏上选择**; 若追求极致精度可优先考虑 CIF/NGBoost/XGBoost, 但 CatBoost 在训练稳定性和参数可解释性上具有优势。