

pCMC_cif_report 模型报告

CIF（条件推理森林 / ExtraTrees）模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_cif_20260802_144459
运行时间	2026-08-02 14:44 ~ 14:49 (约 5 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

CIF (Conditional Inference Forest) 在此实现中由 **ExtraTrees (极端随机树)** 承载：不同于标准随机森林在最优切分点中做选择，ExtraTrees 在每个节点**随机生成切分阈值**，从而进一步降低方差、抑制过拟合。本项目 522 维特征以连续型描述符为主，ExtraTrees 对连续特征的随机切分策略尤其高效，且训练开销极低。

该模型是本次 pCMC 任务 10 个模型中的综合最优者：Test $R^2 = 0.8751$ 排名第 1，Test RMSE = 0.3928 同样排名第 1，显著优于第二名 NGBoost (0.4150)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余 9 个模型完全一致, 保证公平对比。
- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**。

最优试验 (Trial 48, CV RMSE = 0.4769) :

参数	值
n_estimators	1161
max_depth	21
min_samples_split	7
min_samples_leaf	1
max_features	None (用全部特征)
bootstrap	False

调优过程观察: - 前 8 轮表现很差 (CV RMSE 0.69~0.94) , 原因是最优参数搜索初期倾向于 `bootstrap=True` + `max_features='sqrt'/'log2'` 的组合——对 522 维连续特征而言, 随机子集特征容易丢失关键描述符, 且自助采样引入额外噪声。 - 搜索快速收敛到 `bootstrap=False` + `max_features=None` (全特征) + `min_samples_leaf=1` 的区域, 从 Trial 22 起 CV RMSE 稳定进入 0.50~0.55, Trial 48 触底至 0.4769。 - 50 轮中 15 轮被 MedianPruner 剪枝, 整体训练仅耗时约 5 分钟, **调参效率为 10 个模型中最高**。


训练过程

由于 ExtraTrees 是**非迭代式**集成 (一次性训练全部树、取平均) , 日志中无逐轮 loss 曲线, `Training Final Model` 阶段直接输出结果。这意味着: - 无过拟合检测器、无早停需求, 超参确定后即一次成型; - 训练时间几乎全部来自 Optuna 搜索阶段, 最终模型训练仅数秒。

测试结果

指标	值
Test RMSE	0.3928
Test MAE	0.2701
Test R ²	0.8751
Best CV RMSE	0.4769

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



值得注意：Test RMSE (0.3928) 明显低于 CV RMSE (0.4769，差距约 18%)。这种“测试优于交叉验证”的现象说明：其一，随机种子 42 划分出的 140 条测试样本分布略偏简单；其二，ExtraTrees 的极端随机化在 CV 折内平均了部分噪声，而全量训练 (1053 条) 上训练的最终模型信息更充分。Test MSE = 0.1543 与之印证。


特征重要性 (Top 20)

ExtraTrees 的 `feature_importances_` 基于分裂减少不纯度加权，且因为切分阈值随机，重要度分布**高度分散** (Top 1 也仅 0.1)，绝对值参考意义有限，但**相对排序**仍具指示性：


1. **LogP** (0.1) — 脂水分配系数
2. **HeavyAtoms** (0.1) — 重原子数
3. **NAtoms** (0.1) — 原子总数
4. **MolWt** (0.0) — 分子量
5. **atom_mean_46 / atom_mean_16 / maccs_101** (0.0) — 原子聚合与药效团特征

与 CatBoost 的特征重要性排名高度一致 (LogP、HeavyAtoms、NAtoms、MolWt 居前)，再次印证 **pCMC** 的核心决定因素是分子疏水性与尺寸等全局描述符，两个模型的排序互为交叉验证。

SHAP 特征重要性可视化 (基于测试集的 TreeExplainer 归因)：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、HeavyAtoms、NAtoms 位列前三。

结论与评价

优点： - **全模型最佳预测精度**：Test RMSE 0.3928、 R^2 0.8751 双双领先。 - 训练/调参极快（约 5 分钟），几乎无调参成本。 - 无迭代、无早停，训练确定性强，结果可复现性强。 - 随机切分抑制过拟合，对 522 维高维连续特征鲁棒。

不足： - 特征重要性绝对值近零、分散，难以做精确的逐特征归因（相对排序仍可靠）。 - 预测为点估计，**不提供不确定性度量**（对比 NGBoost 可输出方差）。 - 模型本质是平均化集成，对极端分子的外推能力弱于能学趋势的 GBDT/深度模型。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
1	CIF (ExtraTrees)	0.3928	0.8751
2	NGBoost	0.4150	0.8605
3	XGBoost	0.4199	0.8572
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543
6	LightGBM	0.4311	0.8495

CIF 是当前 pCMC 任务**精度最优**的模型，适合作为默认预测器（SmilesPredictor 的 best 选项即按最低 test_rmse 自动选中它）。其不足在于无概率输出与特征归因颗粒度，若需不确定性或可解释性，可搭配 NGBoost / CatBoost 使用。