

pCMC_histgb_report 模型报告

HistGradientBoosting 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_histgb_20260802_150138
运行时间	2026-08-02 15:01 ~ 15:44 (约 43 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

HistGradientBoosting (sklearn 的 HistGradientBoostingRegressor) 是经典的直方图梯度提升：训练前先将每个特征离散化为最多 max_bins 个直方图桶，分裂时只需在桶边界上搜索，从而以极低内存开销逼近 LightGBM 式直方提升的效果。它同时支持 max_depth 与 max_leaf_nodes 双维度约束树结构，正则化由 l2_regularization 控制。

在 pCMC 任务中，HistGB 的 Test R^2 = 0.8280、Test RMSE = 0.4609，在 10 个模型中位列第 7，处于中游偏后，与 LightGBM (0.4311) 相比同源却差距明显，说明参数搜索尚未充分压榨其潜力。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**。

最优试验 (Trial 41, CV RMSE = 0.4835) :

参数	值
learning_rate	0.0690
max_iter	618
max_depth	10
max_leaf_nodes	33
min_samples_leaf	10
l2_regularization	2.680
max_bins	244

调优过程观察: - 最优参数将迭代数收敛在 **618 轮** (搜索空间中位数的约 1/4) , 配合中等学习率 0.069 与较强 L2 正则 (2.68) , 说明 522 维特征上的梯度提升不需要过深过长的迭代即可收敛。 - `max_leaf_nodes=33` 属于偏保守的叶节点上限, 进一步限制了模型容量、防止过拟合。 - 50 轮中 8 轮被 MedianPruner 剪枝; CV RMSE 整体稳定在 0.48~0.51 的窄区间 (最优 0.4835) , 未出现明显离群试验, 搜索空间设置合理。


训练过程

HistGB 同样为迭代式直方提升, 但日志未输出逐轮损失 (sklearn 默认静默训练) , `Training Final Model` 阶段直接产出测试评估。由 CV 表现 (0.4835) 与 Test RMSE (0.4609) 对比可见, 测试集表现略优于交叉验证, 泛化正常, 无过拟合迹象。

测试结果

指标	值
Test RMSE	0.4609
Test MAE	0.3094
Test R ²	0.8280
Best CV RMSE	0.4835

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test MSE = 0.2124 与 RMSE 相互印证。


特征重要性 (Top 20, 置换重要性)

本模型输出的重要性与 CatBoost/CIF 的**不纯度加权重要性**不同，采用的是**置换重要性 (permutation importance)**——随机打乱某特征后测试集性能的下降量，同时给出标准差 (±)。这种方式更能反映特征的真实预测贡献，且**数值在不同模型间可横向比较**：


排名	特征	重要性	语义
1	LogP	0.5394 ± 0.042	脂水分配系数
2	HeavyAtoms	0.3205 ± 0.045	重原子数
3	MolWt	0.1390 ± 0.008	分子量
4	tail_ratio	0.0899 ± 0.012	疏水尾链碳占比
5	atom_std_35	0.0716 ± 0.008	原子聚合统计（电荷相关）

LogP 的置换重要性 (0.5394) 是第二名 HeavyAtoms 的近两倍，标准差小、估计稳定——这给出了一个比不纯度重要性**更可信的证据：pCMC 主要受分子疏水性 (LogP) 主导**，其次是分子尺寸 (HeavyAtoms/MolWt) 与疏水尾占比 (tail_ratio)。这与胶束化自由能由疏水效应驱动的物理机制完全吻合。HBA、TPSA 等极性相关描述符也进入前 20，印证极性基团对 CMC 的次级调控作用。


SHAP 特征重要性可视化（基于测试集的 TreeExplainer 归因）：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP 居首, 与置换重要性结论吻合。



SHAP 交互作用热图：量化特征两两交互对预测的贡献，LogP 与 HeavyAtoms/MolWt 交互显著。

结论与评价

优点： - 采用置换重要性，特征归因**最可靠、可跨模型比较**，本报告中的特征结论有较强说服力。 - 直方图加速，训练内存占用低，调参 43 分钟含 50 轮 CV，成本可控。

不足： - 预测精度在 10 个模型中仅列第 7 ($R^2 = 0.8280$)，落后于同为梯度提升的 LightGBM/CatBoost/XGBoost。 - `max_leaf_nodes` 与 `max_depth` 双约束 + 较强 L2 正则 在 522 维特征上可能**过度限制了模型容量**，是性能偏弱的主因。 - 无内置早停与特征增益诊断输出（对比 CatBoost 的过拟合检测器与参数重要度）。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
5	MLP	0.4241	0.8543
6	LightGBM	0.4311	0.8495
7	HistGB	0.4609	0.8280
8	RNN	0.4664	0.8239
9	RF	0.4808	0.8128

HistGB 与 LightGBM 同为直方提升家族，但两者 Test RMSE 相差 0.03，主要归因于搜索空间与树生长策略差异。当前配置下 HistGB 定位为**中等精度、高可解释性**的备选模型，若需强解释（置换重要性）可选用，若需精度建议转向 CIF / XGBoost。