

pCMC_lightgbm_report 模型报告

LightGBM 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_lightgbm_20260802_155314
运行时间	2026-08-02 15:53 ~ 15:56 (约 3 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

LightGBM 是微软开源的梯度提升框架，采用**单边梯度采样 (GOSS)** 与**互斥特征捆绑 (EFB)** 加速，并以 **leaf-wise** (按叶子分裂) 的树生长策略著称——相比 level-wise 生长，能在相同树深下获得更精确的拟合，但更易过拟合，因此 `num_leaves` 的约束至关重要。本项目搜索空间同时包含 `gbdt` 与 `dart` 两种 boosting 类型。

在 pCMC 任务中，LightGBM 的 Test $R^2 = 0.8495$ 、Test RMSE = 0.4311，在 10 个模型中排名第 6，处于中游，但训练耗时仅约 3 分钟，是**性价比极高**的选项。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征，从缓存加载 (`[Cache HIT]`)，与其余模型一致。

- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (每折内部使用 30 轮早停) 。

最优试验 (Trial 16, CV RMSE = 0.4818) :

参数	值
boosting_type	gbdt
max_depth	10
num_leaves	31
learning_rate	0.0384
n_estimators	1972
subsample / freq	0.820 / 1
colsample_bytree	0.987
reg_alpha / reg_lambda	~0 / 6e-5
min_child_samples	13
min_child_weight	0.0185
min_split_gain	0.0537

关键观察: boosting 类型的选择。 - 搜索早期采样的 `dart` 变体表现灾难性: Trial 0 (CV RMSE 2.07) 、 Trial 3 (2.01) 、 Trial 1 (0.96) 均远超 `gbdt` 的最优值 (0.48) 。 DART 通过 drop-out 丢弃已训练树来缓解过拟合, 但在 1204 条小样本上收敛极不稳定, **Trial 16 之后搜索收敛于 `gbdt` 区域。** -

`num_leaves=31` 相对保守 (对比搜索上限 255) , 配合 `max_depth=10` 双约束 + 几乎不设 L2 正则, 说明 LightGBM 在 522 维特征上靠**较小的叶节点数**即可避免过拟合。 - 每折早停 (30 轮) 使单折训练往往在数百轮内收敛, 5 折 × 50 试验全程仅约 3 分钟, **调参速度全模型第一。**

训练过程

- **调参阶段**: 50 轮试验中仅 4 轮被 MedianPruner 剪枝, 大量试验因早停快速收敛而无需剪枝。 CV RMSE 主体集中在 0.48~0.53 的窄带, Trial 16 以


0.4818 触底。

- **最终训练**：使用最优参数在 1053 条数据上重新训练（早停窗口放宽到 50 轮），在**迭代 190 轮**处早停（valid RMSE = 0.5072），随后损失出现回升迹象，早停及时生效。

测试结果

指标	值
Test RMSE	0.4311
Test MAE	0.2862
Test R ²	0.8495
Best CV RMSE	0.4818

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (0.4311) 优于 CV (0.4818)，泛化良好。Test MSE = 0.1859 与之印证。


特征重要性 (Top 20)

LightGBM 默认输出**分裂次数重要性**（feature 被选为分裂点的次数），数值为计数而非加权得分。排名揭示了**表面活性剂结构特征的主导地位**：


1. **tail_ratio** (339 次分裂) — 疏水尾链碳占比
2. **LogP** (313) — 脂水分配系数
3. **MolWt** (262) — 分子量
4. **head_ratio** (184) — 亲水头基原子占比
5. **HeavyAtoms** (140) — 重原子数

值得注意：**tail_ratio** 与 **head_ratio** 双双进入前 4——这是本项目第一个把“头-尾结构比率”特征排到最前列的模型（CatBoost/CIF 中它们排 5 名开外）。说明 LightGBM 的 leaf-wise 分裂频繁利用头/尾占比这类**可解释的结构比率**做判别，与表面活性剂“亲水头 + 疏水尾”的两亲性本质高度契合。LogP、MolWt、HeavyAtoms 等全局描述符依然重要，与其余模型结论一致。

SHAP 特征重要性可视化（基于测试集的 TreeExplainer 归因）：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图：tail_ratio 与 LogP 并列前茅，印证头尾结构比率的价值。

结论与评价

优点： - **训练/调参极快**（约 3 分钟完成 50 轮 × 5 折），在 10 个模型中效率最高。 - 内置每折早停，自动控制迭代轮数，无过拟合风险。 - 特征重要性直观，且揭示了 tail_ratio / head_ratio 的结构性价值。

不足： - 精度中等 ($R^2 = 0.8495$ ，列第 6)，未进入第一梯队（CIF/NGBoost/XGBoost）。 - num_leaves=31 的保守约束可能压制了 leaf-wise 本可达到的拟合上限。 - dart 变体在小样本上表现不稳定，搜索空间若含 dart 需额外注意收敛性。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543
6	LightGBM	0.4311	0.8495
7	HistGB	0.4609	0.8280
8	RNN	0.4664	0.8239

LightGBM 与 CatBoost/MLP 的差距均在 0.01 RMSE 以内，实际性能非常接近，但训练成本只有后者的 1/20 左右。**在精度要求不极端、强调迭代速度的场景下，LightGBM 是最优折中选择。**