

pCMC_mlp_report 模型报告

MLP 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_mlp_20260802_172700
调参日志	runs\pCMC\pCMC_mlp_tuning_20260802_155757\train.log
运行时间	调参 15:57 ~ 17:27 (约 90 分钟) , 最终训练 17:27
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

MLP (多层感知机) 是 10 个模型中唯一的**前馈全连接深度网络**

(RNN/Transformer 为序列式深度模型)。架构为 Linear → BatchNorm → GELU → Dropout 重复堆叠 N 层, 末层映射到单值输出, 以 522 维特征向量整体作为输入 (不做序列化)。深度网络对特征的**非线性组合与隐式高阶交互**建模能力强于树模型, 是“手工特征 + 神经网络”路线的代表。

在 pCMC 任务中, MLP 的 Test R^2 = 0.8543、Test RMSE = 0.4241, 排名第 5, 是**深度模型中的最优者** (显著优于 RNN 与 Transformer), 整体性能与 CatBoost 几乎持平。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征, 从缓存加载, 与其余模型一致。

- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。这是深度模型中唯一使用 Optuna 的 (RNN/Transformer 用固定架构) 。

最优试验 (Trial 42, CV RMSE = 0.4313) :

参数	值
n_layers	3
hidden_dim	990
dropout	0.267
activation	gelu
learning_rate	0.00673
weight_decay	1.06e-4
batch_size	95
Best CV RMSE	0.4313

调优过程观察: - 早期试验 (Trial 0/1) 表现极差 (CV RMSE 0.84 / 1.67) , 原因是学习率过低 ($1.5e-5$ / $3.5e-5$) 导致欠拟合; **搜索快速收敛到 $lr \in [0.002, 0.01]$ 的合理区间。** - 最优解显著偏好 **GELU 激活 + 中等隐藏层 (700~990) + 3~6 层** 的结构, dropout 稳定在 0.13~0.33 的适度区间以平衡过拟合。 - Trial 37 与 Trial 42 的 CV RMSE 仅差 $2e-5$ (0.431314 vs 0.431294) , 说明搜索已收敛、对超参不敏感, **最优解稳定**。 - 50 轮中 9 轮被剪枝; 单轮 5 折 CV 平均耗时约 1.7 分钟, 深度网络的调参成本 (约 90 分钟) 显著高于树模型 (LightGBM 仅 3 分钟) 。

训练过程

最终模型以最优参数在 1053 条数据上训练, **早停在 epoch 265** 触发 (验证集 RMSE = 0.4480) 。训练约 265 个 epoch 表明网络需要较多迭代才能收敛, 但由于早停机制, 未出现过拟合蔓延; 最终以验证最优权重 (而非末轮权重) 作为交付模型。

说明：最终训练与调参在同一脚本中连续执行（调参日志末尾包含最终训练段）， `pCMC_mlp_tuning` 目录即本次调参过程存档。

测试结果

指标	值
Test RMSE	0.4241
Test MAE	0.3163
Test R ²	0.8543
Best CV RMSE	0.4313
Best val RMSE	0.4480

说明：本次 MLP 运行**未生成** `pred_vs_true` 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用 `train_mlp_use_pharmhgt_features.py` 中加载的缓存特征另行绘制。

Test RMSE (0.4241) 略优于 CV (0.4313)，泛化良好，无过拟合迹象。Test MSE = 0.1799 与之印证。

特征重要性

MLP 为黑盒网络，日志未输出特征重要性。其输入为 522 维原始特征向量，重要特征需借助 **SHAP 的 KernelExplainer** 事后归因（`shap_mlp.py` 路径下可生成，但本次 pCMC 运行未生成 SHAP 图）。基于其余模型的一致性结论，可推断其预测主要由 LogP、HeavyAtoms、MolWt 等全局疏水性/尺寸描述符驱动。

结论与评价

优点：

- **深度模型中的最优者**：R² = 0.8543，与 CatBoost 持平，证明神经网络能有效挖掘 522 维手工特征的非线性结构。
- 使用 Optuna 充分调参（vs 固定架构的 RNN/Transformer），超参选择有依据、结果可复现。
- 早停 + Dropout + weight_decay 三重正则，泛化稳健。

不足： - 调参成本高（约 90 分钟），为树模型的数十倍。 - 黑盒模型，可解释性差；MAE (0.3163) 在 10 个模型中偏高，说明对中间区间分子存在系统性偏差。 - 不提供不确定性估计（对比 NGBoost）。

关于历史记录说明： 项目 CLAUDE.md 曾记载“MLP 为当前最佳 (Test RMSE=0.342, R²=0.905) ”，与本次日志输出 (0.4241 / 0.8543) 不符——同一组最优超参 (3×990 GELU、dropout 0.27、lr 0.0067、batch 95) 出现在两处，但指标数值不同。**本文以本次运行日志为准**；若需核实历史最佳记录，应回溯当时的运行目录。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
3	XGBoost	0.4199	0.8572
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543
6	LightGBM	0.4311	0.8495
7	HistGB	0.4609	0.8280

MLP 以微小差距位列第一梯队之后，但作为深度网络的代表，其**扩展潜力**（更深的架构、特征自学习）优于树模型；在现有手工特征+小样本（1053）配置下，精度略逊于 CIF/XGBoost，性价比不及 LightGBM。