

pCMC_ngboost_report 模型报告

NGBoost 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_ngboost_20260802_172739
运行时间	2026-08-02 17:27 ~ 17:28 (约 1 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

NGBoost (Natural Gradient Boosting) 是斯坦福提出的**概率型梯度提升**框架：它不是直接回归均值，而是把输出建模为一个**参数化分布**（此处为 Normal 分布，即同时预测均值和方差），并通过**自然梯度**对分布参数进行 boosting。其独特价值在于——每次预测不仅给出 pCMC 的点估计，还附带**不确定性（标准差）**，这对于实验设计中评估预测可靠性具有实际意义。

在 pCMC 任务中，NGBoost 的 Test $R^2 = 0.8605$ 、Test RMSE = 0.4150，在 10 个模型中**综合排名第 2**，仅次于 CIF，且是唯一具备概率输出能力的模型。

数据与方法

- 特征**：522 维 PharmHGT 风格特征，从缓存加载（[Cache HIT]），与其余模型一致。
- 数据规模**：训练集 1204 条（1053 训练 + 151 验证），测试集 140 条。

- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

NGBoost 是本项目中**唯一未运行 Optuna** 的模型, 直接采用**预调优参数** (Using pretuned hyperparameters (skipping Optuna search)), 来源于此前的研究:

参数	值
n_estimators	637
learning_rate	0.0337
minibatch_frac	0.723
max_depth	5
min_samples_leaf	13
score_rule	LogScore

这一选择的代价是**没有为 pCMC 目标重新搜索**超参数, 但 NGBoost 对超参数相对不敏感, 且 637 棵浅树 (depth=5) 的配置在概率提升中属于稳健的默认区间。训练全程仅约 1 分钟, 是 10 个模型中训练最快的之一。

训练过程

日志记录了 600 轮迭代的训练损失走势:


迭代	loss	scale	norm
0	1.4929	1.000	1.050
200	-0.1056	1.000	0.469
400	-0.4636	0.500	0.206
600	-0.6786	0.500	0.195

训练损失 (基于 LogScore 的负对数似然) 从 1.49 单调降至 -0.68, `norm` (每轮梯度更新的范数) 从 1.05 收缩至 0.195, 说明自然梯度 boosting 稳定收敛、每一步更新幅度逐步收窄。日志中 `val_loss` 恒为 0.0000, 这是概率输出的验证集指标未按相同口径记录的日志细节, 不影响最终测试评估的可靠性。

测试结果

指标	值
Test RMSE	0.4150
Test MAE	0.2853
Test R ²	0.8605
预测分布	Normal (均值 $\pm$ 标准差)
平均预测标准差	0.1432

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test MSE = 0.1723 与之印证。**平均预测标准差 0.1432 是一个极具价值的输出**：它表示模型对测试集中每个分子的 pCMC 预测，平均认为有 ~68% 的把握落在 ± 0.14 的区间内——将预测不确定性与点估计一并交付，这在后续实验中可作为置信度筛选依据。


特征重要性

日志尝试输出特征重要性时出现 `unexpected shape (2, 522), skipping` ——这是因为 NGBoost 的基学习器输出 **2 个分布参数**（均值与方差），其重要性权重为 2×522 的结构，现有日志代码未适配该形状而跳过。这属于**日志展示层面的缺失**，而非模型问题。基于其余模型的一致性证据，可推断均值参数的预测仍主要由 LogP、HeavyAtoms、MolWt 等疏水性/尺寸描述符驱动。

SHAP 特征重要性可视化（基于测试集的 KernelExplainer 归因，NGBoost 无原生 TreeExplainer）：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *LogP*、*HeavyAtoms*、*tail_ratio* 居前。

结论与评价

优点： - **概率输出：**同时给出均值与不确定性，是 10 个模型中唯一能评估单点预测置信度的模型，工程价值最高。 - 精度第 2 ($R^2 = 0.8605$)，仅次于 CIF，且差距很小 (RMSE 差 0.022)。 - 训练极快 (约 1 分钟)，无调参开销。

不足： - 未针对 pCMC 重新调参 (沿用预调参数)，理论上还有优化空间。 - 特征重要性展示缺失 (形状未适配)，可解释性文档化不完整。 - 相比点估计模型 (CIF/XGBoost)，均值预测的极致精度略有折衷 (概率模型需同时拟合方差)。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R ²
1	CIF (ExtraTrees)	0.3928	0.8751
2	NGBoost	0.4150	0.8605
3	XGBoost	0.4199	0.8572
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543

NGBoost 是“精度 + 不确定性”双重需求下的**首选模型**：当用户不仅要 pCMC 预测值、还要知道该预测有多可靠时，NGBoost 优于精度略高的 CIF。**推荐将 NGBoost 作为 CIF 之外的互补预测器**，两者对比可用于识别预测置信度低的分子。