

# pCMC\_rf\_report 模型报告

## RandomForest 模型报告 — pCMC 预测

### 报告信息

| 项目     | 内容                                |
|--------|-----------------------------------|
| 目标变量   | pCMC (log CMC)                    |
| 运行目录   | runs\pCMC\pCMC_rf_20260802_172839 |
| 运行时间   | 2026-08-02 17:28 ~ 17:34 (约 6 分钟) |
| 特征类型   | PharmHGT 522 维手工特征                |
| 报告生成日期 | 2026-08-02                        |

### 概述

RandomForest (随机森林) 是最经典的 bagging 集成：对训练集做有放回抽样 (bootstrap) 训练多棵决策树，每棵树在每个分裂点从随机特征子集中选择最优切分，最终取平均。相比其“姊妹模型” ExtraTrees (CIF)，随机森林**在最优切分点中选择**，单树更强但方差更大，在 522 维高维特征上更依赖正则约束。

在 pCMC 任务中，RandomForest 的 Test  $R^2 = 0.8128$ 、Test RMSE = 0.4808，在 10 个模型中排名第 9 (仅优于 Transformer)，是精度较弱的传统模型。

### 数据与方法

- 特征**: 522 维 PharmHGT 风格特征，从缓存加载 ([Cache HIT])，与其余模型一致。
- 数据规模**: 训练集 1204 条 (1053 训练 + 151 验证)，测试集 140 条。

- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

## 超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (与 CIF 共用同一搜索空间) 。

**最优试验 (Trial 13, CV RMSE = 0.5200) :**

| 参数                | 值            |
|-------------------|--------------|
| n_estimators      | 633          |
| max_depth         | 24           |
| min_samples_split | 3            |
| min_samples_leaf  | 2            |
| max_features      | None (用全部特征) |
| bootstrap         | True         |
| max_samples       | 0.732        |

**调优过程观察:** - 50 轮中多达 **25 轮被 MedianPruner 剪枝** (一半试验) , 且多数集中在搜索中段, 说明 RF 的 CV 收敛很慢——因为树多、每轮 CV 慢, 且剪枝后剩余试验集中在少数方向。 - 搜索明确收敛到 `max_features=None` (**全特征**) + `bootstrap=True` + `max_samples≈0.73` (**部分样本**) 的组合: 全部特征保证单树信息量, bootstrap + 子采样控制树间方差。早期 `max_features='sqrt'/'log2'` 的试验表现差 (CV RMSE 0.65~0.81) 。 - 最终配置与 CIF (ExtraTrees) 形成**关键对照**: CIF 收敛到 `bootstrap=False` , 而 RF 需要 `bootstrap=True` 才能达到相近的方差控制——这正是 ExtraTrees 用“随机切分阈值”换取方差抑制、而随机森林必须依赖自助采样实现同样的效果。


## 训练过程

RF 为一次性集成训练 (无迭代、无早停) , `Training Final Model` 后直接输出测试评估。由 CV (0.5200) 与 Test (0.4808) 对比, 测试表现优于交叉验证, 泛化正常。

## 测试结果

| 指标                  | 值             |
|---------------------|---------------|
| Test RMSE           | <b>0.4808</b> |
| Test MAE            | <b>0.3355</b> |
| Test R <sup>2</sup> | <b>0.8128</b> |
| Best CV RMSE        | 0.5200        |

图：预测值 vs 真实值散点图与残差图见 [pred\\_vs\\_true.png](#)。



Test MSE = 0.2311，在 10 个模型中偏高（仅次于 Transformer），说明 RF 对 pCMC 的拟合精度有限。Test MAE = 0.3355 同样是倒数第二（仅优于 Transformer），预测残差整体偏大。


## 特征重要性 (Top 20)

RF 输出不纯度加权重重要性，与 CIF 一样**高度分散**（Top 1 仅 0.2，多数近 0），相对排序仍有意义：


1. **LogP** (0.2) — 脂水分配系数
2. **HeavyAtoms / NAtoms / MolWt** (0.1) — 分子尺寸类
3. **atom\_std\_35 / maccs\_101 / tail\_ratio / head\_ratio** (0.0) — 次级特征

排序与此前 CatBoost/CIF 的结论一致（LogP 与分子尺寸主导），此处不再赘述物理含义。值得注意的是 head\_ratio 与 tail\_ratio 均进入前 20，与 LightGBM 的结论相互印证，支持“头-尾结构比率”对 CMC 的重要作用。

**SHAP 特征重要性可视化**（基于测试集的 TreeExplainer 归因）：



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



*Top-20 平均 |SHAP| 条形图：LogP 领先，其余特征重要性分布较分散（与日志观察一致）。*

## 结论与评价

**优点：** - 无需数据预处理、无迭代训练，模型稳定、几乎不可调参失败。 - 训练快（约 6 分钟含调参），baseline 级可用。

**不足：** - **精度偏弱** ( $R^2 = 0.8128$ ，排名第 9)，显著落后于同类 ExtraTrees (CIF, 0.8751) ——同一搜索空间下，随机森林因“选最优切分”方差较大、在 522 维连续特征上欠拟合。 - 50 轮调参中一半被剪枝，搜索效率低。 - 点估计，无概率输出，特征重要性绝对值近零。

**横向定位（10 个模型中按 Test RMSE 排序）：**

| 排名 | 模型                  | Test RMSE     | Test R <sup>2</sup> |
|----|---------------------|---------------|---------------------|
| 7  | HistGB              | 0.4609        | 0.8280              |
| 8  | RNN                 | 0.4664        | 0.8239              |
| 9  | <b>RandomForest</b> | <b>0.4808</b> | <b>0.8128</b>       |
| 10 | Transformer         | 0.6136        | 0.6951              |

RF 与 CIF 的差距 (RMSE 差 0.088、R<sup>2</sup> 差 0.062) 是本次任务中最有启发性的对照组之一：**在同样的搜索空间与数据下，ExtraTrees 的随机切分策略显著优于随机森林的最优切分策略**。若需随机森林家族，直接采用 CIF 即可获得更好结果，RandomForest 适合作为兼容性 baseline 保留。