

pCMC_rnn_report 模型报告

RNN (LSTM) 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_rnn_20260802_173512
运行时间	2026-08-02 17:35 ~ 17:41 (约 6 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

RNN 使用 **3 层 LSTM** 处理 522 维特征向量。本项目对深度序列模型有一个特殊设计：**将 522 维特征向量重塑为 (batch, 522, 1)，即把每个特征维度当作一个时间步、逐维送入 LSTM** (Deep models treat 522-dim vector as sequence)。LSTM 因此沿“特征轴”顺序读取 522 个时间步，最终隐藏状态经线性层映射为 pCMC。

这一设计的前提是**特征维度之间存在可被顺序建模的“序列依赖”**。但 522 维 PharmHGT 特征由原子聚合、键聚合、MACCS、BRICS、头尾比、描述符等**异构模块拼接**而成，维度间并无自然的时序关系——这是 RNN 在本任务中偏弱的结构性原因。

在 pCMC 任务中，RNN 的 Test $R^2 = 0.8239$ 、Test RMSE = 0.4664，排名第 8，是深度模型中表现次优者（仅优于 Transformer）。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

RNN 使用**固定架构, 不经过 Optuna**:

参数	值
LSTM 层数	3
hidden_dim	64
dropout	0.2
激活	relu (LSTM 内部)
learning_rate	1e-3
weight_decay	1e-5
batch_size	32
训练轮数	800

固定超参意味着模型容量与训练策略未针对 pCMC 优化, hidden_dim=64 对 522 维输入而言容量偏小, 是该模型精度受限的因素之一。

训练过程

日志记录了每 50 轮的验证 RMSE, **训练曲线呈现明显震荡**:

Epoch	Val RMSE	备注
50	1.176	初始
100	1.188 (best 0.967)	早期震荡
200	1.176 (best 0.886)	波动
350	0.855	开始下降
500	0.663 (best 0.658)	缓慢收敛
700	0.589	继续下降
800	0.628 (best 0.5611)	末轮回升

关键观察： - 验证 RMSE 在 epoch 50~250 间**反复在 0.86~1.19 之间震荡**，未出现单调下降，说明 LSTM 在 1053 条小样本上优化不稳定（梯度震荡/学习率偏大）。 - epoch 300 后才进入稳定下降阶段，最终在 epoch 800 达到 best val RMSE = 0.5611。 - 800 轮训练到末轮验证损失仍有回升，说明**尚未充分收敛**；若放宽训练轮数或降低学习率，或可进一步改善。

测试结果

指标	值
Test RMSE	0.4664
Test MAE	0.3550
Test R ²	0.8239
Best val RMSE	0.5611

说明：本次 RNN 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

Test RMSE (0.4664) 明显优于验证最佳 (0.5611)，说明最终模型在测试集上泛化尚可，但 MAE = 0.3550 在 10 个模型中偏高（倒数第三），存在系统性偏差。

特征重要性

LSTM 为黑盒循环网络，日志无特征重要性输出。其“逐维读入”的机制使每个特征维度等价地参与时序传播，**无法区分特征主次**——这与 CatBoost/HistGB 明确指向 LogP 等主导特征形成对比，也是其可解释性不足的体现。

结论与评价

优点： - 验证了“序列化 522 维特征”路线的可行性，作为深度模型的探索性 baseline 有价值。 - 训练仅 6 分钟，成本低。

不足： - **特征维度无自然时序关系**，LSTM 的序列假设与本任务特征结构不匹配，是性能瓶颈的结构性问题。 - 训练曲线震荡剧烈，优化不稳定；800 轮仍未充分收敛。 - $R^2 = 0.8239$ （第 8），明显落后于同为深度网络的 MLP（0.8543）——MLP 直接全连接建模非线性，比强行序列化更契合 522 维扁平特征。 - 无超参调优、hidden 容量小，进一步限制上限。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
6	LightGBM	0.4311	0.8495
7	HistGB	0.4609	0.8280
8	RNN	0.4664	0.8239
9	RF	0.4808	0.8128
10	Transformer	0.6136	0.6951

RNN 的教训对本项目具有方法论价值：**手工特征 + 深度模型的正确组合是 MLP 式全连接（直接建模特征间非线性），而非 LSTM/Transformer 式序列化**。后者在本数据上既慢又不稳，除非特征本身具有可解释的序列结构（如逐原子顺序），否则不建议采用。当前 RNN 定位为方法学对照，不推荐作为生产预测器。