

pCMC_transformer_report 模型报告

Transformer 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_transformer_20260802_174306
运行时间	2026-08-02 17:43 ~ 18:42 (约 59 分钟)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

Transformer 采用 **3 层 Transformer Encoder** ($d_{\text{model}}=128$ 、4 头注意力、FFN 256、GELU 激活)，与 RNN 相同，将 522 维特征向量重塑为 (batch, 522, 1) 的序列输入，通过**自注意力机制**建模特征维度间的依赖关系，末层池化后映射为 pCMC。训练使用 CosineAnnealingLR 学习率调度与梯度裁剪 ($\text{grad_clip}=5.0$)。

在 pCMC 任务中，Transformer 的 $\text{Test } R^2 = 0.6951$ 、 $\text{Test RMSE} = 0.6136$ ，**在 10 个模型中排名最末**，且与倒数第二的 RF (0.4808) 差距显著 (RMSE 差 0.13)，是唯一未能达到 $R^2 > 0.8$ 的模型。

数据与方法

- 特征**: 522 维 PharmHGT 风格特征，从缓存加载 ([Cache HIT])，与其余模型一致。

- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

Transformer 使用**固定架构, 不经过 Optuna**:

参数	值
d_model	128
Encoder 层数	3
注意力头数	4
FFN 维度	256
激活	GELU
learning_rate	1e-3
weight_decay	1e-5
batch_size	16
训练轮数	500
调度器	CosineAnnealingLR
梯度裁剪	5.0

固定超参 + 小 batch (16) + 单头规模 128, 整体容量与训练策略均未针对 522 维小样本优化。

训练过程

日志记录了每 5 轮的验证 RMSE, **收敛极其缓慢**:

Epoch	Val RMSE	阶段
5	0.965	初始
40	0.736	早期下降
75	0.635	中期
160	0.611	慢速爬行
315	0.566	后期
395	0.550	最优
500	0.566	末轮

关键观察： - 经过 **395 个 epoch** 验证 RMSE 才达到 0.5501 的最优值，且全程波动、收敛速度极慢；0.965 → 0.55 的下降跨越了近 400 轮，说明模型在小样本上每轮学到的有效信息很少。 - 即便 500 轮训满，验证 RMSE 也**始终未低于 0.55**，远差于 MLP（best val 0.448）——注意力机制在 522 个“伪时间步”上建立依赖的成本极高、收益极低。 - 训练耗时约 1 小时，是深度模型中成本最高的，而效果最差，性价比严重失衡。

测试结果

指标	值
Test RMSE	0.6136
Test MAE	0.4386
Test R ²	0.6951
Best val RMSE	0.5501

说明：本次 Transformer 运行**未生成** pred_vs_true 预测-真值散点图与 SHAP 图（该训练脚本未输出绘图文件）。如需可视化，可复用缓存特征另行绘制。

关键信号：Test RMSE (0.6136) 劣于 Best val RMSE (0.5501) ——这是 10 个模型中唯一“测试差于验证”的模型（其余模型多为测试优于验证），说明 Transformer 在测试集上**泛化失效**，存在过拟合或对测试分布适配不良。Test MSE = 0.3765 为全模型最高，MAE = 0.4386 同样垫底。

特征重要性

Transformer 依赖注意力权重，但日志未输出注意力归因。其自注意力会为 522 个特征维度计算两两关联，理论上可做可解释性分析（attention rollout），但本项目未生成相应图。鉴于模型整体失效，其特征级解释的参考价值有限。

结论与评价

优点： - 作为注意力机制的探索性 baseline，验证了“序列化 + 自注意力”路线在本任务的**不适用性**，为后续方法选择提供了明确的反面证据。

不足： - **性能垫底**： $R^2 = 0.6951$ 为全模型最低，且唯一测试劣于验证，泛化失效。 - 收敛极慢（395 轮才见底），训练 1 小时成本最高、收益最低。 - 与 RNN 相同的结构性问题：522 维异构特征**无自然序列关系**，自注意力建模的“依赖”缺乏物理意义；而 Transformer 参数量大、对 1053 条小样本更容易过拟合。 - 固定超参未优化，小 batch + 大模型加剧了不稳定性。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R^2
8	RNN	0.4664	0.8239
9	RF	0.4808	0.8128
10	Transformer	0.6136	0.6951
—	MLP（对照）	0.4241	0.8543

方法论结论： 三个深度模型（MLP 0.8543 / RNN 0.8239 / Transformer 0.6951）的排序清晰地说明——对 522 维 PharmHGT 扁平特征，**全连接（MLP）» 循环（LSTM）» 注意力（Transformer）**。Transformer 的强项在于长程依赖与大规模预训练，而本任务样本量小、特征维度排列无时序意义，恰恰落在其能力盲区。**Transformer 应被排除出本项目的生产预测方案**；若未来引入图结构（AttentiveFP）或大分子表示，方可重新评估注意力路线的价值。