

pCMC_xgboost_report 模型报告

XGBoost 模型报告 — pCMC 预测

报告信息

项目	内容
目标变量	pCMC (log CMC)
运行目录	runs\pCMC\pCMC_xgboost_20260802_201550
调参日志	runs\pCMC\pCMC_xgboost_20260802_193437\train.log (Optuna 200 轮)
运行时间	调参 19:34 ~ 20:08 (约 34 分钟) , 最终运行 20:15 ~ 20:20
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-02

概述

XGBoost 是陈天奇提出的梯度提升框架，以其对**二阶泰勒展开**、稀疏感知与列块并行的实现著称。本项目为 XGBoost 配置了**全模型最复杂的调参管线**：200 轮 Optuna × 5 折 CV (CV 样本 1083) , 配合 **Top-K holdout 泛化性筛选** (独立 holdout 121 样本 + 训练-验证差距惩罚, 防止过拟合的“虚高”参数被选中) 。

在 pCMC 任务中, XGBoost 的 Test $R^2 = 0.8572$ 、Test RMSE = 0.4199, 在 10 个模型中排名第 3, 处于第一梯队 (CIF、NGBoost 之后) 。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练集 1204 条 (1053 训练 + 151 验证) , 测试集 140 条; 调参阶段进一步划分 CV 1083 / Holdout 121。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

当前运行使用预调优参数 (Using pretuned hyperparameters (skipping Optuna + Top-K)) , 来源为旧调参日志 (200 轮 Optuna 的 Trial 128) :

参数	值
n_estimators	1636
max_depth	6
learning_rate	0.0203
subsample	0.766
colsample_bytree / bylevel / bynode	0.821 / 0.676 / 0.537
min_child_weight	1.241
gamma	0.0227
reg_alpha / reg_lambda	0.154 / 0.0021
max_delta_step	0.981
booster	dart

Optuna 参数重要度 (旧调参日志) :

参数	重要度
gamma	0.7991
max_delta_step	0.0802
colsample_bynode	0.0296
max_depth	0.0274
其余 (colsample_bytree 等)	< 0.02

参数重要度显示 **gamma (分裂最小损失增益)** 对 XGBoost 表现的影响压倒性 **(0.80)**，这是本项目所有模型中单个参数重要度最高的信号——说明 522 维特征上的分裂极易过拟合，**必须依赖 gamma 强制每次分裂带来足够的信息增益**。最终参数 `booster='dart'` (drop-out 正则化提升) 与保守的 `max_depth=6`、`gamma=0.023` 相互印证了这一判断。


训练过程

- **调参阶段 (旧日志)**：200 轮 Optuna 从 Trial 0 的 0.558 收敛至 Trial 128 的 **CV RMSE = 0.4916**，随后进入 Top-K holdout 筛选（选择在独立 holdout 上表现最泛化的参数，而非仅 CV 最优），体现项目对过拟合的一贯警惕。
- **最终训练 (当前日志)**：直接以预调优参数在 1053 条训练集上训练（无 Optuna、无早停重复），输出测试评估。日志中 Top-20 特征重要度全部为 0.0，属于 dart booster + 重要性输出口径的展示问题（详见下节），不影响模型本身。

测试结果

指标	值
Test RMSE	0.4199
Test MAE	0.2849
Test R ²	0.8572
参考 CV RMSE (调参时)	0.4916


图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。




Test RMSE (0.4199) 显著优于调参 CV (0.4916) , 且 MAE (0.2849) 是 10 个模型中最低的, 说明其预测残差整体最小、对多数分子都接近真实值。Test MSE = 0.1763 与之印证。

特征重要性 (说明)

当前日志输出的 Top-20 特征重要度**数值全部为 0.0**, 但排序仍指示 LogP、NAtoms、HeavyAtoms、MolWt 等疏水性/尺寸描述符与 MACCS 药效团特征靠前——这与 CatBoost/CIF/HistGB 的特征排序**高度一致**。数值归零的原因是 dart 模式下模型对特征重要性 (默认 weight/分类型) 的口径输出异常, 属于**日志展示缺陷**; 若要精确归因, 应改用 `shap_xgboost.py` 的 SHAP 分析 (TreeExplainer) 。下方 SHAP 图即为该分析的实测结果, 可据此完成精确归因:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: LogP、HeavyAtoms、NAtoms 位列前三, 与其余树模型结论一致。

结论与评价

优点: - 精度第 3 ($R^2 = 0.8572$) , 与 NGBoost (0.8605) 几乎持平, 且 **MAE 全模型最低** (0.2849) 。 - 最严谨的调参流程 (200 轮 + Top-K 泛化筛选 + 差距惩罚) , 参数选择可信度高、过拟合风险被主动压制。 - 参数重要度 (gamma=0.80) 给出极具洞察的结论, 指导了后续正则方向。

不足: - 调参成本高 (200 轮约 34 分钟 + 后续训练) , 在 10 个模型中耗时前列。 - dart booster 的特征重要性输出异常, 可解释性文档化需依赖 SHAP 补充。 - 相对 CIF (0.3928) 仍有 0.027 的 RMSE 差距, 未登顶。

横向定位 (10 个模型中按 Test RMSE 排序) :

排名	模型	Test RMSE	Test R ²
1	CIF (ExtraTrees)	0.3928	0.8751
2	NGBoost	0.4150	0.8605
3	XGBoost	0.4199	0.8572
4	CatBoost	0.4235	0.8548
5	MLP	0.4241	0.8543

XGBoost 与 CatBoost 几乎并列 (RMSE 差 0.004) , 是**稳健的高精度选择**; 其 MAE 优势 (0.2849 vs CatBoost 0.2953) 意味着在“多数分子都预测准”的语义下表现更优。作为调参最充分的模型, XGBoost 适合作为**精度基准**; 若追求极致精度可优先 CIF, 追求不确定性可优先 NGBoost。