

Pi_CMC CatBoost 模型报告

CatBoost 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_catboost_20260806_155128
运行时间	15:51 ~ 17:09 (约 1 小时 18 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CatBoost 是 Yandex 推出的梯度提升库, 核心创新在于**对称树 (oblivious tree)** 与**有序目标编码 (ordered target statistics)**, 对类别特征友好且几乎无需调参即可取得稳定结果。本项目以 522 维稠密数值特征为输入, 使用 Optuna 50 轮 $\times$ 5 折交叉验证搜索 `depth / learning_rate / iterations / l2_leaf_reg` 等关键超参。

在 Pi_CMC 任务中, CatBoost 的 Test $R^2 = 0.6424$ 、Test RMSE = 4.3069, 在 10 个模型中**排名第 2**, 与榜首 XGBoost (4.2675) 仅差 0.0395, 同属第一梯队 ($R^2 \approx 0.64$)。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 本次运行**缓存未命中** ([Cache MISS]), 现场计算并写缓存, 631/631 与 70/70 分子全部有效。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 16, CV RMSE = 3.7878) :

参数	值
depth	9
learning_rate	0.02024
iterations	964
l2_leaf_reg	1.8127
random_strength	4.3621
bagging_temperature	3.5595
border_count	207
one_hot_max_size	35
leaf_estimation_iterations	8
min_data_in_leaf	47
Best CV RMSE	3.7878

Optuna 参数重要度:

参数	重要度
l2_leaf_reg	0.2946
depth	0.2036
random_strength	0.1142
one_hot_max_size	0.1127
min_data_in_leaf	0.1084
learning_rate	0.0814
其余 (iterations 等)	< 0.05

调优过程观察： - 最优解集中在 **depth=9、learning_rate≈0.02、iterations≈1000** 的组合，属中等深度 + 慢学习率的稳健配置；50 轮中有约 20 轮被剪枝，说明搜索有效避开了明显次优的深度-学习率组合。 - 参数重要度显示 **l2_leaf_reg (叶节点 L2 正则, 0.295) 与 depth (0.204) 合占近半**——在 Pi_CMC 这一样本量较小的任务 (CV 552) 上，控制模型复杂度 (正则 + 树深) 是决定泛化的首要因素，与 XGBoost 中 min_child_weight 居首的结论相互印证。 - one_hot_max_size=35 表明对少数低基数特征仍保留 one-hot 编码能力；min_data_in_leaf=47 较高，进一步抑制小样本上的分裂过拟合。


训练过程

- **调参阶段：**50 轮 Optuna 从 Trial 0 的 CV RMSE 3.9780 收敛至 Trial 16 的 **3.7878**，后续 30 余轮未见显著改进，搜索收敛。
- **最终训练：**以最优参数在 552 条训练集上训练，**早停在第 417 轮触发** (overfitting detector, 150 轮无改进即停)，`bestTest = 4.7427`，最终模型收缩为前 418 轮 (Shrink model to first 418 iterations)。学习曲线显示训练损失 (learn) 持续降至 1.1 而验证损失在 400 轮附近触底，早停机制有效防止了过拟合蔓延。

测试结果

指标	值
Test RMSE	4.3069
Test MAE	2.9607
Test R ²	0.6424
参考 CV RMSE (调参时)	3.7878
Best val RMSE (早停迭代)	4.7427

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.3069) 介于调参 CV (3.7878) 与早停验证 (4.7427) 之间，处于正常泛化区间。Test MSE = 18.5491 与之印证。CatBoost 的 $R^2 = 0.6424$ 位列第 2，MAE (2.9607) 与 XGBoost (2.9343) 几乎持平，是第一梯队中稳健的精度选择。


特征重要性 (Top 20)

日志输出的 gain 特征重要度前五 (Top 20 头部)：


1. **brics_30** (2.7) —— BRICS 片段反应活性描述符
2. **HBD** (1.8) —— 氢键供体数量
3. **MolWt** (1.6) —— 分子量
4. **atom_mean_44** (1.6) —— 原子特征聚合 (均值)
5. **atom_mean_3** (1.4) —— 原子特征聚合 (均值)

头部特征分布比 pCMC 任务更**分散**（前五仅 2.7~1.4，无一家独大的强信号），其余还包括 `atom_mean_52`、`bond_mean_3`、`atom_std_29`、`head_ratio`、`NAtoms` 等。**物理分析**：Pi_CMC（表面压 = $\gamma_0 - \gamma_{\text{CMC}}$ ）由表面活性剂把表面张力压低的效率决定，`HBD`（头基氢键供体）与 `head_ratio`（头基原子占比）的入选表明**极性头基的氢键能力与头尾比例**直接调控界面吸附层的分子间作用力；`MolWt / NAtoms` 反映分子尺寸对吸附量的影响；`brics_30` 作为反应活性片段则体现了特定结构基元对表面活性的贡献。

SHAP 分析（TreeExplainer）给出的 top-5 依赖图为 `brics_30`、`HBD`、`atom_std_38`、`surf_cationic`、`bond_std_12`，与 gain 排序大致呼应，并额外凸显了 **surf_cationic（阳离子表面活性剂类型）** 的重要性——电荷类型对界面吸附的影响在 Pi_CMC 上比 pCMC 更显著：



SHAP 蜜蜂图: 每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: brics_30、HBD 等靠前, 与 gain 排序一致。

结论与评价

优点: - 精度第 2 ($R^2 = 0.6424$, Test RMSE = 4.3069), 与榜首 XGBoost 仅差 0.0395, 属第一梯队。 - MAE (2.9607) 与 XGBoost 几乎持平, 多数分子预测残差小。 - 早停 + 较高 min_data_in_leaf + l2_leaf_reg 三重防过拟合, 泛化稳健; 对称树训练效率高。

不足: - 调参成本较高 (50 轮 5 折 CV 约 1 小时 18 分钟, 为同梯队模型中最耗时)。 - 相对 XGBoost 仍有 0.0395 的 RMSE 差距, 未登顶。 - $R^2 = 0.6424$ 仍属中上水平, 对 Pi_CMC 高值区间的残差偏大。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
1	XGBoost	4.2675	0.6489
2	CatBoost	4.3069	0.6424
3	NGBoost	4.3943	0.6277
4	LightGBM	4.4858	0.6121

CatBoost 与 XGBoost 构成 Pi_CMC 的第一梯队 ($R^2 \approx 0.64$)，二者几乎并列。若追求最优 MAE 可优先 XGBoost；CatBoost 的对称树在稳定可复现与防过拟合上同样值得信赖，是**稳健的高精度选择**。