

Pi_CMC CIF (ExtraTrees) 模型报告

CIF（条件推理森林 / ExtraTrees）模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_cif_20260806_171025
运行时间	17:10 ~ 17:13 (约 3 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

CIF (Conditional Inference Forest) 在此实现中由 **ExtraTrees (极端随机树)** 承载：不同于标准随机森林在最优切分点中做选择，ExtraTrees 在每个节点**随机生成切分阈值**，从而进一步降低方差、抑制过拟合。本项目 522 维特征以连续型描述符为主，ExtraTrees 对连续特征的随机切分策略尤其高效，且训练开销极低。

在 Pi_CMC 任务中，CIF 的 Test $R^2 = 0.6119$ 、Test RMSE = 4.4869，在 10 个模型中**排名第 5**，与第 4 名 LightGBM (4.4858) 几乎并列，位于第二梯队头部（该模型在 pCMC 任务中曾为综合最优，但 Pi_CMC 上表现回落）。

数据与方法

- **特征**：522 维 PharmHGT 风格特征，从缓存加载（[Cache HIT]），与其余 9 个模型完全一致，保证公平对比。
- **数据规模**：训练池 631 条（552 训练 + 79 验证），测试集 70 条。
- **数据划分**：`train_test_split(0.125, random_state=42)`，固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证**。

最优试验 (Trial 33, CV RMSE = 3.8665) :

参数	值
n_estimators	845
max_depth	14
min_samples_split	5
min_samples_leaf	3
max_features	None（用全部特征）
bootstrap	False
Best CV RMSE	3.8665

调优过程观察： - 前 8 轮表现很差（CV RMSE 4.88~6.07），原因是最优参数搜索初期倾向于 `bootstrap=True` + `max_features='sqrt'/'log2'` 的组合——对 522 维连续特征而言，随机子集特征容易丢失关键描述符，且自助采样引入额外噪声。 - 搜索快速收敛到 `bootstrap=False` + `max_features=None`（全特征）+ `min_samples_leaf=3` 的区域，Trial 33 触底至 3.8665，Trial 42~49 稳定在 3.92~4.03，搜索收敛。 - 50 轮中约 20 轮被 MedianPruner 剪枝，整体训练仅耗时约 3 分钟，**调参效率为 10 个模型中最高之一**。


训练过程

由于 ExtraTrees 是**非迭代式**集成（一次性训练全部树、取平均），日志中无逐轮 loss 曲线，`Training Final Model` 阶段直接输出结果。这意味着： - 无过拟合检测器、无早停需求，超参确定后即一次成型； - 训练时间几乎全部来自 Optuna 搜索阶段，最终模型训练仅数秒。

测试结果

指标	值
Test RMSE	4.4869
Test MAE	2.9857
Test R ²	0.6119
Best CV RMSE	3.8665

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.4869) 高于 CV RMSE (3.8665)，存在一定的测试-调参差距（约 16%），说明 Pi_CMC 上该模型不如 pCMC 任务（测试优于 CV）那般占优。Test MSE = 20.1321 与之印证。CIF 的 $R^2 = 0.6119$ 位列第 5，与 LightGBM 几乎并列。


特征重要性 (Top 20)

ExtraTrees 的 `feature_importances_` 基于分裂减少不纯度加权，且因为切分阈值随机，重要度分布**高度分散**（Top 1 仅 0.1），绝对值参考意义有限，但**相对排序**仍具指示性：


1. **atom_mean_44** (0.1) — 原子特征聚合（均值，Gasteiger 电荷类）
2. **maccs_28** (0.0) — MACCS 药效团子结构键
3. **bond_mean_3** (0.0) — 键特征聚合（均值）
4. **maccs_111** (0.0) — MACCS 药效团子结构键
5. **atom_std_44** (0.0) — 原子特征聚合（标准差）

物理分析：与 pCMC 任务 (LogP/HeavyAtoms 等全局描述符主导) 不同, CIF 在 Pi_CMC 上的头部特征转向 **原子聚合统计 (atom_mean_44 / atom_std_44, 电荷类) + MACCS 药效团 (maccs_28 / maccs_111) + 键级聚合 (bond_mean_3)**, 与 CatBoost/HistGB 的结论呼应——Pi_CMC 更依赖**极性基团的电荷/药效团信息**而非单纯疏水链长度。surf_nonionic (非离子类型) 与 HBD (氢键供体) 亦进入 Top-20, 提示表面活性剂类型与氢键能力对表面压的贡献。

SHAP 分析 (TreeExplainer) 给出的 top-5 依赖图为 maccs_111、atom_mean_44、bond_mean_3、surf_nonionic、maccs_28, 与排序大致呼应：



SHAP 蜜蜂图：每个点是一个测试样本, x 轴为 SHAP 值, 颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *maccs_111*、*atom_mean_44*、*bond_mean_3* 靠前。

结论与评价

优点： - 训练/调参极快（约 3 分钟），几乎无调参成本，调参效率为 10 个模型中最高之一。 - 无迭代、无早停，训练确定性高，结果可复现性强。 - 随机切分抑制过拟合，对 522 维高维连续特征鲁棒；MAE (2.9857) 在树模型中偏低，多数分子预测残差较小。

不足： - 特征重要性绝对值近零、分散，难以做精确的逐特征归因（相对排序仍可靠）。 - 相对第一梯队 (XGBoost/CatBoost) 有约 0.18~0.22 的 RMSE 差距，未进入 $R^2 \approx 0.64$ 梯队。 - 预测为点估计，**不提供不确定性度量**（对比 NGBoost 可输出方差）。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
3	NGBoost	4.3943	0.6277
4	LightGBM	4.4858	0.6121
5	CIF (ExtraTrees)	4.4869	0.6119
6	HistGB	4.5919	0.5935
7	RandomForest	4.7542	0.5642

CIF 与 LightGBM 几乎并列构成第二梯队头部。CIF 在 pCMC 任务上曾登顶，但 Pi_CMC 上表现回落，说明**不同目标的最佳模型并不一致**；在 Pi_CMC 上，若偏好低训练成本的稳健树模型，CIF 仍是性价比高的选择。