

Pi_CMC HistGB 模型报告

HistGB 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_histgb_20260806_171314
运行时间	17:13 ~ 17:39 (约 26 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

HistGB (`sklearn.ensemble.HistGradientBoostingRegressor`) 是 scikit-learn 自 0.21 起引入的梯度提升实现, 采用**直方图分箱**与**分箱级别的梯度统计**加速训练, 并原生支持**早停与内置缺失值处理**, 是 LightGBM 思想的 sklearn 官方实现。本项目以 522 维稠密数值特征为输入, 使用 Optuna 50 轮 $\times$ 5 折交叉验证搜索 `learning_rate / max_iter / max_depth / max_leaf_nodes` 等关键超参。

在 Pi_CMC 任务中, HistGB 的 Test $R^2 = 0.5935$ 、Test RMSE = 4.5919, 在 10 个模型中**排名第 6**, 位于第二梯队中段, 性能与 LightGBM/CIF 相当但略逊。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 33, CV RMSE = 4.0659) :

参数	值
learning_rate	0.11596
max_iter	651
max_depth	14
max_leaf_nodes	204
min_samples_leaf	5
l2_regularization	0.7430
max_bins	161
Best CV RMSE	4.0659

调优过程观察: - 最优解偏好深树 (**depth=14**) + **大量叶子节点 (204)** + **较小 min_samples_leaf (5)** , 配合中等学习率 (0.116) 与适度 L2 正则 (0.74) , 在充分建模特征交互的同时压制过拟合。 - Trial 0 的 CV RMSE 4.2074 已属不错, 搜索随后通过增大 max_leaf_nodes 与 max_depth 收敛到 4.07 附近; 50 轮中约 20 轮被剪枝, 搜索稳定收敛。


训练过程

- **调参阶段**: 50 轮 Optuna 内每轮 5 折 CV 早停收敛, CV RMSE 从 Trial 0 的 4.2074 收敛至 Trial 33 的 **4.0659**, 后续试验 (Trial 49 为 4.1052) 未见改进。
- **最终训练**: 以最优参数在 552 条训练集上训练, `max_iter=651` 由 sklearn 内置早停兜底 (日志未单独打印 best_iteration) , 随后直接进行测试评估。

测试结果

指标	值
Test RMSE	4.5919
Test MAE	3.0901
Test R ²	0.5935
参考 CV RMSE (调参时)	4.0659

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.5919) 高于调参 CV (4.0659)，存在一定的测试-调参差距，但处于可接受泛化范围。Test MSE = 21.0859 与之印证。HistGB 的 $R^2 = 0.5935$ 位列第 6，与第 4/5 名的 LightGBM/CIF 差距在 0.1 的 RMSE 以内。

特征重要性 (Top 20)

HistGB 采用置换重要性 (permutation-based) 口径，Top-5 特征 (Top 20 头部)：


1. **atom_std_44** (2.34 ± 0.52) —— 原子特征聚合 (标准差)
2. **atom_mean_46** (2.20 ± 0.31) —— 原子特征聚合 (均值)
3. **atom_std_52** (1.42 ± 0.16) —— 原子特征聚合 (标准差)
4. **atom_mean_24** (1.22 ± 0.19) —— 原子特征聚合 (均值)
5. **atom_mean_38** (1.02 ± 0.16) —— 原子特征聚合 (均值)

物理分析： HistGB 的重要性分布是树模型中最“分散”的一组——Top-20 几乎全部是 **原子级特征聚合 (mean/std)**，辅以 **tail_ratio** (第 9) 与 **maccs_111** (第 10)。这说明 HistGB 的预测依赖**大量原子局部统计特征的合力**


(电荷/电负性散布的均值与波动)，而非少数全局疏水性描述符；这与其 $\text{max_depth}=14$ 的深树结构相吻合——深树能逐层组合众多原子统计特征。

`atom_std_44 / atom_std_52` 的高标准差重要性提示**原子性质在分子内的不均匀分布**对 Pi_CMC 有显著影响，符合表面活性剂头尾两亲结构带来的性质梯度。


SHAP 分析 (TreeExplainer) 给出的 top-5 依赖图为 `atom_std_44`、`atom_mean_46`、`atom_std_52`、`atom_mean_24`、`maccs_111`，与置换重要性排序一致：



SHAP 蜜蜂图：每个点是一个测试样本， x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_std_44*、*atom_mean_46* 靠前, 与置换重要性一致。



SHAP 交互热图：展示头部特征两两交互对预测的影响。

结论与评价

优点： - sklearn 原生实现、内置早停与缺失值处理，工程集成方便、无额外依赖。 - 精度第 6 ($R^2 = 0.5935$)，与第 4/5 名差距在 0.1 以内，性能稳定可用。 - 置换重要性口径（带置信区间）比 gain 更稳健，可解释性文档质量高。

不足： - 相对第一梯队 (XGBoost/CatBoost) 有约 0.28~0.32 的 RMSE 差距，未进入 $R^2 \approx 0.64$ 梯队。 - 测试-调参差距 (4.5919 vs 4.0659) 偏大，深树配置 (depth=14、叶子 204) 在 552 样本上存在一定过拟合倾向。 - MAE (3.0901) 在树模型中偏高，中高值区间残差偏大。

横向定位 (10 个模型中按 Test RMSE 排序)：

排名	模型	Test RMSE	Test R^2
4	LightGBM	4.4858	0.6121
5	CIF (ExtraTrees)	4.4869	0.6119
6	HistGB	4.5919	0.5935
7	RandomForest	4.7542	0.5642
8	MLP	4.8837	0.5402

HistGB 与 LightGBM/CIF 构成第二梯队 ($R^2 \approx 0.59\sim0.61$)，彼此 RMSE 差距在 0.1 以内。作为 sklearn 官方实现，HistGB 在**零额外依赖、集成便捷**的约束下提供了可靠的基线性能，但精度峰值仍需第一梯队的 XGBoost/CatBoost。