

Pi_CMC LightGBM 模型报告

LightGBM 模型报告 — Pi_CMC 预测

报告信息

项目	内容
目标变量	Pi_CMC (CMC 时的表面压, $= \gamma_0 - \gamma_{\text{CMC}}$, 单位 mN/m)
运行目录	runs\Pi_CMC\Pi_CMC_lightgbm_20260806_174010
运行时间	17:40 ~ 17:42 (约 2 分钟, 含 Optuna 50 轮调参与最终训练)
特征类型	PharmHGT 522 维手工特征
报告生成日期	2026-08-07

概述

LightGBM 是微软开源的梯度提升框架, 以 **Leaf-wise (按叶子生长) 树**、**直方图分箱**与 **GOSS/EFB 采样**著称, 训练速度快、内存占用低。本项目以 522 维稠密数值特征为输入, 使用 Optuna 50 轮 $\times$ 5 折交叉验证搜索 `boosting_type / max_depth / num_leaves / learning_rate` 等关键超参。

在 Pi_CMC 任务中, LightGBM 的 Test $R^2 = 0.6121$ 、Test RMSE = 4.4858, 在 10 个模型中**排名第 4**, 与第 5 名 CIF (4.4869) 几乎并列, 位于第二梯队的头部。

数据与方法

- **特征**: 522 维 PharmHGT 风格特征, 从缓存加载 ([Cache HIT]), 与其余模型一致。
- **数据规模**: 训练池 631 条 (552 训练 + 79 验证) , 测试集 70 条。
- **数据划分**: `train_test_split(0.125, random_state=42)` , 固定随机种子。

超参数与调优

采用 **Optuna 50 轮 × 5 折交叉验证** (TPE 采样器 + MedianPruner) 。

最优试验 (Trial 45, CV RMSE = 4.0237) :

参数	值
boosting_type	gbdt
max_depth	12
num_leaves	115
learning_rate	0.03624
n_estimators	1749
subsample / freq	0.9262 / 6
colsample_bytree	0.5048
reg_alpha / reg_lambda	≈ 0 / $1.6e-4$
min_child_samples	11
min_split_gain	0.6819
cat_smooth / cat_l2	18.71 / 20.38

调优过程观察: - Trial 0 用 dart + 大 depth/大 num_leaves 时 CV RMSE 高达 21.94 (严重过拟合) , Trial 1 的 dart 也达 9.16; **搜索迅速转向 gbdt 并收敛到 4.02 附近**, 最终最优试验为 gbdt。 - 最优解偏好**较深的树 (depth=12)** + **较多叶子 (115)** , 但配合 `colsample_bytree=0.50` (列采样) 与 `min_split_gain=0.68` 控制分裂, 避免过拟合——说明在 522 维特征上, LightGBM 需要同时用“深树挖掘交互”和“列采样/分裂增益阈值”压制噪声。 - 50 轮中多数试验在 5 折内早停收敛, 每轮平均仅数秒, 整个调参约 2 分钟, 是 10 个模型中调参最快之一。


训练过程

- **调参阶段**：50 轮 Optuna 内，每轮 5 折 CV 均以“验证集 30 轮无改进即停”早停，CV RMSE 从 Trial 0 的 21.94 收敛至 Trial 45 的 **4.0237**。
- **最终训练**：以最优参数在 552 条训练集上训练，**早停在第 138 轮触发**（50 轮无改进等待），`bestIteration = 138`，验证集 RMSE = 4.8822。学习曲线显示验证损失在 ~140 轮即触底，训练高效收敛。

测试结果

指标	值
Test RMSE	4.4858
Test MAE	3.1482
Test R ²	0.6121
参考 CV RMSE（调参时）	4.0237
Best val RMSE（早停迭代）	4.8822

图：预测值 vs 真实值散点图与残差图见 [pred_vs_true.png](#)。



Test RMSE (4.4858) 介于调参 CV (4.0237) 与早停验证 (4.8822) 之间，处于正常泛化区间。Test MSE = 20.1220 与之印证。LightGBM 的 $R^2 = 0.6121$ 位列第 4，与第 5 名 CIF 仅差 0.0002，性能相当但训练成本低得多。


特征重要性 (Top 20)

日志输出的 gain 特征重要度前五 (Top 20 头部)：


1. **MolWt** (148.0) —— 分子量
2. **atom_mean_35** (132.0) —— 原子特征聚合 (均值)
3. **tail_ratio** (130.0) —— 尾碳占比
4. **LogP** (107.0) —— 脂水分配系数
5. **atom_std_25** (86.0) —— 原子特征聚合 (标准差)

物理分析: LightGBM 的特征排序是树模型中**最接近 pCMC 任务典型画像**的一组——**MolWt**、**LogP**、**HeavyAtoms**、**RotBonds** 等疏水性/尺寸描述符集体靠前, 且 **tail_ratio** (尾链占比) 进入前三, 直观呼应表面活性剂的**两亲结构**: 尾链越长、疏水体积越大, 表面活性剂在界面的吸附趋势越强, **Pi_CMC** 相应越高。
atom_mean_35 / atom_std_25 等原子聚合统计反映局部电负性与电荷散布对界面吸附层的作用。

SHAP 分析 (TreeExplainer) 给出的 top-5 依赖图为 **atom_mean_44**、**bond_mean_3**、**atom_std_52**、**atom_std_44**、**atom_mean_35**, 与 gain 排序大致呼应, 共同指向**原子局部统计与分子尺寸**的主导作用:



SHAP 蜜蜂图：每个点是一个测试样本，x 轴为 SHAP 值，颜色代表特征取值高低。



Top-20 平均 |SHAP| 条形图: *atom_mean_44*、*bond_mean_3* 等靠前。

结论与评价

优点： - **调参极快**（约 2 分钟），是 10 个模型中训练/调参成本最低的之一，性价比高。 - 精度第 4 ($R^2 = 0.6121$)，与第 5 名 CIF 几乎并列。 - 早停机制 + 列采样 + 分裂增益阈值多重重正化，泛化稳健。

不足： - 相对第一梯队 (XGBoost/CatBoost) 仍有约 0.18~0.22 的 RMSE 差距，未进入 $R^2 \approx 0.64$ 梯队。 - MAE (3.1482) 在树模型中偏高，说明存在中等偏差的预测点。 - 深树 (depth=12、叶子 115) 配置有轻微过拟合倾向，依赖早停兜底。

横向定位（10 个模型中按 Test RMSE 排序）：

排名	模型	Test RMSE	Test R ²
2	CatBoost	4.3069	0.6424
3	NGBoost	4.3943	0.6277
4	LightGBM	4.4858	0.6121
5	CIF (ExtraTrees)	4.4869	0.6119
6	HistGB	4.5919	0.5935

LightGBM 与 CIF 构成第二梯队头部，二者 RMSE 几乎相同，但 LightGBM 训练时间仅为 CIF 的零头。若预算有限、需要快速迭代，LightGBM 是**高性价比**的选择；追求精度峰值仍需 XGBoost/CatBoost。